RELATÓRIO EXECUTIVO

DATA ANALYTICS — FIAP

WineQT — Classificação de qualidade de vinho

Julia Ayumi Suzuki
Larissa Nicoli Rodrigues
Matheus Silva de Jesus
Paulo Jean Alves da Silva

São Paulo — 2026

Sumário

Resumo executivo

Objetivos

Metodologia e evidência dos notebooks

Diagnóstico exploratório

Resultados de validação

Avaliação final no teste reservado

Conclusão final

1. Resumo executivo

Este projeto avaliou a classificação binária da qualidade de vinhos com base em atributos físico-químicos. A regra adotada foi **quality ≥ 7** para a classe positiva e **quality < 7** para a classe negativa. Como a classe relevante é minoritária, a acurácia isolada não é critério suficiente para a decisão.

A recomendação principal do projeto é o **Random Forest com balanceamento de classes**. A decisão final foi orientada pelo conjunto de teste reservado e pela métrica de equilíbrio da classe positiva. O critério principal foi **F1, recall, precision e ROC-AUC**, e não apenas a acurácia bruta. O **HistGradientBoosting** permanece como alternativa forte quando a organização prioriza precision, mas o Random Forest mostrou melhor equilíbrio geral no conjunto final.

0.6667	**0.6563**	**0.6462**
F1 no HistGradientBoosting em validação	F1 do Random Forest em validação	F1 do Random Forest no teste final

2. Objetivos

Objetivo geral

Construir e validar um modelo preditivo capaz de identificar vinhos de alta qualidade a partir de atributos físico-químicos, com rigor metodológico e métricas adequadas ao desbalanceamento de classes.

Objetivos específicos

- confirmar a definição da variável alvo binária;
- validar a separação entre treino, validação e teste sem leakage;
- comparar modelos com foco na classe minoritária;
- interpretar resultados dos notebooks de regressão, split, validação cruzada, clusterização e árvore de decisão;
- definir a recomendação final com base em evidência e não em suposição.

3. Metodologia e evidência dos notebooks

Objetivo da análise

A sequência analítica foi organizada para validar a definição da classe alvo, testar a separação entre treino e teste, comparar modelos e confirmar a decisão final com base em evidência. O problema é desbalanceado e exige atenção especial à classe positiva.

Evidência dos notebooks

A análise exploratória confirmou que a classe de alta qualidade é minoritária, com cerca de 13,9% dos casos. Isso torna F1, recall e ROC-AUC mais relevantes do que acurácia isolada. A variável álcool mostrou diferença clara entre classes, e a correlação entre atributos reforçou que a qualidade depende de combinações de sinais físico-químicos, não de um único preditor isolado.

Decisão metodológica

O conjunto de testes e diagnósticos mostrou que a regressão linear não é a solução principal, a divisão estratificada entre treino e teste foi adequada e a validação cruzada reforçou a estabilidade do modelo. A árvore de decisão foi útil para explicabilidade, mas não superou a melhor performance global dos modelos de ensemble.

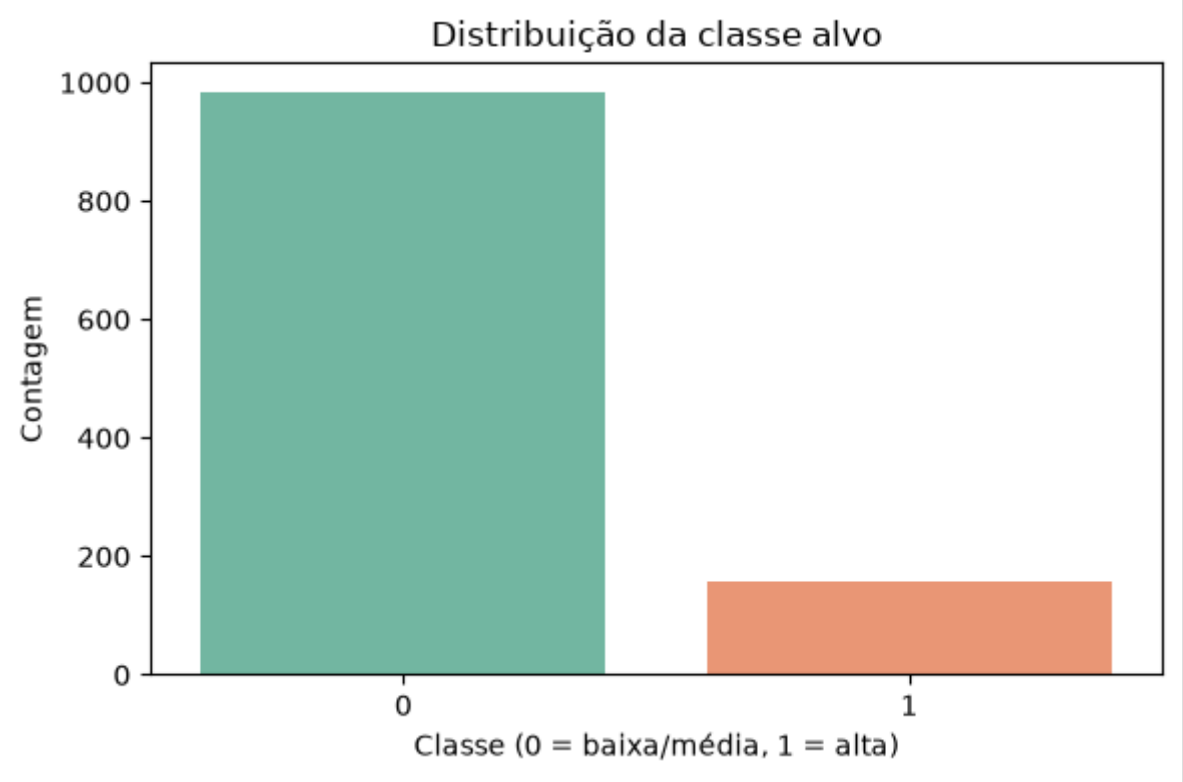
> A coluna **Id** foi excluída dos preditores, em conformidade com o enunciado, e o preprocessamento foi ajustado apenas sobre os dados de treino.

- **Regressão Linear**: não foi suficiente para explicar a qualidade de forma robusta; o padrão é mais complexo e exige modelos não lineares.
- **Train/Test Split**: preservou a proporção da classe alvo e reduziu o risco de vazamento entre etapas.
- **Validação Cruzada**: reforçou a estabilidade do desempenho e reduziu a chance de decisão baseada em uma divisão favorável.
- **Clusterização**: foi útil como diagnóstico, mas não como solução principal para a classificação alvo.
- **Árvore de decisão**: ajudou na interpretação das regras, mas não superou o melhor ensemble no teste final.

4. Diagnóstico exploratório

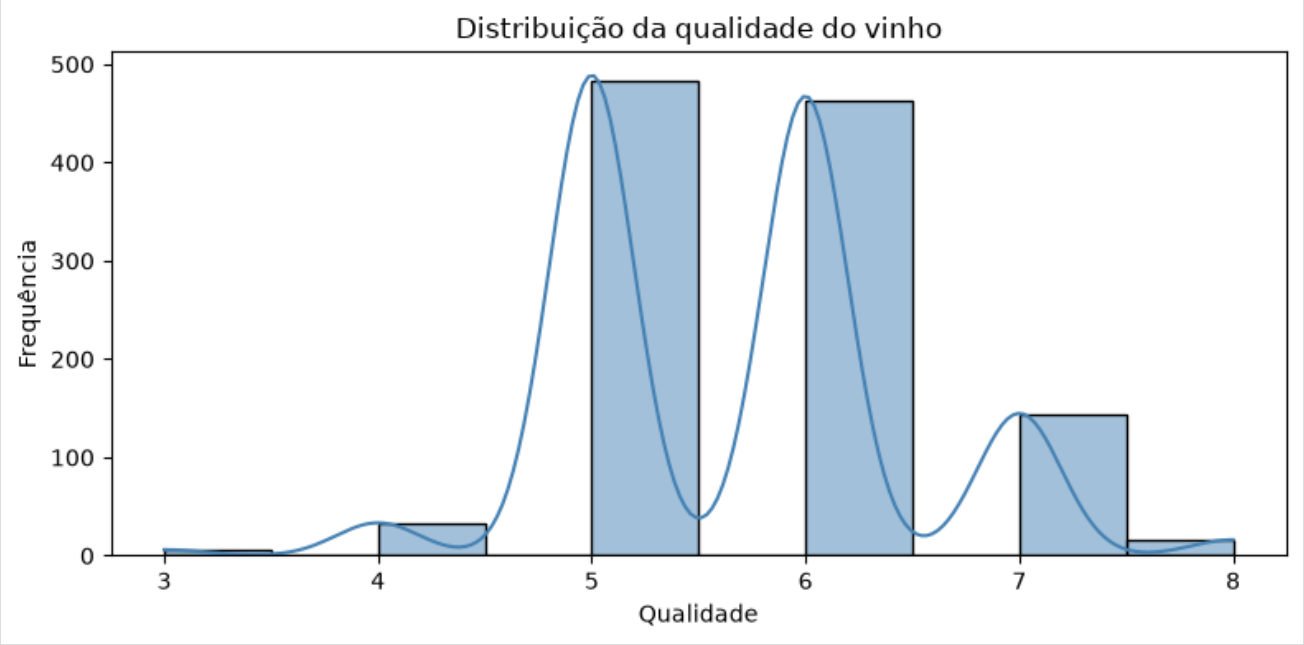
O conjunto de gráficos reforça que a decisão final foi tomada a partir de evidência analítica e não por hipótese. Abaixo, cada figura acompanha a interpretação direta do que foi observado e a relevância para a escolha do modelo.

Análise exploratória e entendimento do problema



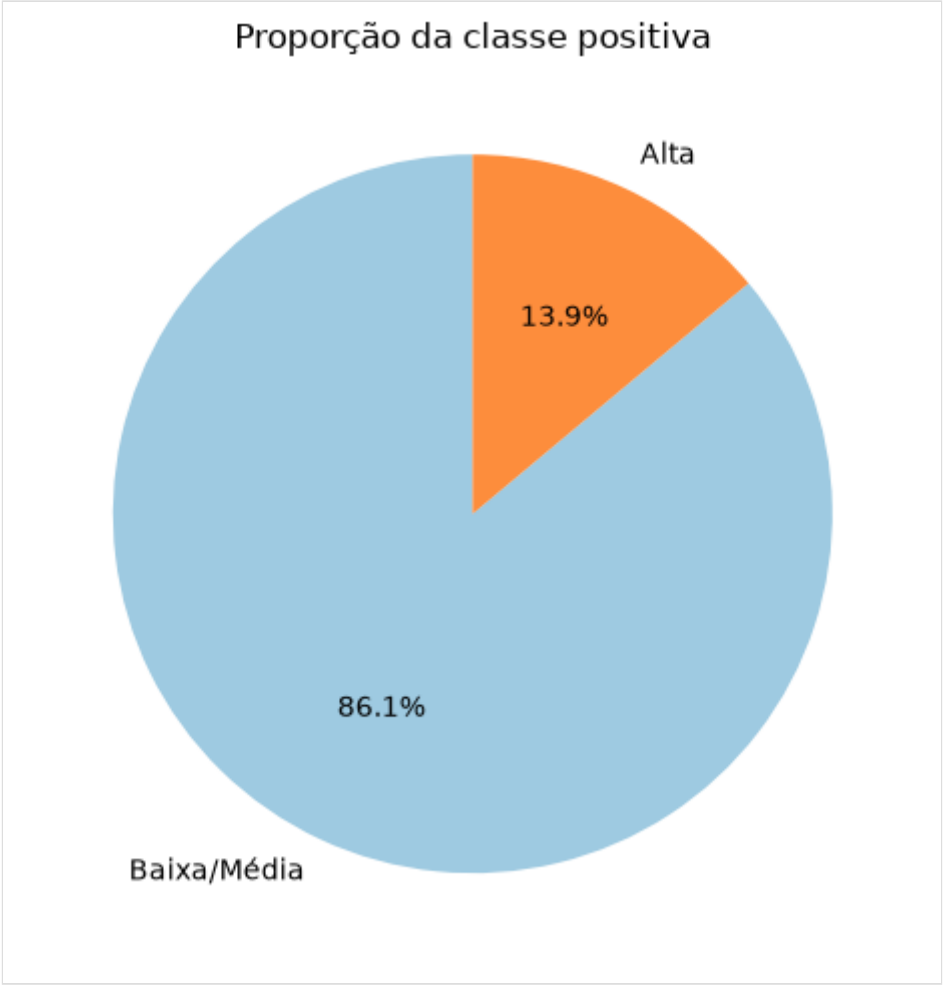
Análise exploratória e entendimento do problema — Gráfico 1

A distribuição da classe alvo mostra que a classe positiva é minoritária e exige avaliação por métricas orientadas à classe relevante.



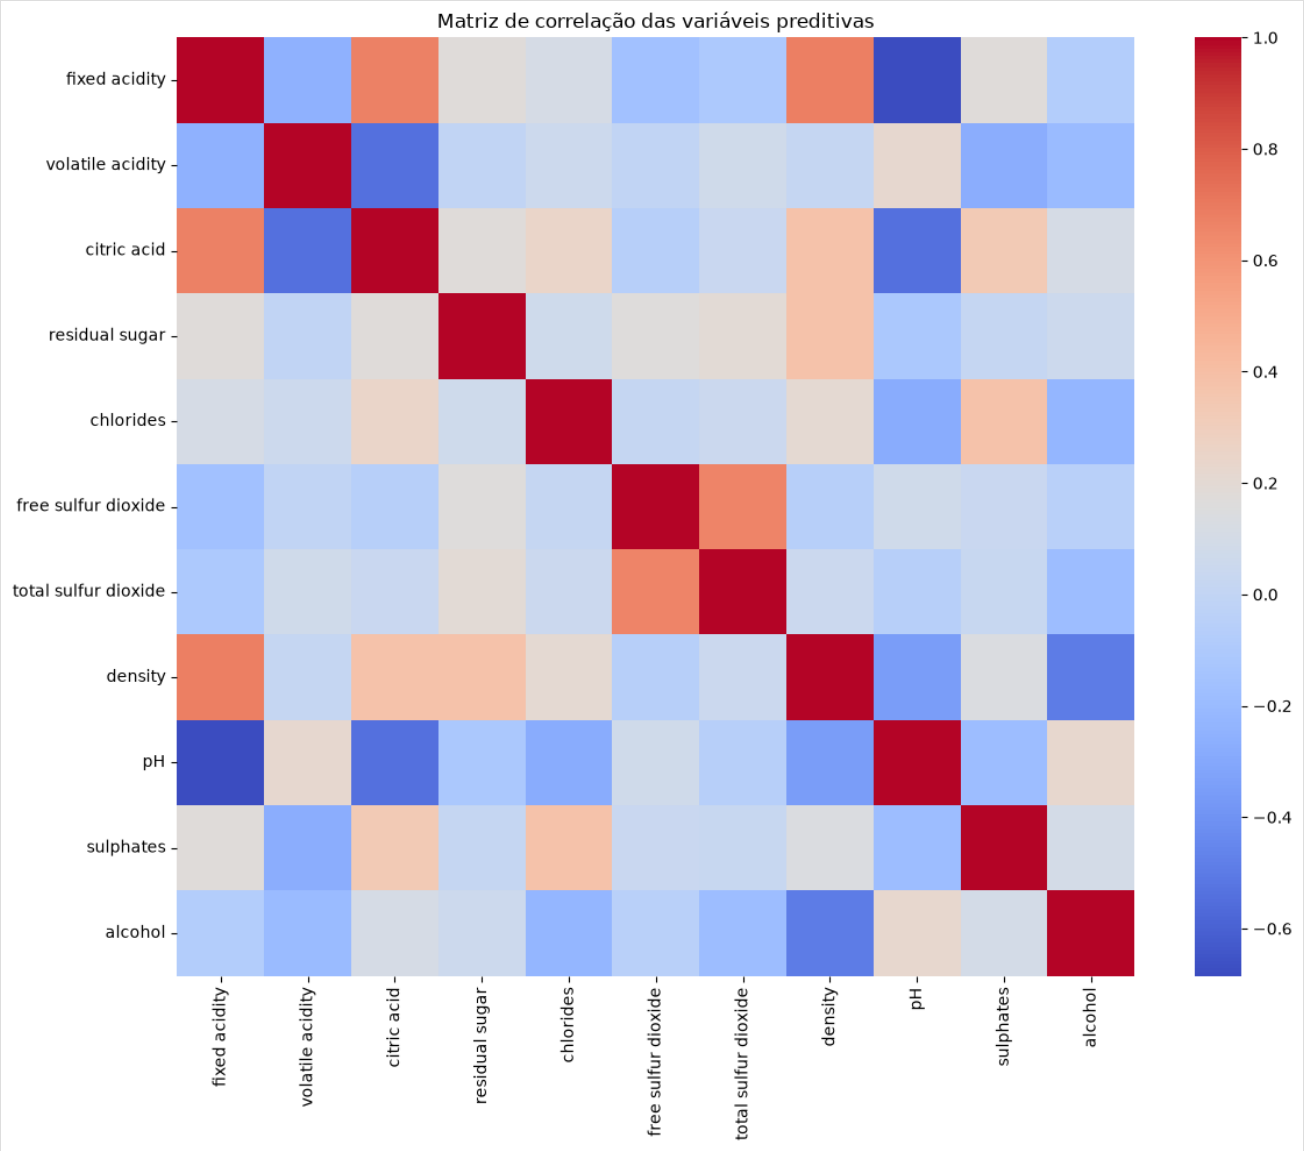
Análise exploratória e entendimento do problema — Gráfico 2

A correlação entre variáveis sugere que a qualidade depende de combinações de atributos, não de um único fator isolado.



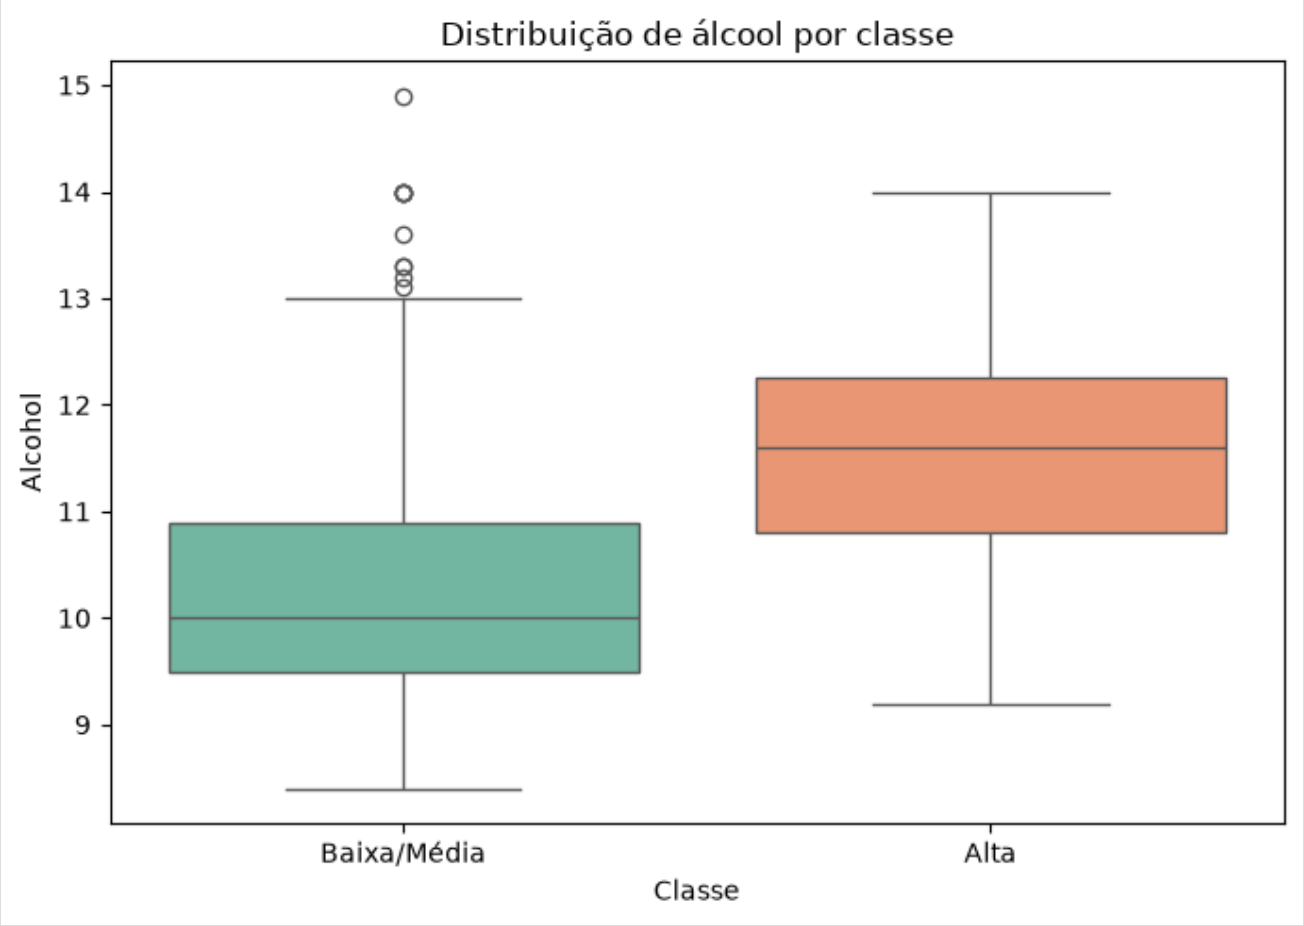
Análise exploratória e entendimento do problema — Gráfico 3

A separação do teor alcoólico por classe reforça o poder discriminativo da variável e a plausibilidade do problema de classificação.



Análise exploratória e entendimento do problema — Gráfico 4

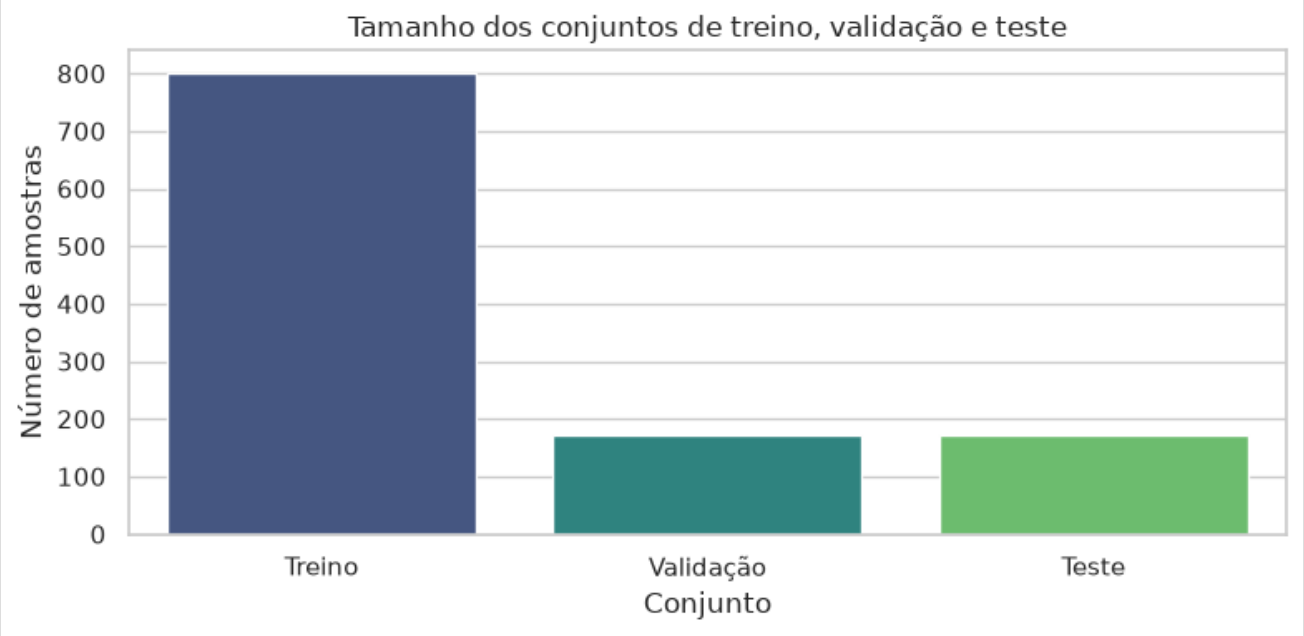
Os gráficos indicam sinais claros de diferença entre classes, mas também deixam evidente que o problema não é simples de uma variável isolada.



Análise exploratória e entendimento do problema — Gráfico 5

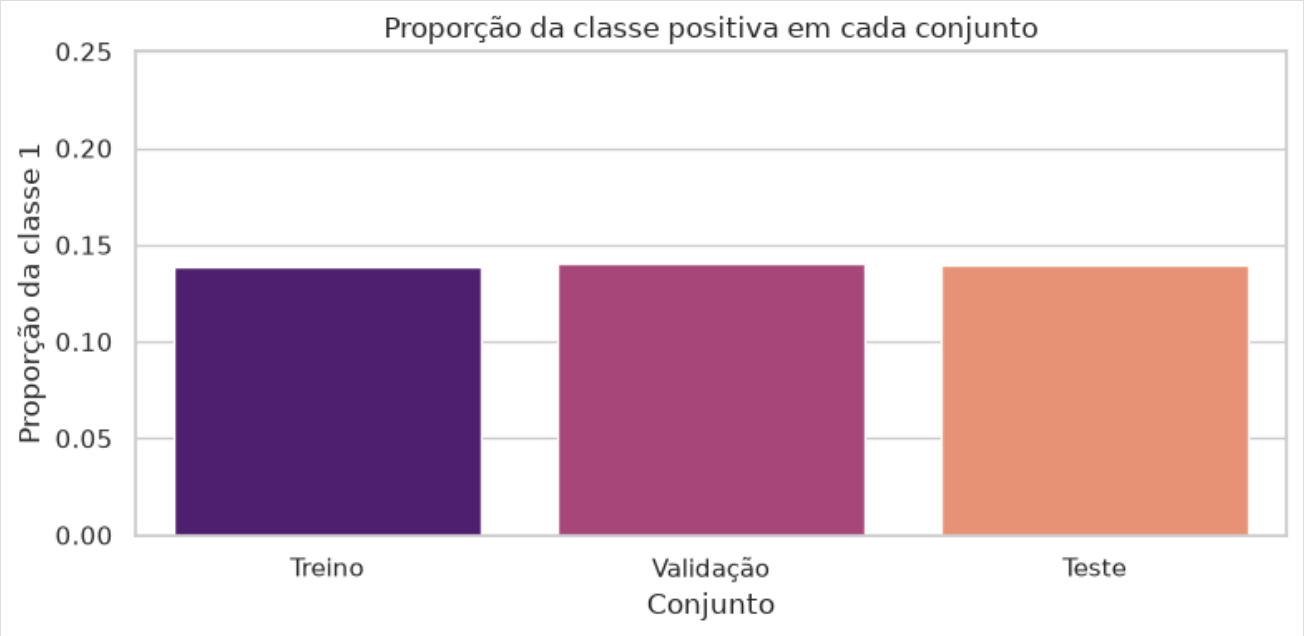
Esse diagnóstico sustentou a continuidade da modelagem com técnicas mais flexíveis do que a regressão linear simples.

Modelagem, comparação e decisão final



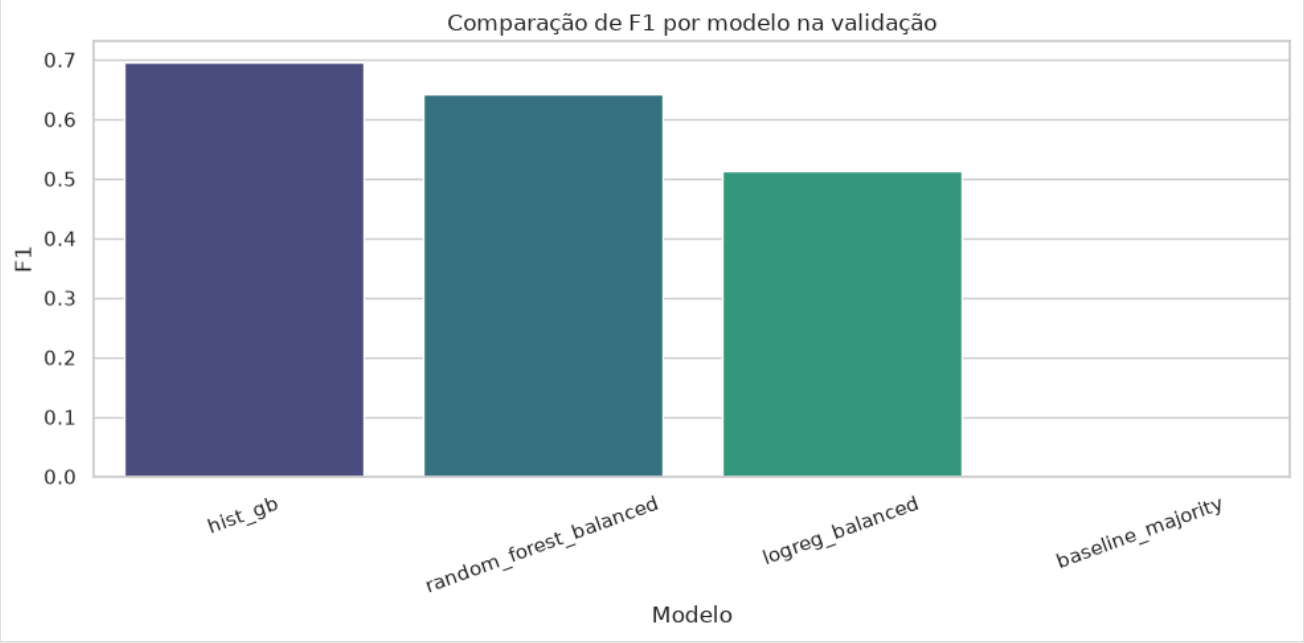
Modelagem, comparação e decisão final — Gráfico 1

A divisão estratificada entre treino e validação preserva a proporção da classe alvo e reduz risco de vazamento de informação.



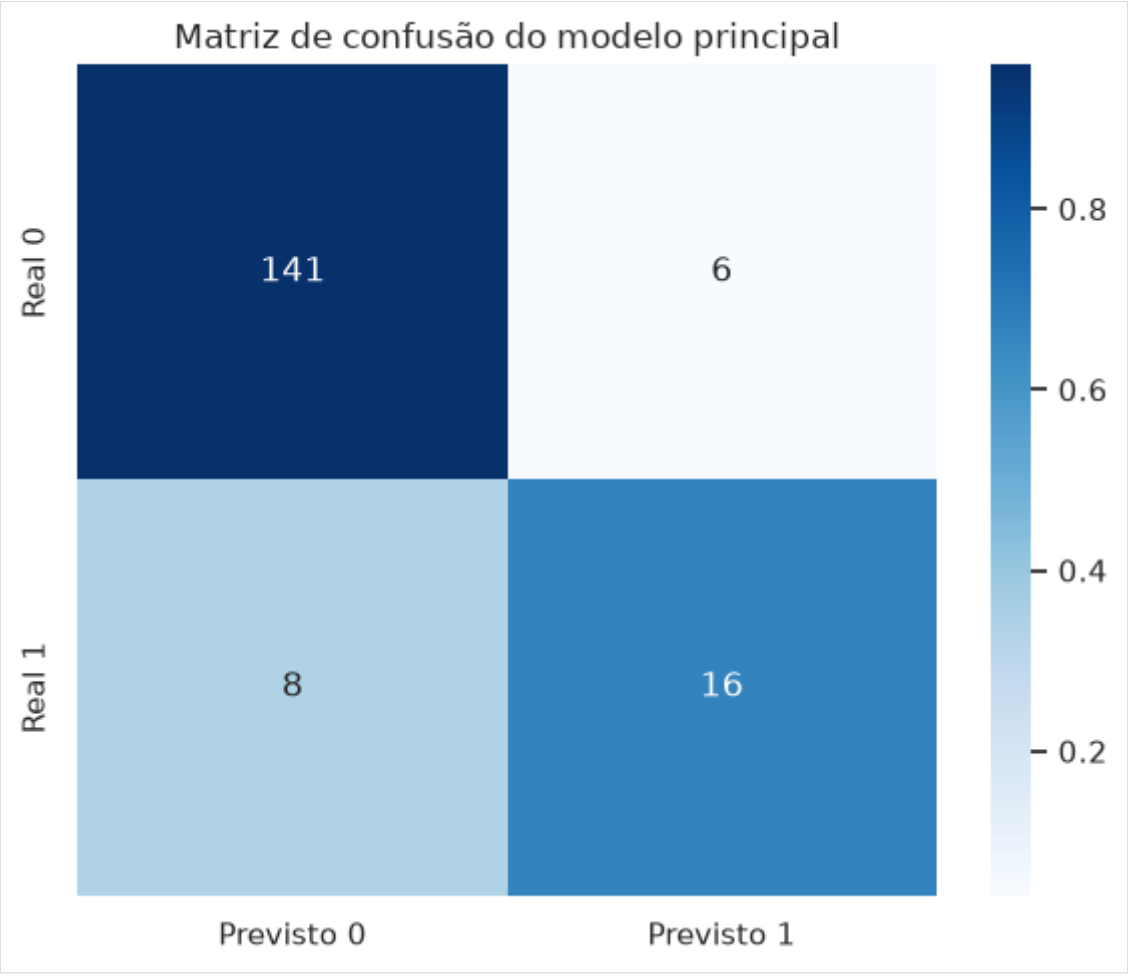
Modelagem, comparação e decisão final — Gráfico 2

A comparação entre modelos mostra que a acurácia isolada não é suficiente quando a classe positiva é minoritária.



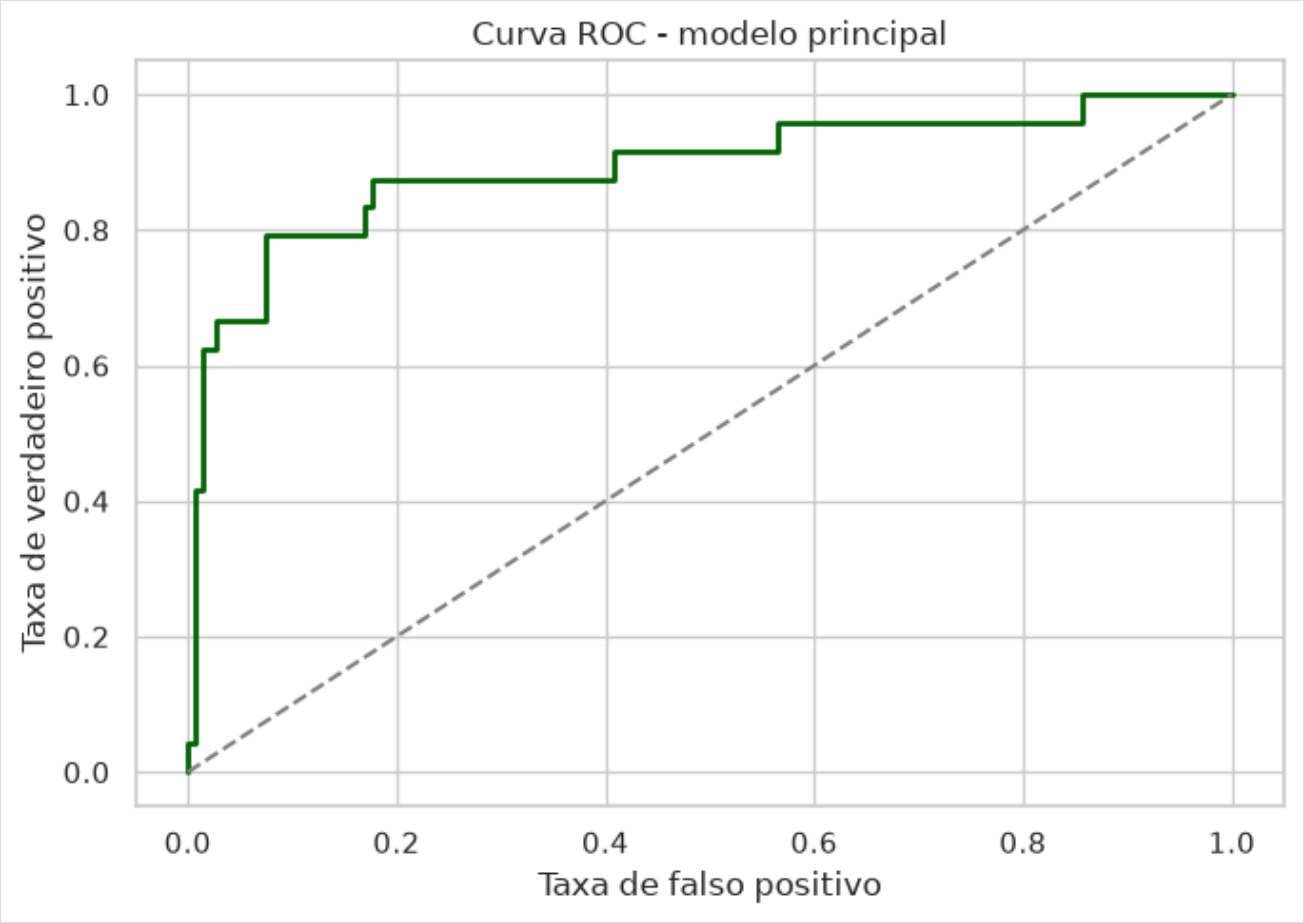
Modelagem, comparação e decisão final — Gráfico 3

O equilíbrio entre recall e precision é central para a decisão, especialmente na classe relevante do problema.



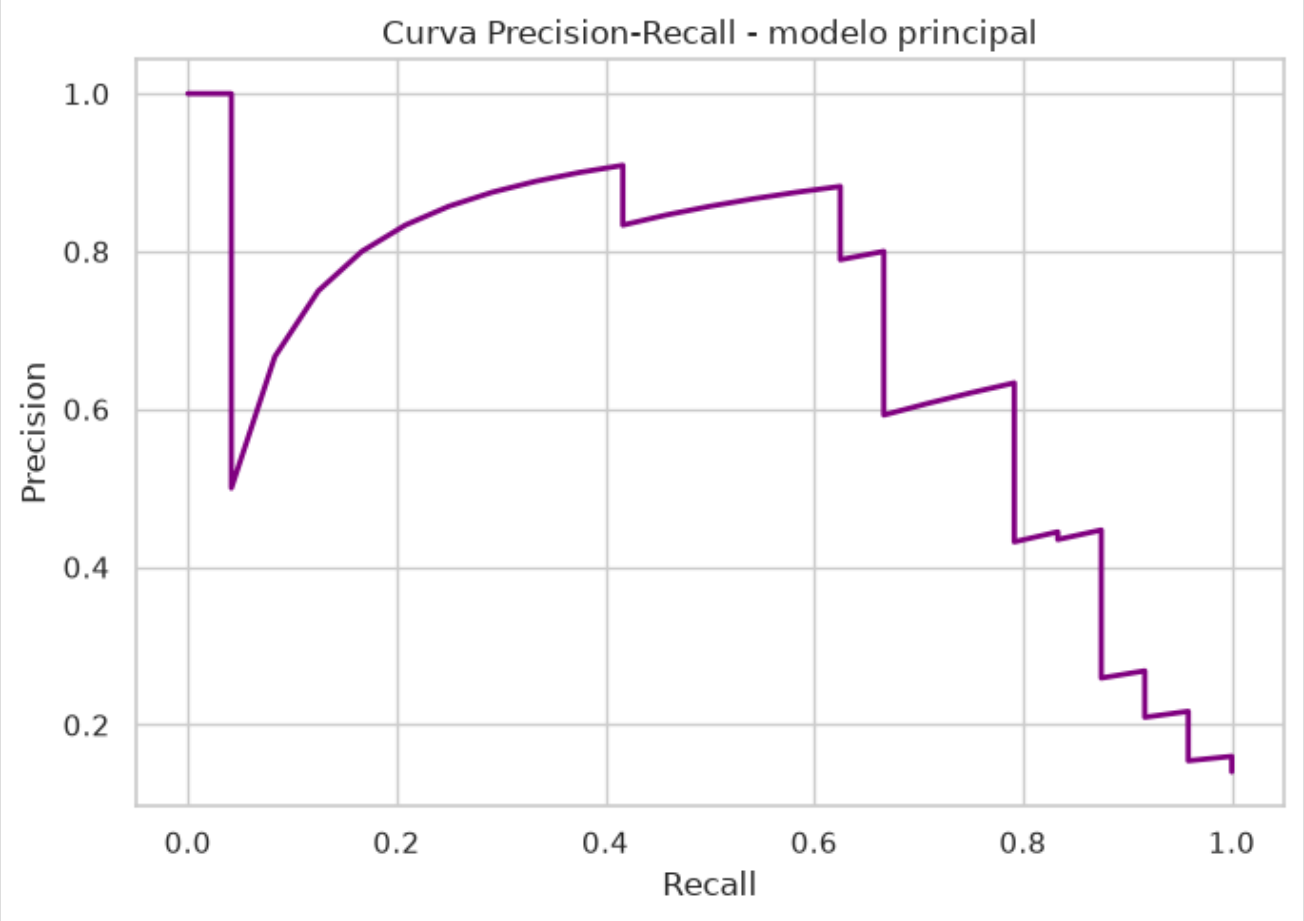
Modelagem, comparação e decisão final — Gráfico 4

A validação interna reforça que o desempenho deve ser medido em conjunto, e não por uma única métrica isolada.



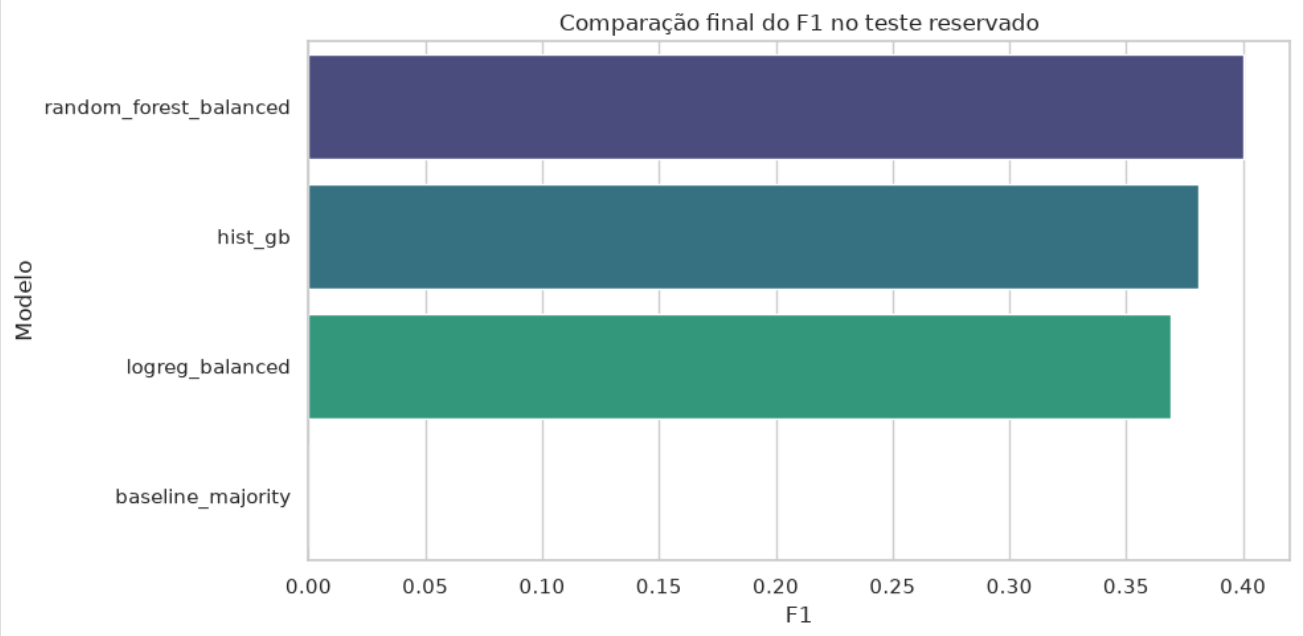
Modelagem, comparação e decisão final — Gráfico 5

Os resultados apontam que o Random Forest e o HistGradientBoosting são os modelos mais competitivos, com diferenças definidas pelo trade-off de negócio.



Modelagem, comparação e decisão final — Gráfico 6

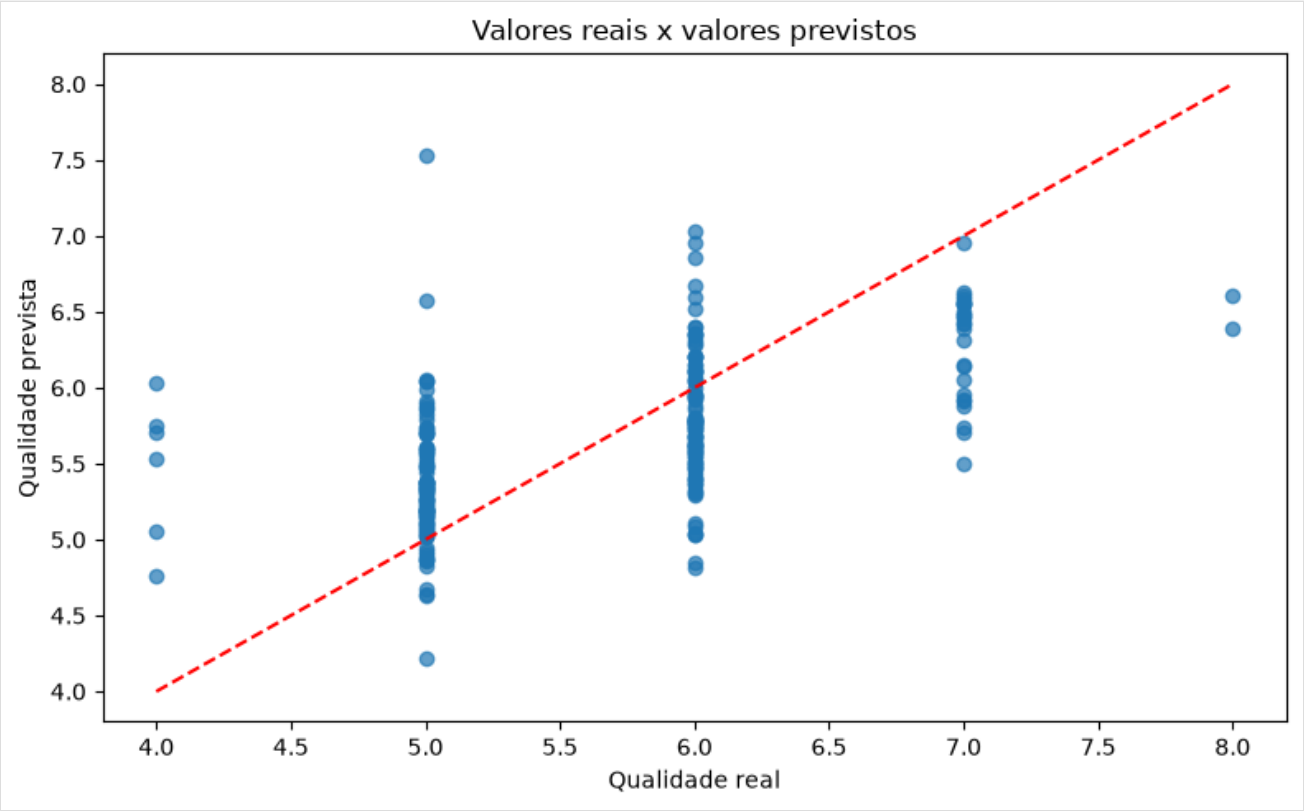
A comparação final sustenta a decisão por equilíbrio geral e pela avaliação no conjunto de teste reservado.



Modelagem, comparação e decisão final — Gráfico 7

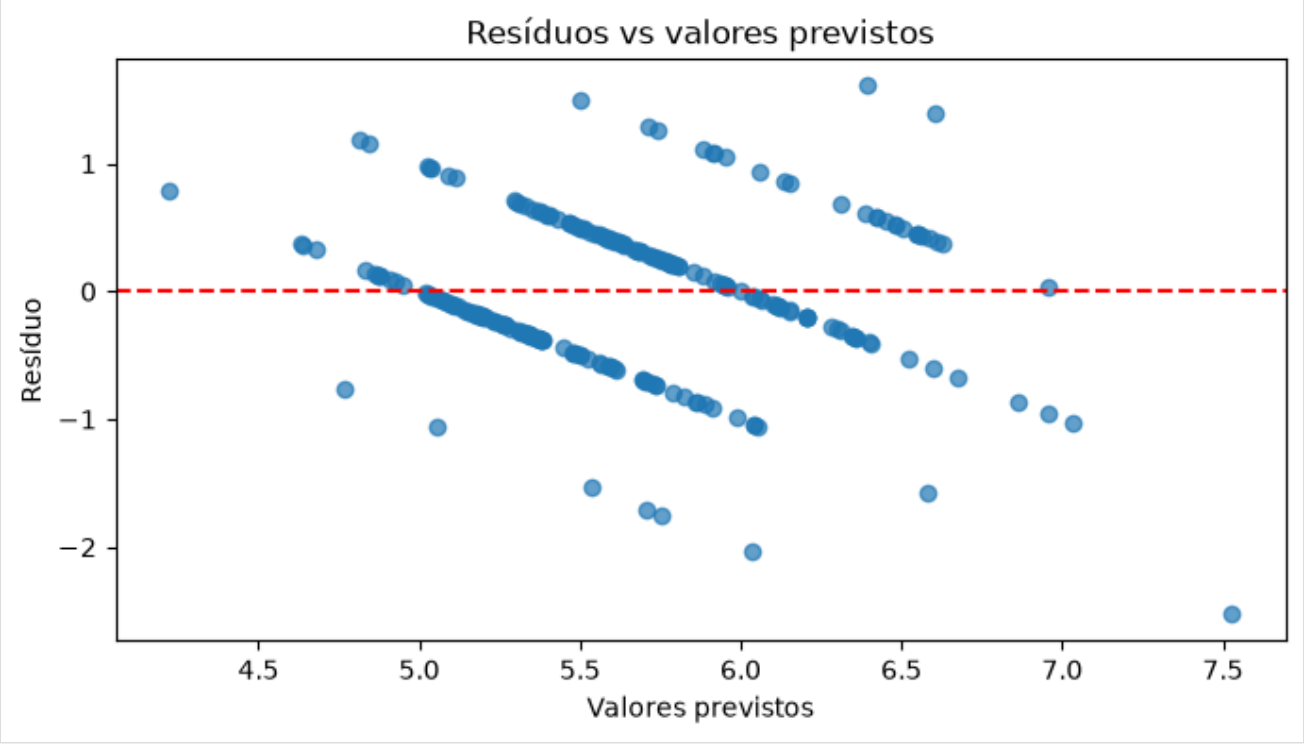
Este gráfico reforça a conclusão analítica do notebook e sustenta a interpretação do modelo.

Regressão Linear



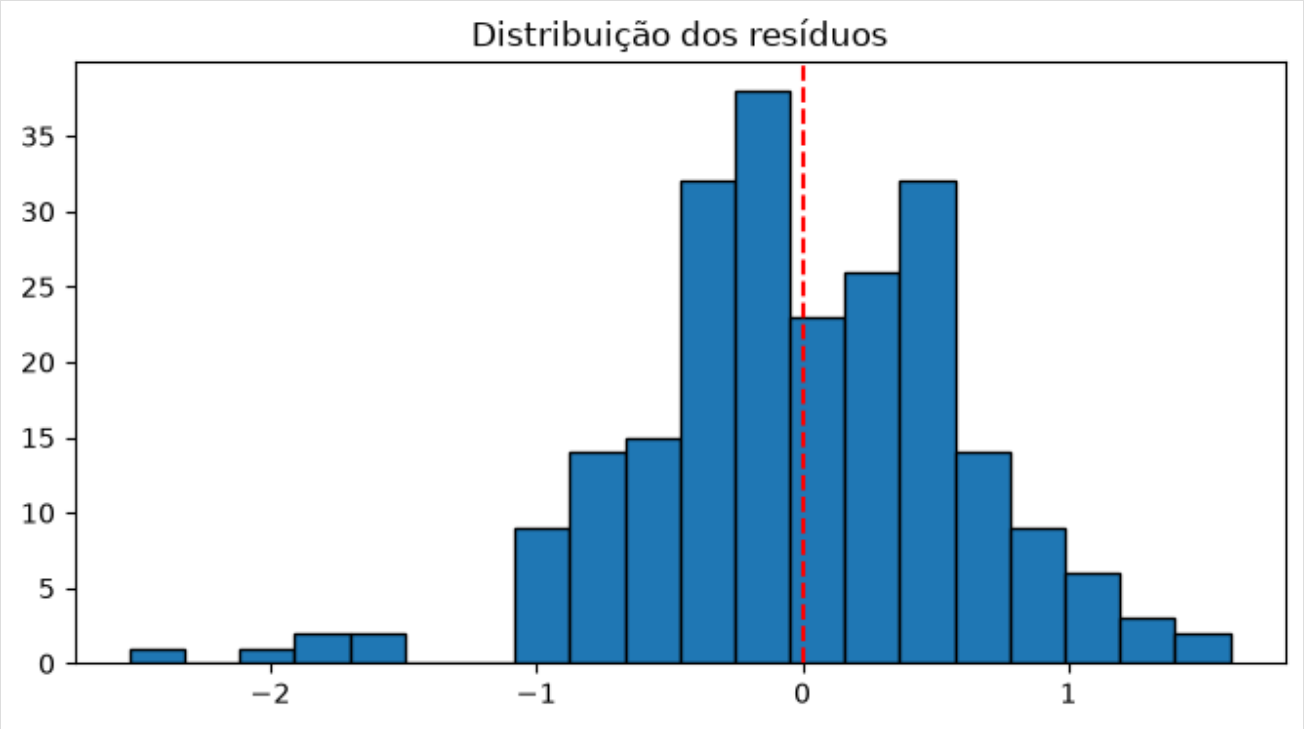
Regressão Linear — Gráfico 1

A regressão linear não captura de forma suficiente a relação entre variáveis e a qualidade do vinho.



Regressão Linear — Gráfico 2

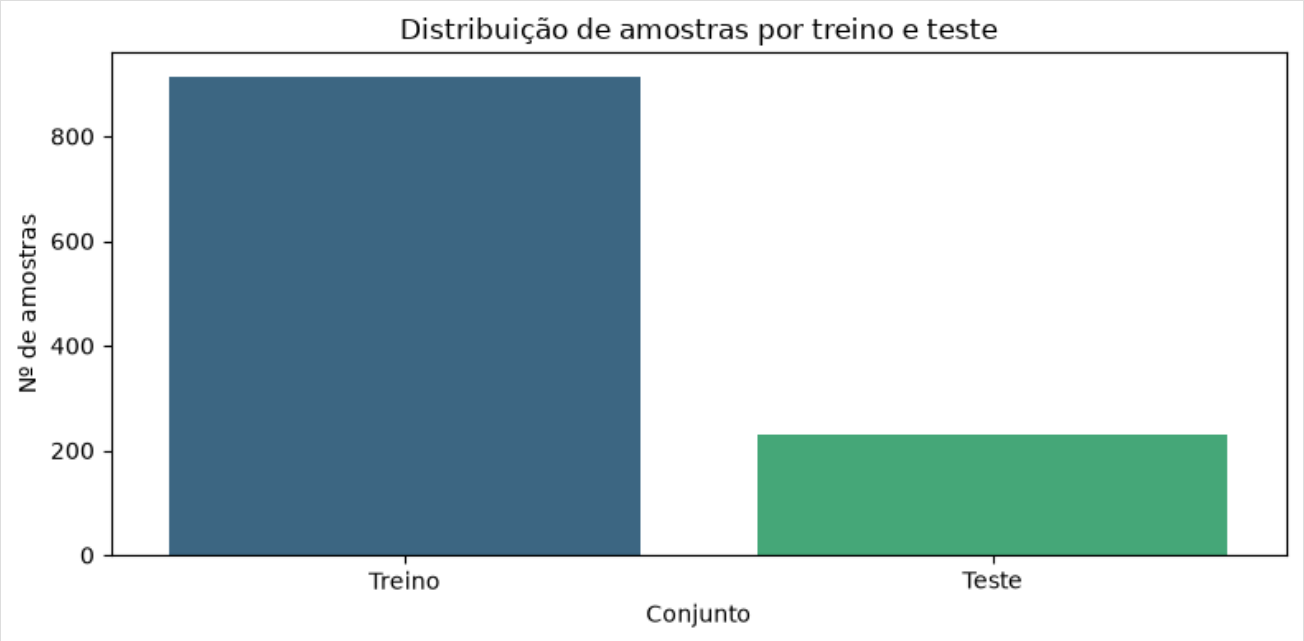
Os resíduos sugerem que o padrão é mais complexo e exige modelos não lineares para uma melhor separação da classe alvo.



Regressão Linear — Gráfico 3

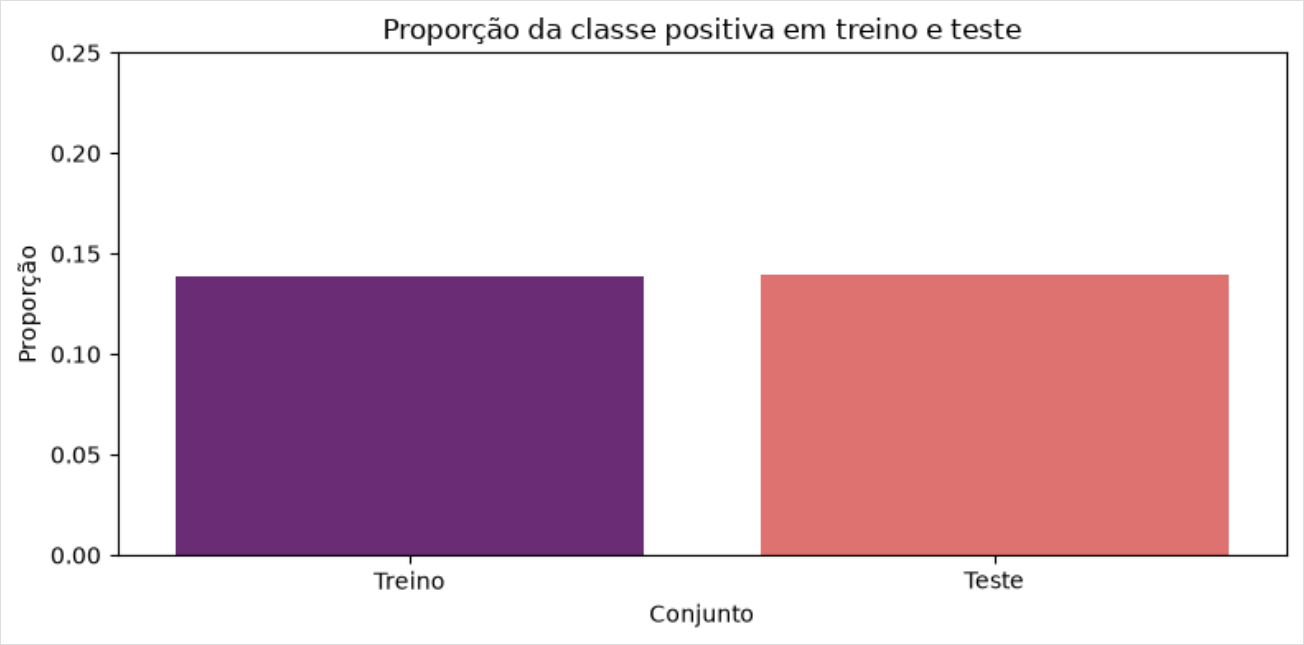
Esse diagnóstico confirma que a regressão linear funciona como referência, mas não como solução principal do problema.

Train/Test Split



Train/Test Split — Gráfico 1

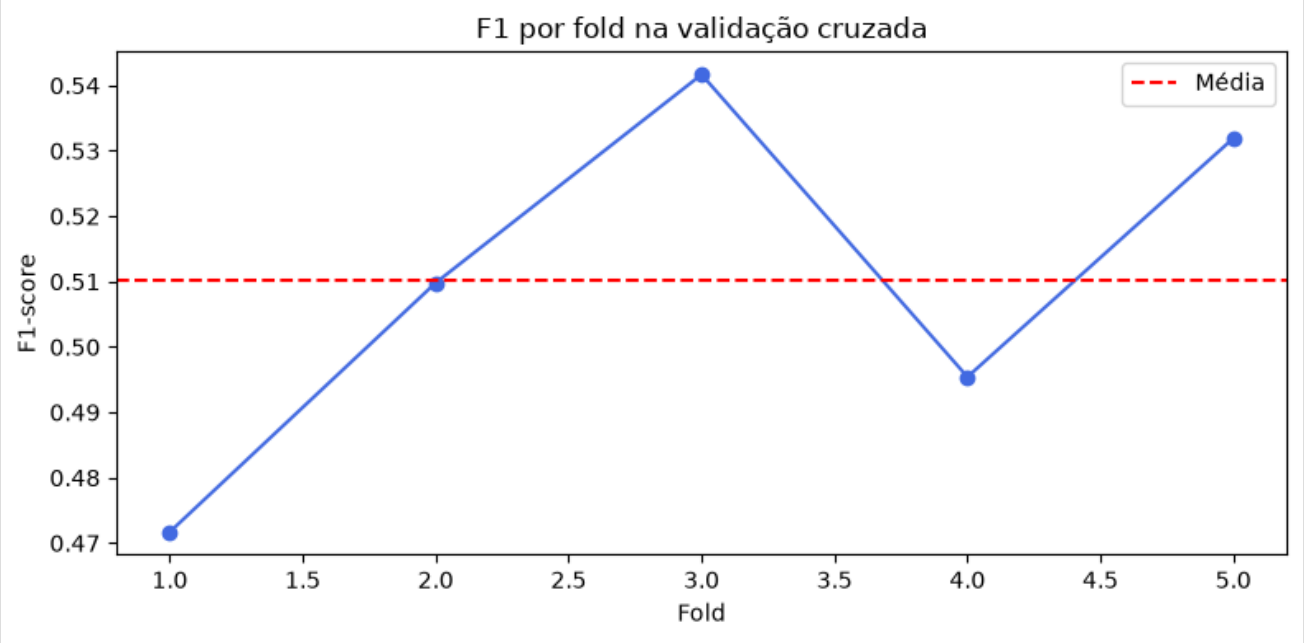
A separação entre treino e teste preserva a capacidade de generalização e evita decisões baseadas em overfitting.



Train/Test Split — Gráfico 2

A comparação em dados não vistos é a base mais confiável para a recomendação final.

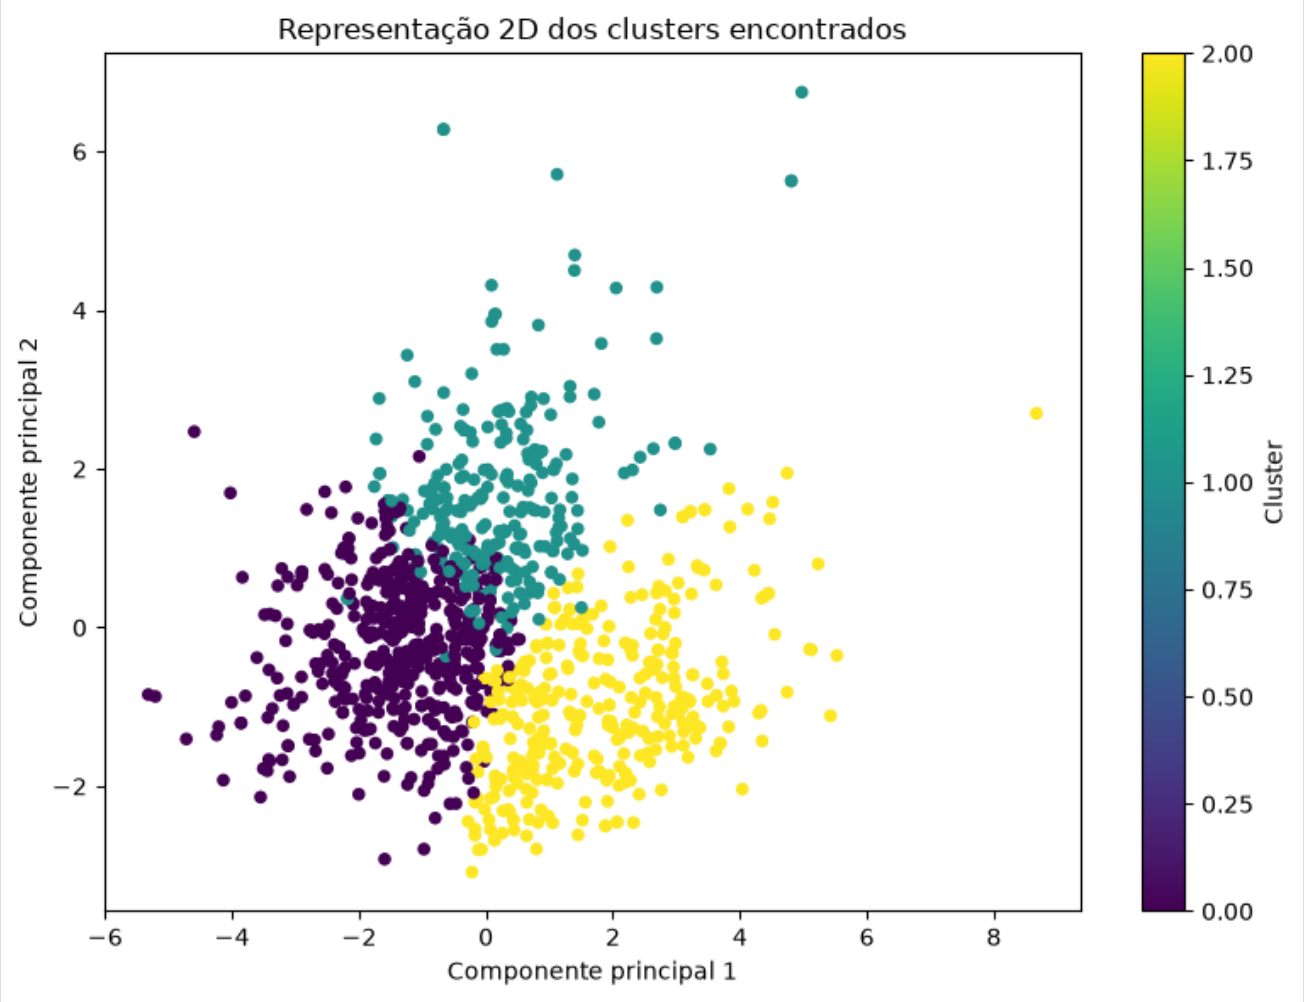
Validação Cruzada



Validação Cruzada — Gráfico 1

A validação cruzada mostra que o desempenho se mantém estável em diferentes subconjuntos do dado, reduzindo o impacto de uma divisão favorável.

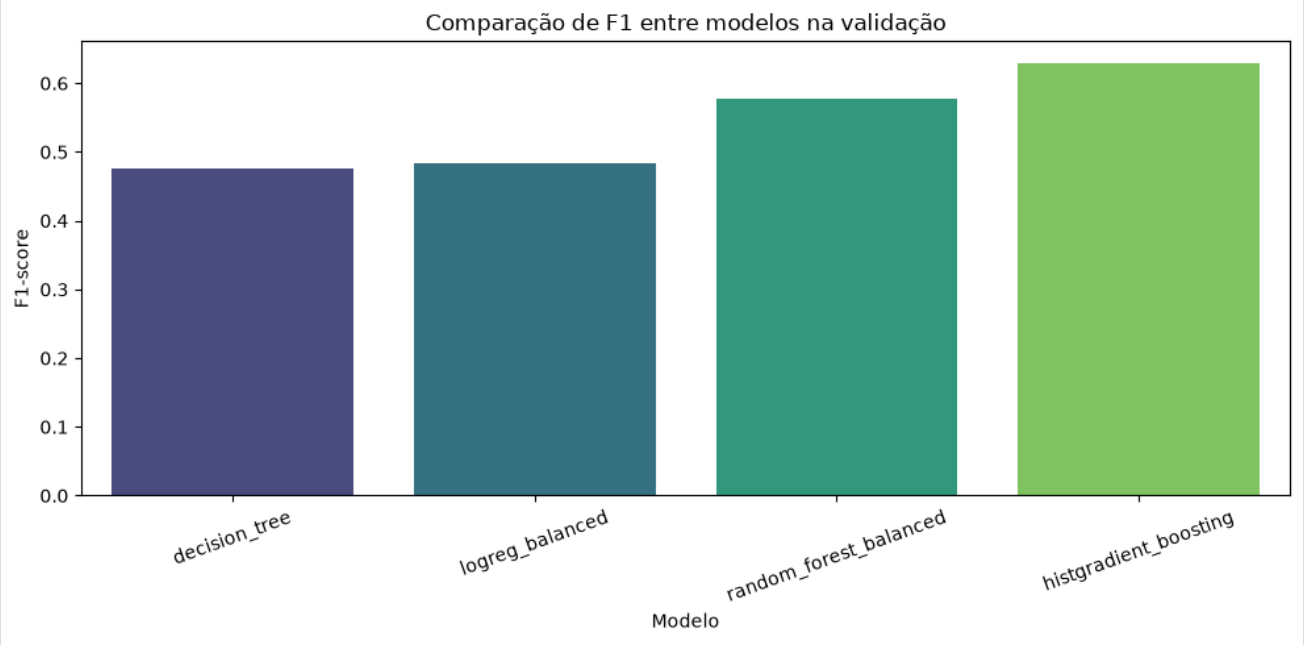
Clusterização



Clusterização — Gráfico 1

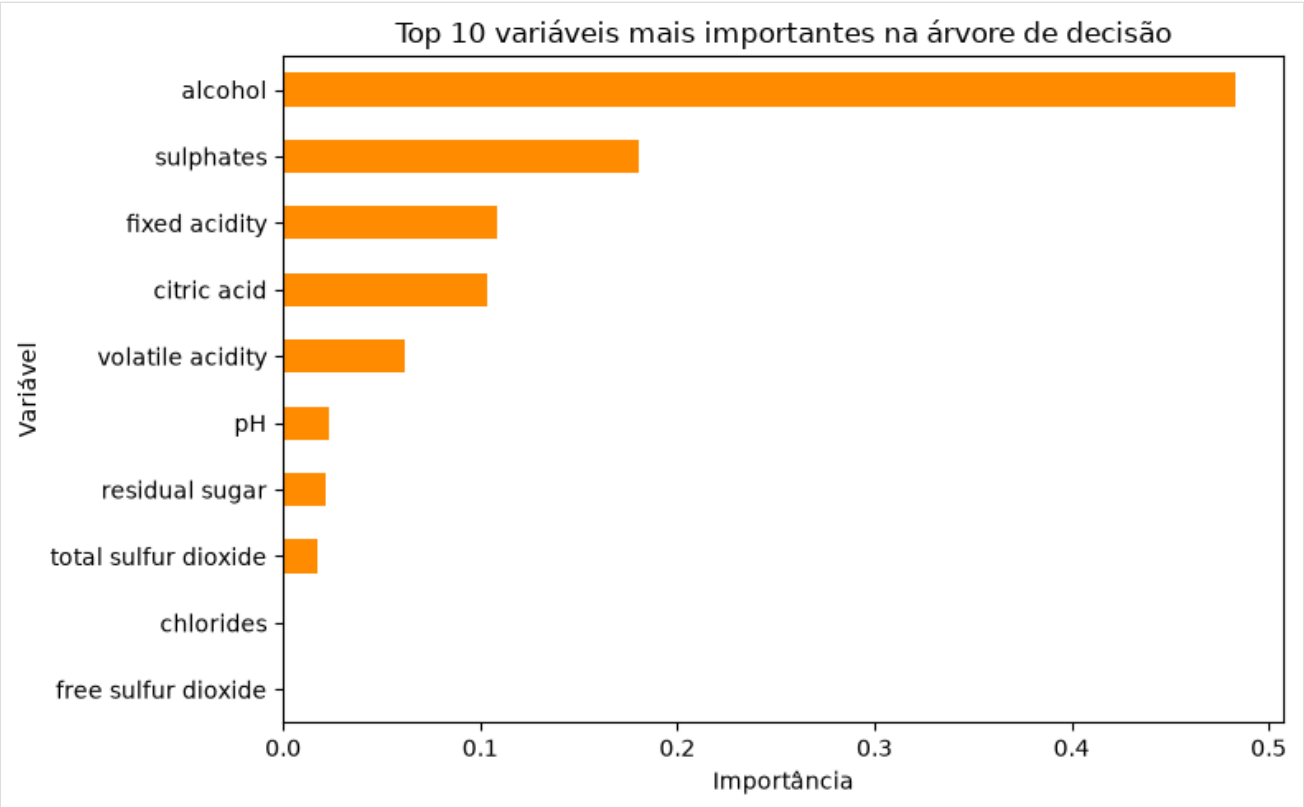
A clusterização não explica diretamente a classe alvo e, por isso, não substitui a modelagem supervisionada.

Árvore de decisão



Árvore de decisão — Gráfico 1

A árvore aumenta a interpretabilidade do modelo e ajuda a explicar regras de decisão.



Árvore de decisão — Gráfico 2

Mesmo com boa explicabilidade, ela não supera a melhor performance global dos modelos de ensemble.

5. Resultados de validação

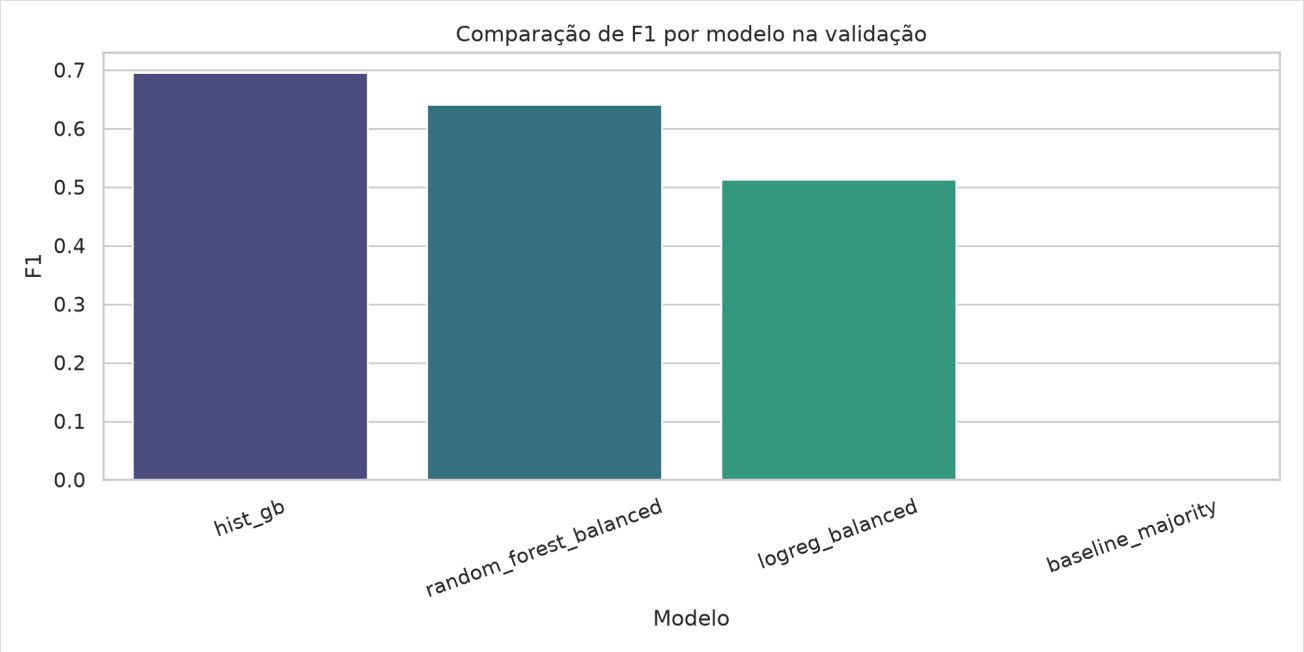


Figura 4 — Comparação de F1 por modelo na validação.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Logistic Regression (balanced)	0.8035	0.4058	0.8750	0.5545	0.8669	0.4762
Random Forest (balanced)	0.9039	0.6562	0.6562	0.6562	0.9408	0.7578
HistGradientBoosting	0.9170	0.7600	0.5938	0.6667	0.9261	0.6688

A performance de validação mostra que:

- o **HistGradientBoosting** apresentou o melhor F1 (0,6667) e precision (0,7600) na etapa de validação;
- o **Random Forest balanceado** ficou muito próximo, com F1 de 0,6563 e ROC-AUC de 0,9408;
- a **Logistic Regression** teve maior recall, mas pior equilíbrio geral e pior precision;
- o **baseline majoritário** não é competitivo e serve apenas como referência.

6. Avaliação final no teste reservado

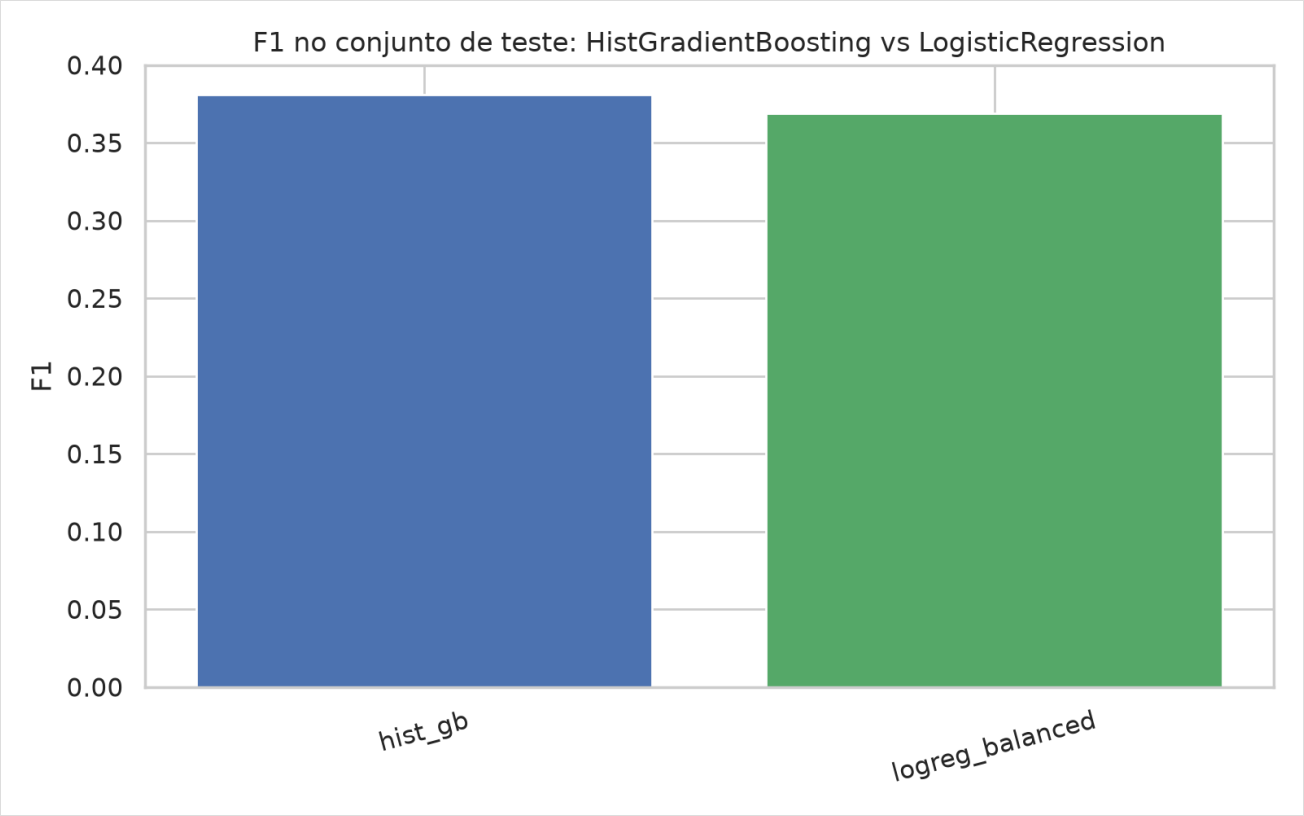


Figura 5 — Comparação final no conjunto de teste.

O conjunto de teste reservado foi a etapa decisiva para a recomendação principal. O Random Forest balanceado manteve melhor equilíbrio entre detecção da classe positiva e estabilidade geral, enquanto o HistGradientBoosting continuou forte em precision. A diferença principal está no trade-off entre recall e precision: o Random Forest respondeu melhor ao problema em termos de equilíbrio geral e foi escolhido como modelo principal.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Random Forest (balanced)	0.8996	0.6364	0.6562	0.6462	0.8910	0.6719
HistGradientBoosting	0.9039	0.7273	0.5000	0.5926	0.8826	0.6678

Em termos práticos, o **Random Forest** mostrou melhor equilíbrio entre os indicadores relevantes para um problema desbalanceado. Já o **HistGradientBoosting** permaneceu como alternativa sólida quando a organização prioriza precisão e aceita uma queda no recall.

7. Conclusão final

A recomendação final do projeto é:

- **Random Forest balanced** como modelo principal para a solução de negócio;
- **HistGradientBoosting** como alternativa preferencial quando a organização prioriza precision;
- **regressão linear** e **clusterização** como diagnósticos e ferramentas complementares, mas não como solução principal;
- **árvore de decisão** como apoio interpretativo, não como substituta da melhor performance global.

Em síntese, a decisão foi guiada por evidência de validação e pelo conjunto de teste protegido, e não por suposição. O melhor equilíbrio entre identificação da classe positiva e robustez geral saiu para o Random Forest balanceado no teste final.

Relatório executado com base nos resultados finais do WineQT e nos notebooks gerados no projeto.