RELATÓRIO EXECUTIVO

DATA ANALYTICS — FIAP

WineQT — Classificação de qualidade de vinho

Julia Ayumi Suzuki
Larissa Nicoli Rodrigues
Matheus Silva de Jesus
Paulo Jean Alves da Silva

São Paulo — 2026

Sumário

1. Resumo executivo 3
2. Objetivos 3
3. Metodologia e evidência dos notebooks 4
4. Diagnóstico exploratório 5
    4.1 Análise exploratória 5
    4.2 Evidências complementares 10
5. Resultados de validação 19
    5.1 Ajuste de limiar 20
    5.2 Checagem final no teste reservado 20
6. Avaliação final no teste reservado 21
7. Conclusão final 22

1. Resumo executivo

O projeto partiu de uma pergunta objetiva: como identificar, de forma confiável, vinhos de alta qualidade usando apenas atributos físico-químicos. A regra de negócio foi mantida do início ao fim: **quality ≥ 7** como classe positiva e **quality < 7** como classe negativa. Como a classe positiva é minoritária, a análise foi conduzida com foco em equilíbrio entre sensibilidade e precisão da classe relevante.

Na trilha de decisão, comparamos modelos, validamos alternativas para outliers e calibramos limiar sem usar o teste final na escolha. O desfecho foi a recomendação de **Random Forest com balanceamento de classes** e limiar operacional de **0.46**, sustentado por **F1, recall, precision, ROC-AUC e Average Precision**.

0.6647	0.4167	0.4167
F1 do Random Forest com limiar 0.46 (CV)	F1 do Random Forest com limiar 0.46 (teste)	Recall do Random Forest com limiar 0.46 (teste)

2. Objetivos

Objetivo geral

Construir e validar um modelo preditivo capaz de identificar vinhos de alta qualidade a partir de atributos físico-químicos, com rigor metodológico e métricas adequadas ao desbalanceamento de classes.

Objetivos específicos

- confirmar a definição da variável alvo binária;
- validar a separação entre treino, validação e teste sem leakage;
- comparar modelos com foco na classe minoritária;
- interpretar resultados dos notebooks de regressão, split, validação cruzada, clusterização e árvore de decisão;
- definir a recomendação final com base em evidência e não em suposição.

3. Metodologia e evidência dos notebooks

Objetivo da análise

A trilha metodológica foi montada como uma sequência de decisão: entender o dado, testar alternativas em ambiente controlado e validar a decisão final em conjunto reservado. Como o problema é desbalanceado, o foco permaneceu na classe positiva durante todas as comparações.

Evidência dos notebooks

A análise exploratória mostrou que a classe de alta qualidade representa cerca de 13,9% do conjunto. Esse ponto definiu a régua analítica: F1, recall e ROC-AUC ganharam prioridade sobre acurácia isolada. Também foi observado que álcool e correlações multivariadas oferecem sinal útil para distinguir as classes.

Na etapa de outliers, boxplots e critério de IQR destacaram extremos em sulfur dioxide, chlorides e residual sugar. A decisão foi não remover pontos de forma automática no EDA, preservando sinal potencial da classe positiva para avaliação experimental posterior.

Decisão metodológica

Os testes mostraram que regressão linear funciona como referência, mas não captura a complexidade do problema. A divisão estratificada e a validação cruzada trouxeram estabilidade para a comparação. A árvore de decisão contribuiu para explicabilidade, enquanto os ensembles sustentaram melhor desempenho preditivo.

> A coluna **Id** foi excluída dos preditores, em conformidade com o enunciado, e o preprocessamento foi ajustado apenas sobre os dados de treino.

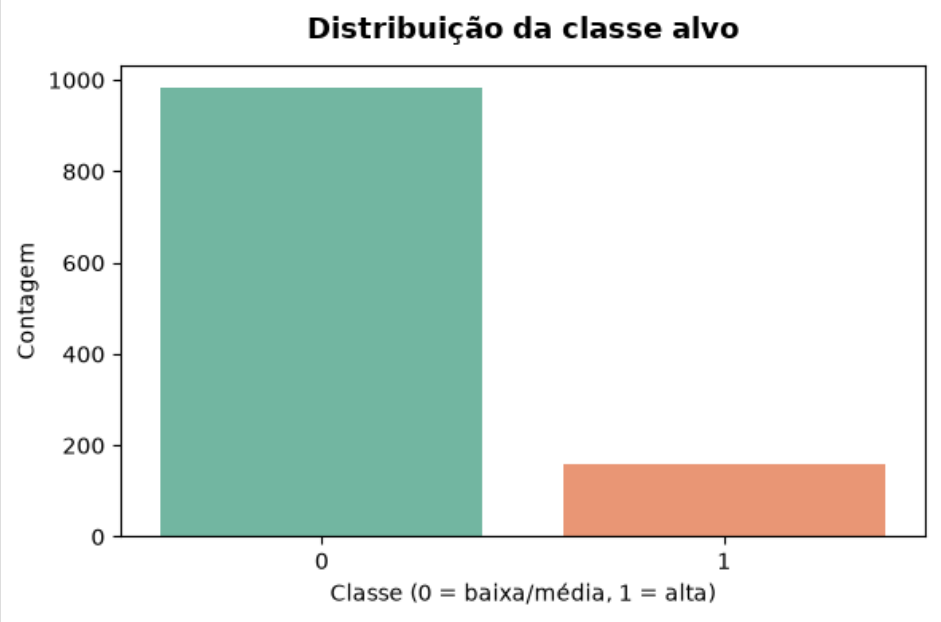
- **Regressão Linear**: não foi suficiente para explicar a qualidade de forma robusta; o padrão é mais complexo e exige modelos não lineares.
- **Train/Test Split**: preservou a proporção da classe alvo e reduziu o risco de vazamento entre etapas.
- **Validação Cruzada**: reforçou a estabilidade do desempenho e reduziu a chance de decisão baseada em uma divisão favorável.
- **Clusterização**: foi útil como diagnóstico, mas não como solução principal para a classificação alvo.
- **Árvore de decisão**: ajudou na interpretação das regras, mas não superou o melhor ensemble no teste final.

4. Diagnóstico exploratório

> A leitura exploratória abre a narrativa do projeto: primeiro entendemos a distribuição da classe e da qualidade, depois avaliamos relações entre variáveis e, por fim, diagnosticamos outliers. Isso prepara o terreno para a modelagem com critérios claros de decisão.

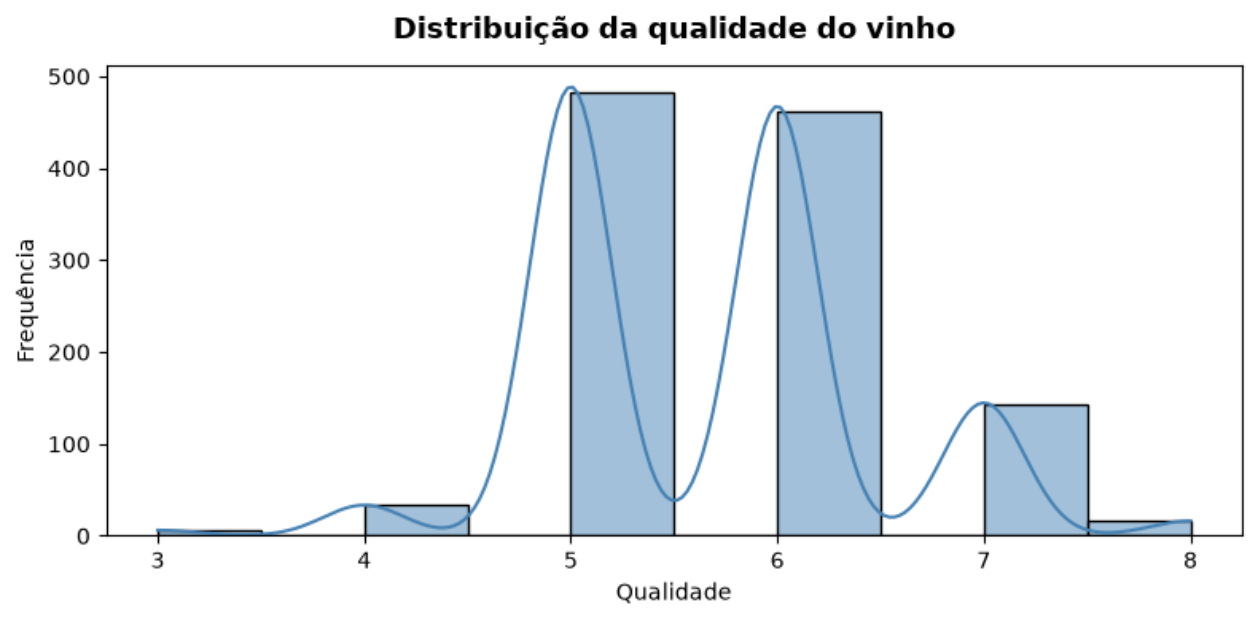
4.1 Análise exploratória

Esta seção apresenta os sinais iniciais do problema: distribuição da classe alvo, distribuição da qualidade, relações entre variáveis e diagnóstico de outliers. O objetivo é contextualizar por que as etapas seguintes priorizam métricas de equilíbrio da classe positiva.



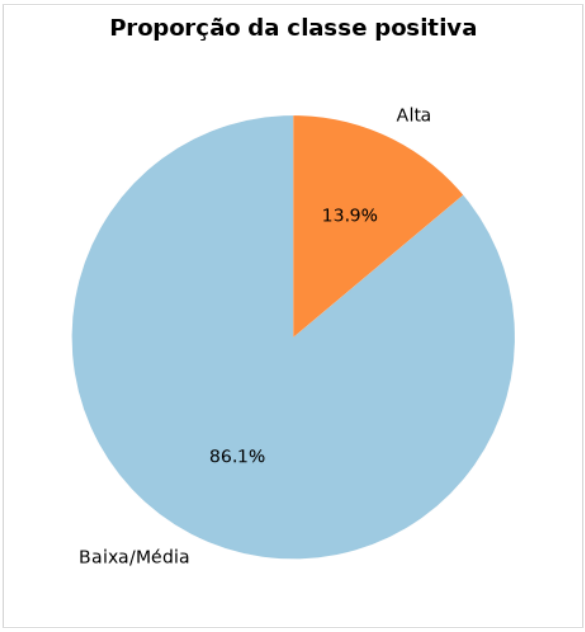
Análise exploratória — Gráfico 1

A história começa com um ponto central: a classe positiva é minoritária, então o problema exige foco em métricas de equilíbrio e sensibilidade, e não apenas acurácia.



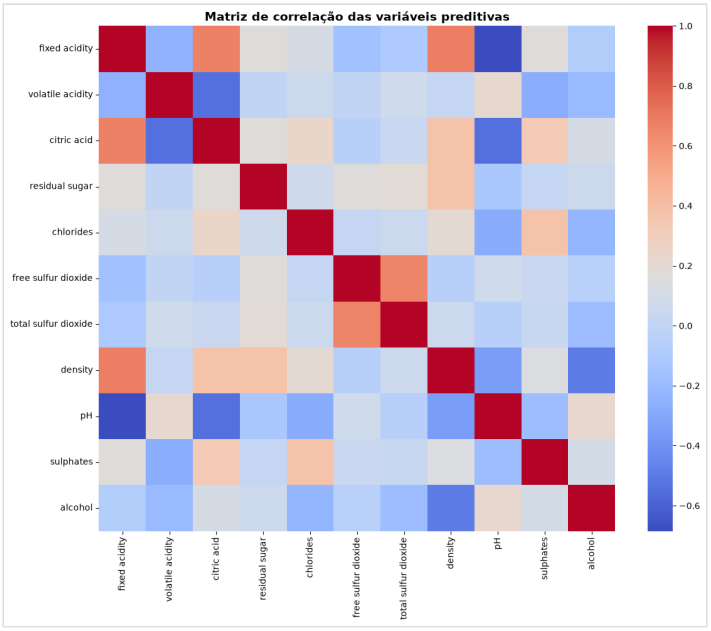
Análise exploratória — Gráfico 2

Em seguida, a distribuição da qualidade mostra como as classes se organizam no conjunto e justifica por que a fronteira de decisão não é trivial.



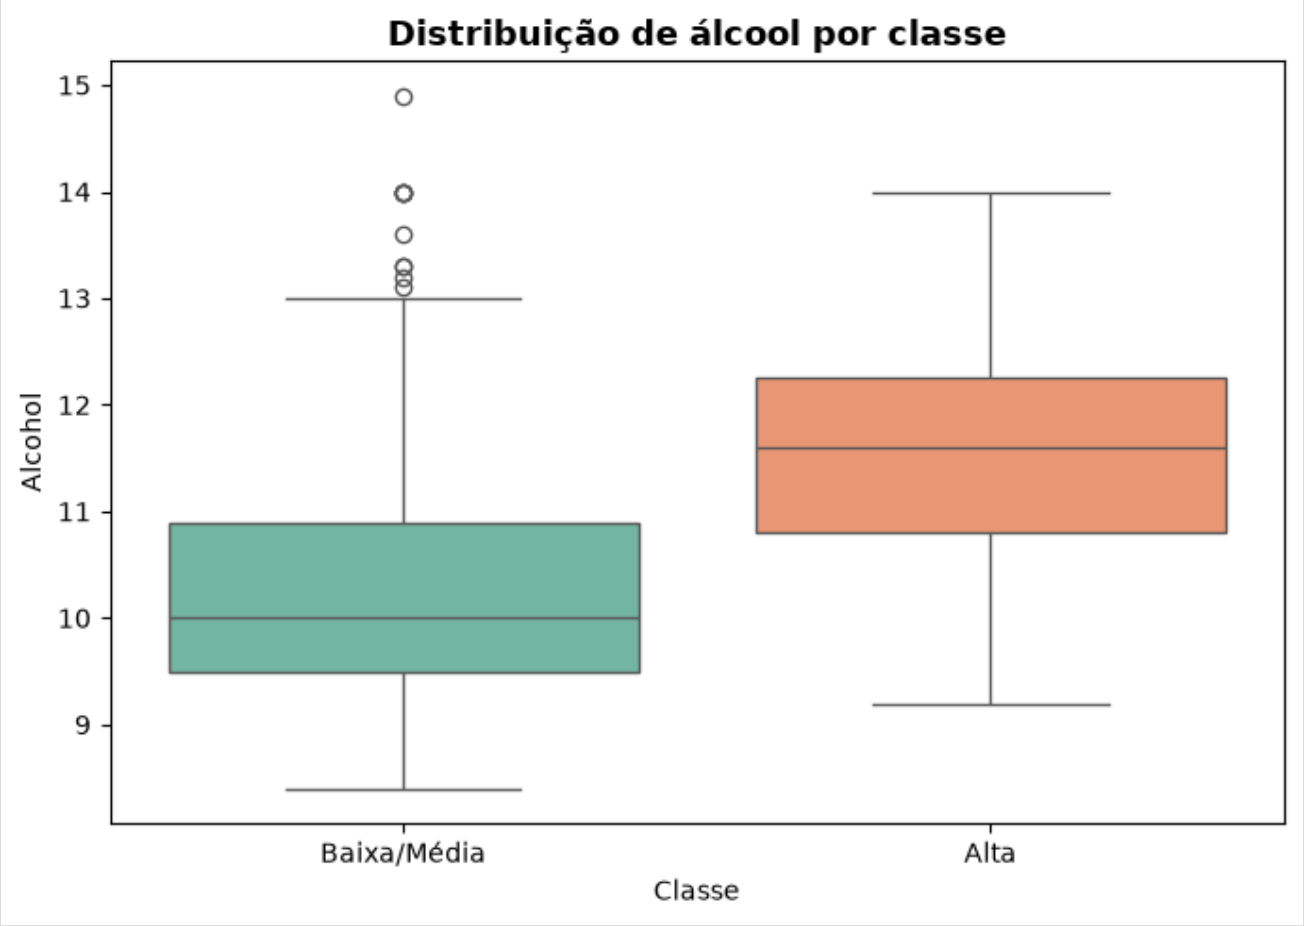
Análise exploratória — Gráfico 3

A proporção entre classes reforça o contexto de desbalanceamento observado na etapa inicial.



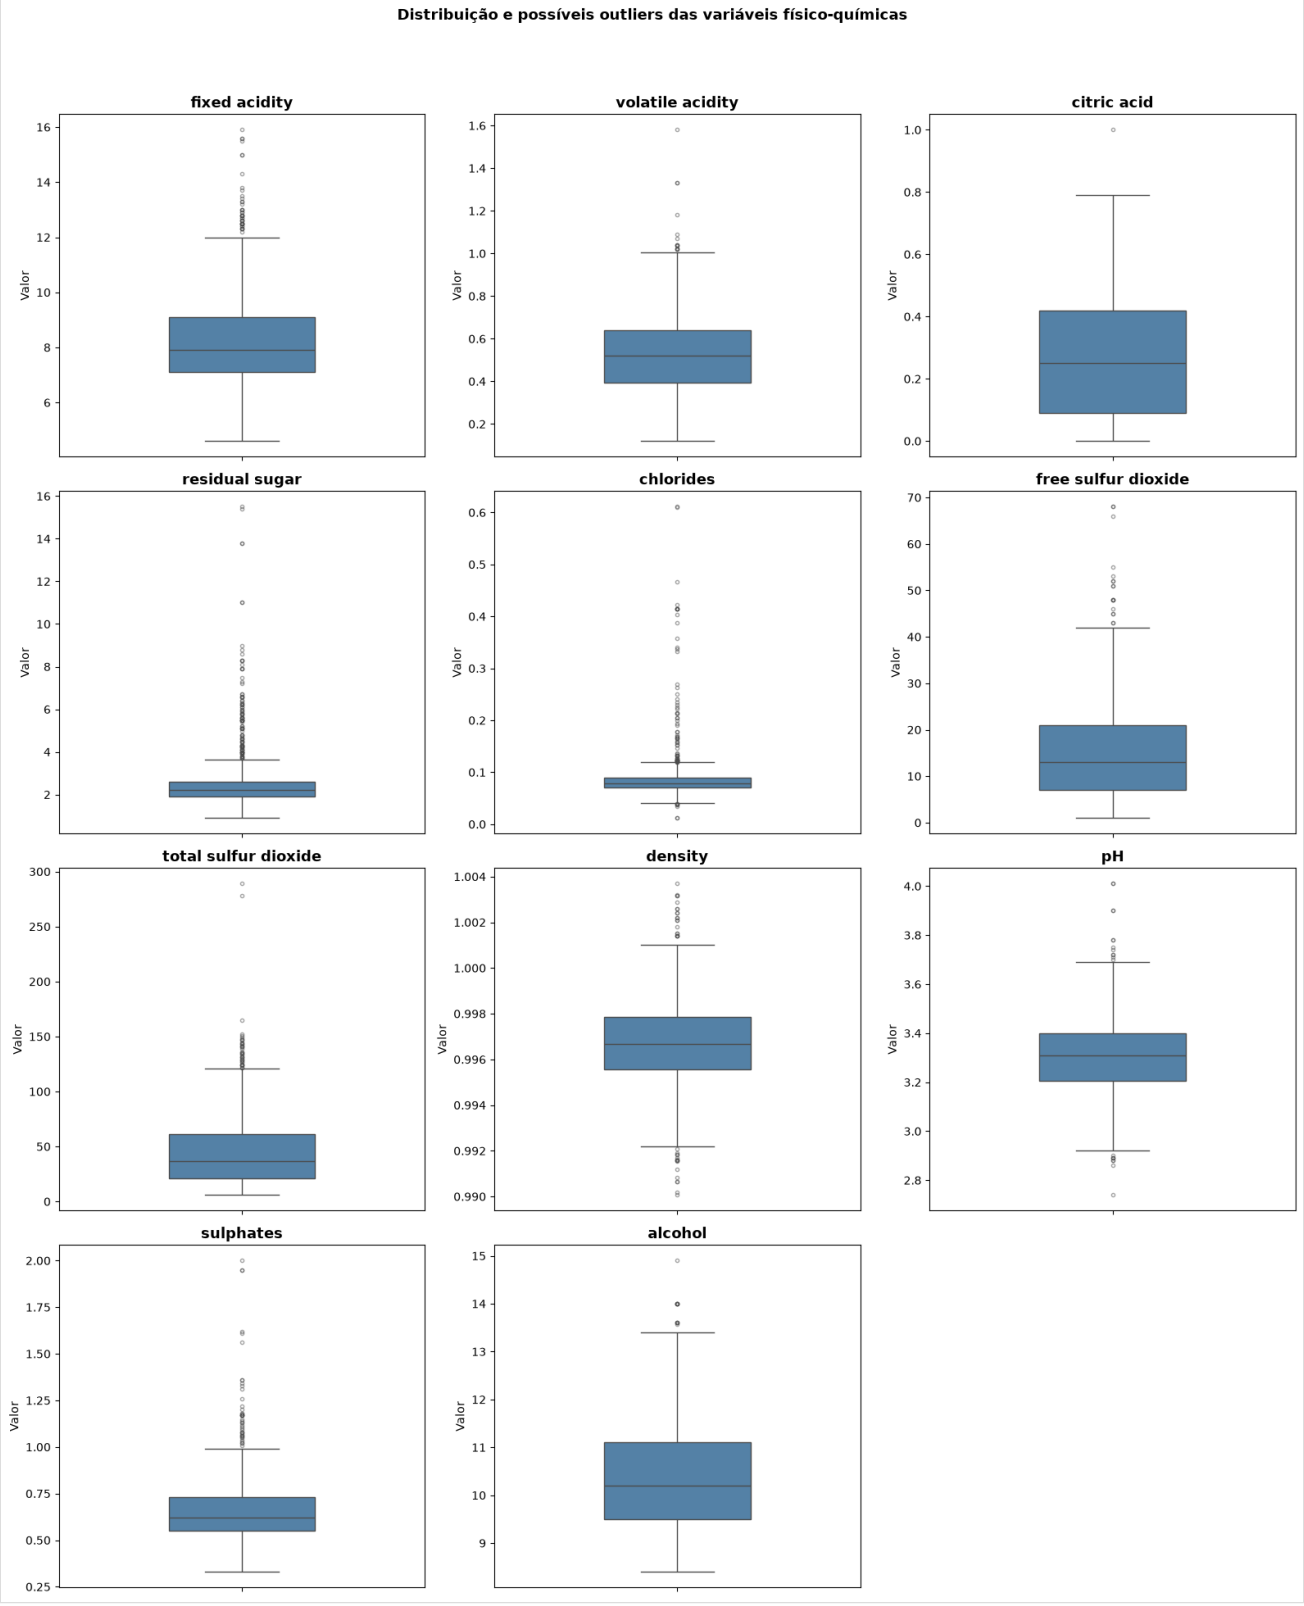
Análise exploratória — Gráfico 4

A matriz de correlação mostra que a qualidade não responde a um único fator isolado, mas à combinação entre variáveis físico-químicas.



Análise exploratória — Gráfico 5

A separação do teor alcoólico por classe fortalece a leitura de que algumas variáveis carregam sinal preditivo relevante.

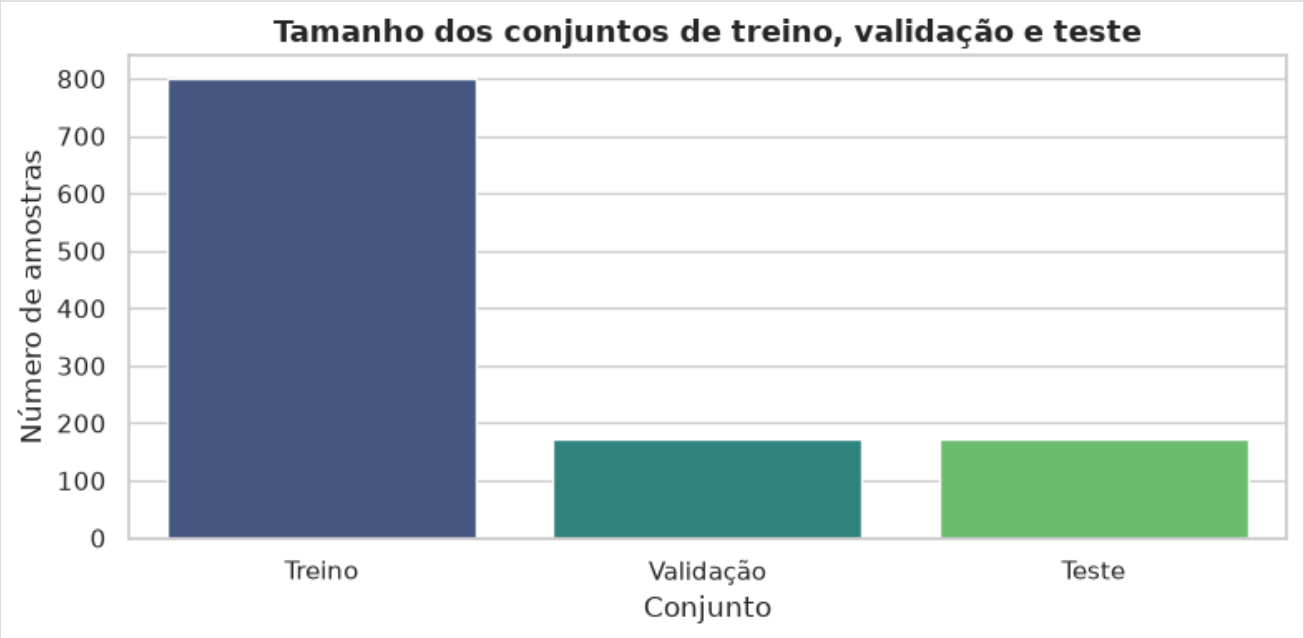


Análise exploratória — Gráfico 6

Por fim, os boxplots com IQR revelam caudas e extremos importantes, orientando a etapa de validação de outliers sem alterar prematuramente o conjunto.

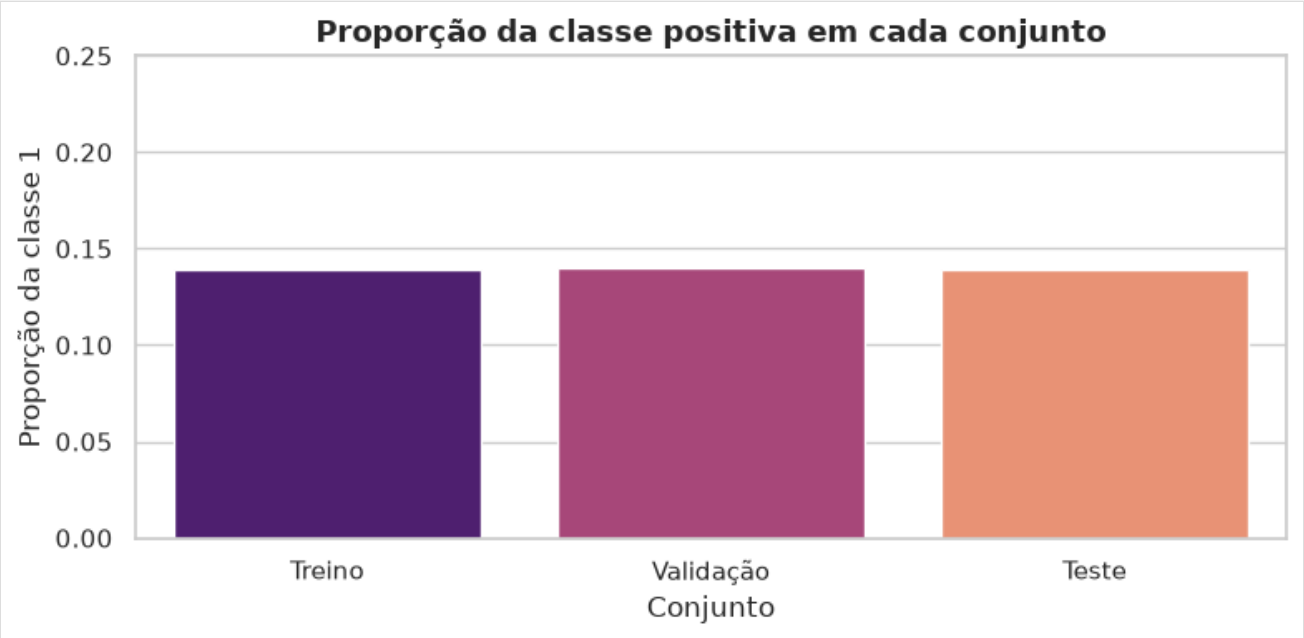
4.2 Evidências complementares da trilha analítica

Com a base exploratória consolidada, a sequência abaixo mostra como cada etapa complementar sustentou a recomendação final, preservando separação entre treino, validação e teste.



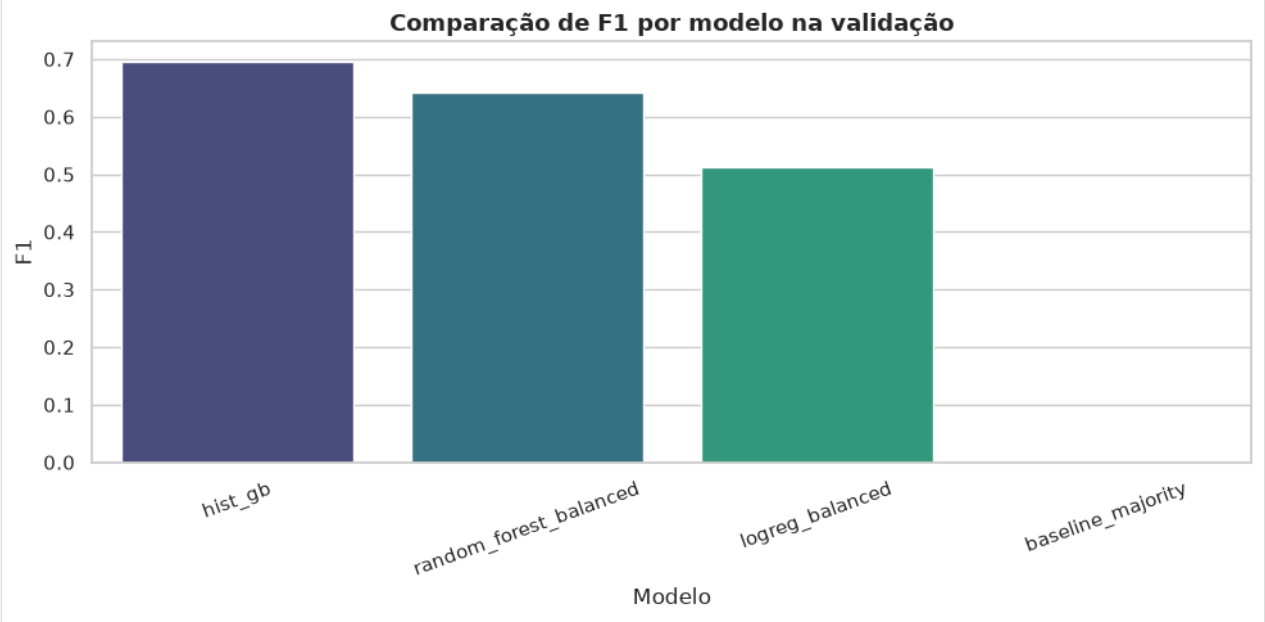
Modelagem, comparação e decisão final — Gráfico 1

A divisão estratificada entre treino e validação preserva a proporção da classe alvo e reduz risco de vazamento de informação.



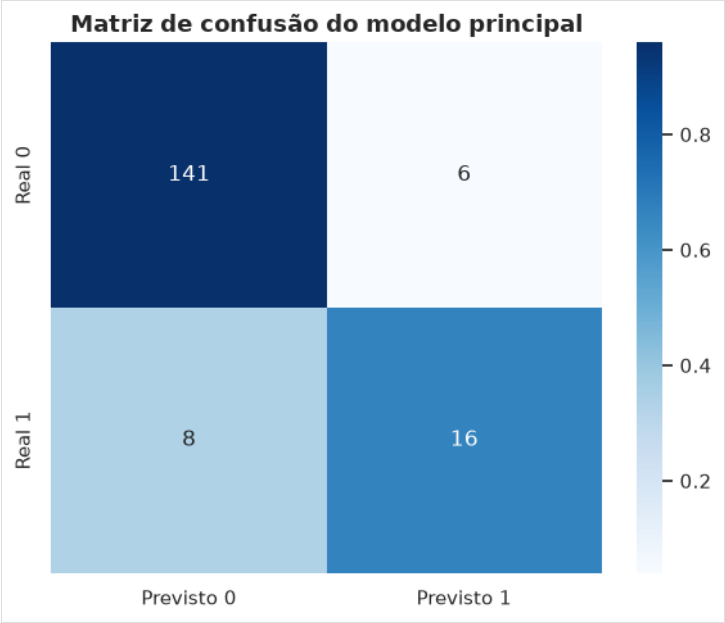
Modelagem, comparação e decisão final — Gráfico 2

A comparação entre modelos mostra que a acurácia isolada não é suficiente quando a classe positiva é minoritária.



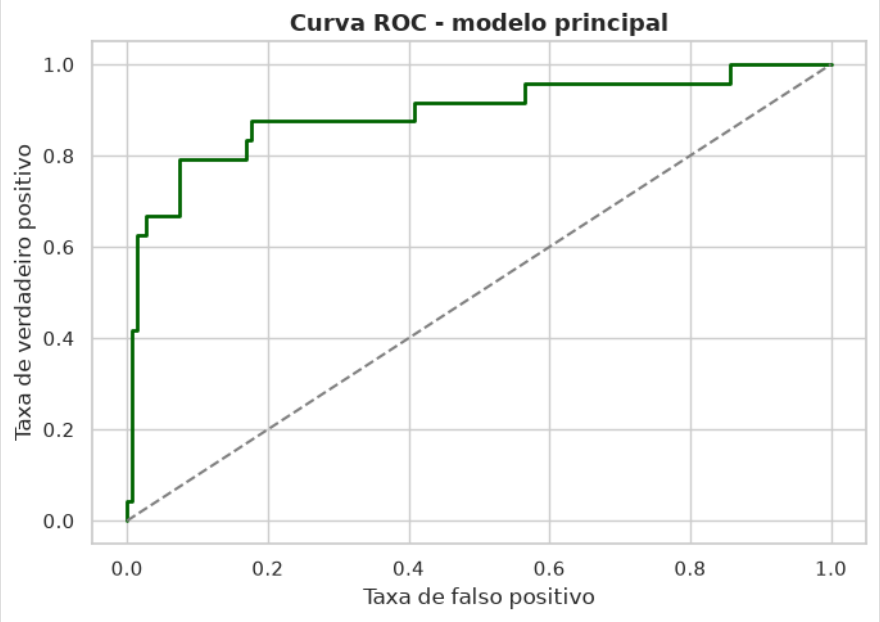
Modelagem, comparação e decisão final — Gráfico 3

O equilíbrio entre recall e precision é central para a decisão, especialmente na classe relevante do problema.



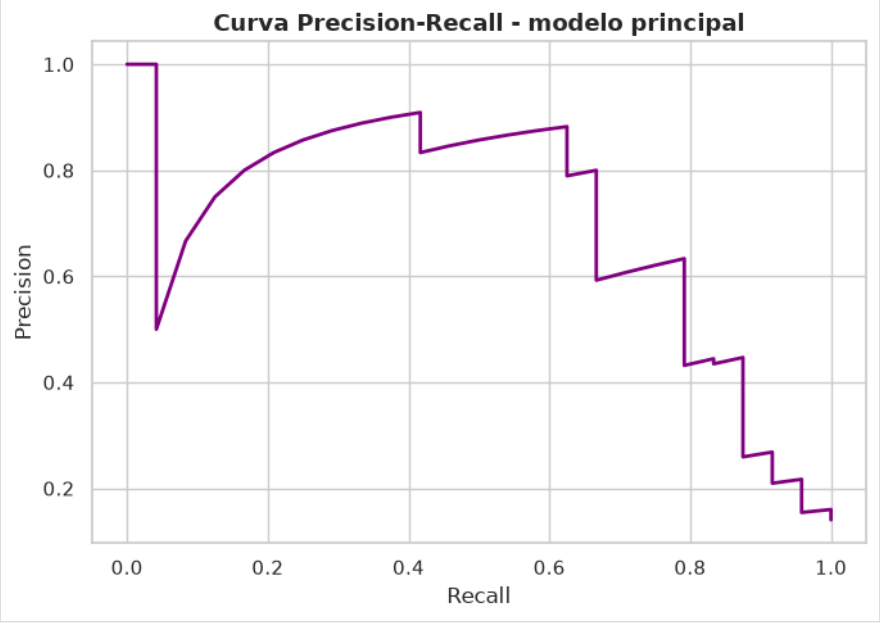
Modelagem, comparação e decisão final — Gráfico 4

A validação interna reforça que o desempenho deve ser medido em conjunto, e não por uma única métrica isolada.



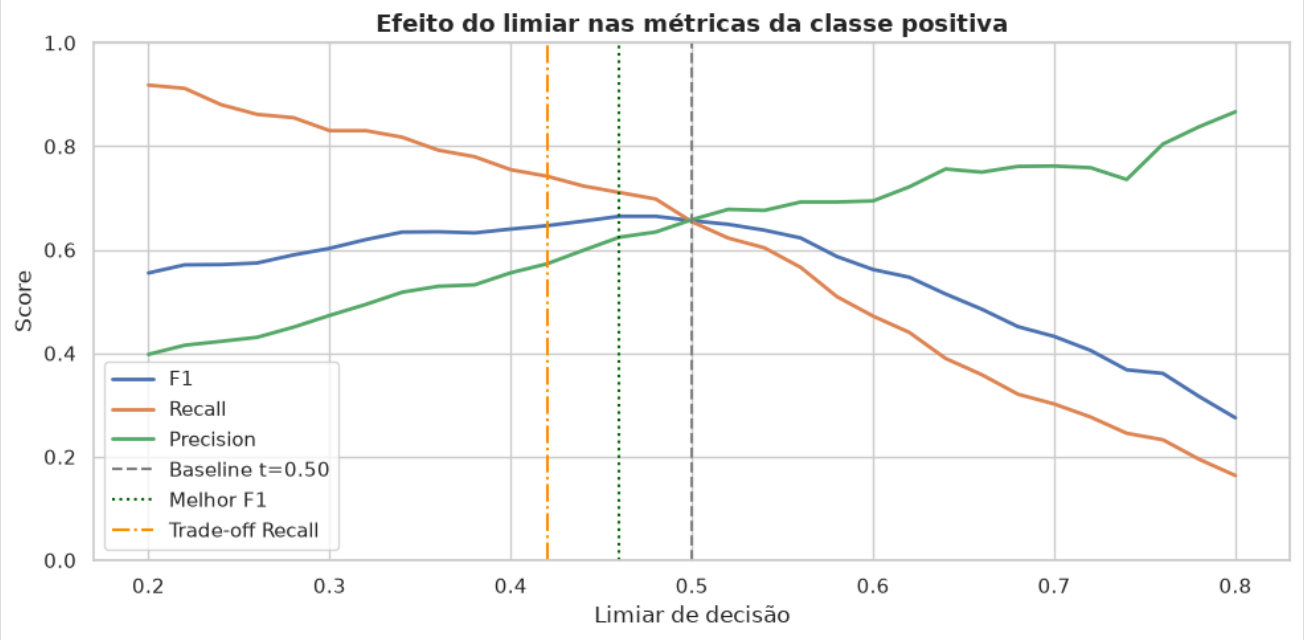
Modelagem, comparação e decisão final — Gráfico 5

Os resultados apontam que o Random Forest e o HistGradientBoosting são os modelos mais competitivos, com diferenças definidas pelo trade-off de negócio.



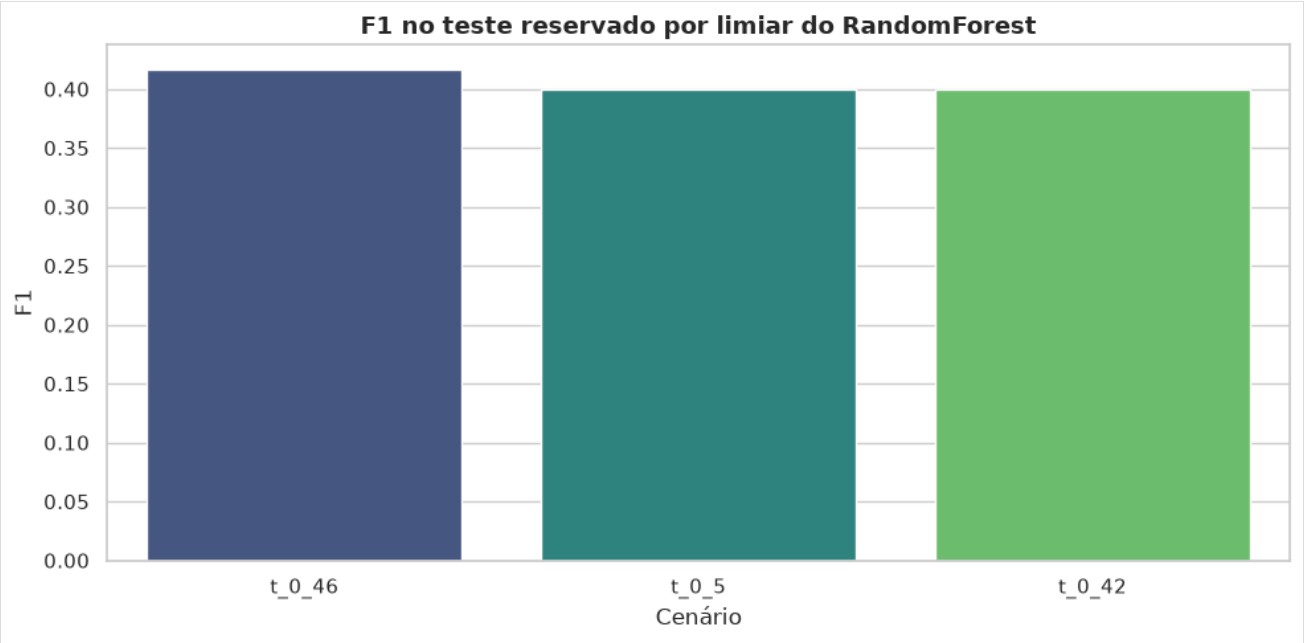
Modelagem, comparação e decisão final — Gráfico 6

A comparação final sustenta a decisão por equilíbrio geral e pela avaliação no conjunto de teste reservado.



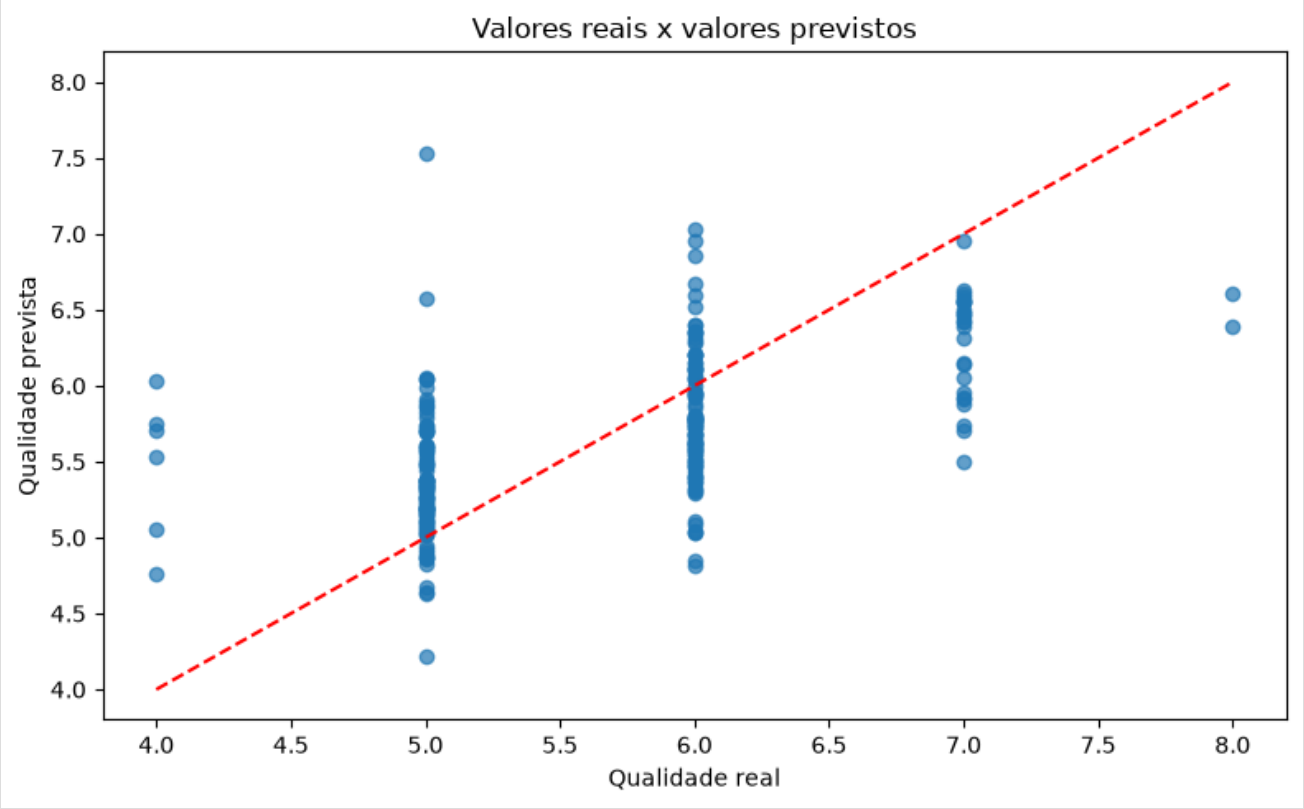
Modelagem, comparação e decisão final — Gráfico 7

Este gráfico reforça a conclusão analítica do notebook e sustenta a interpretação do modelo.



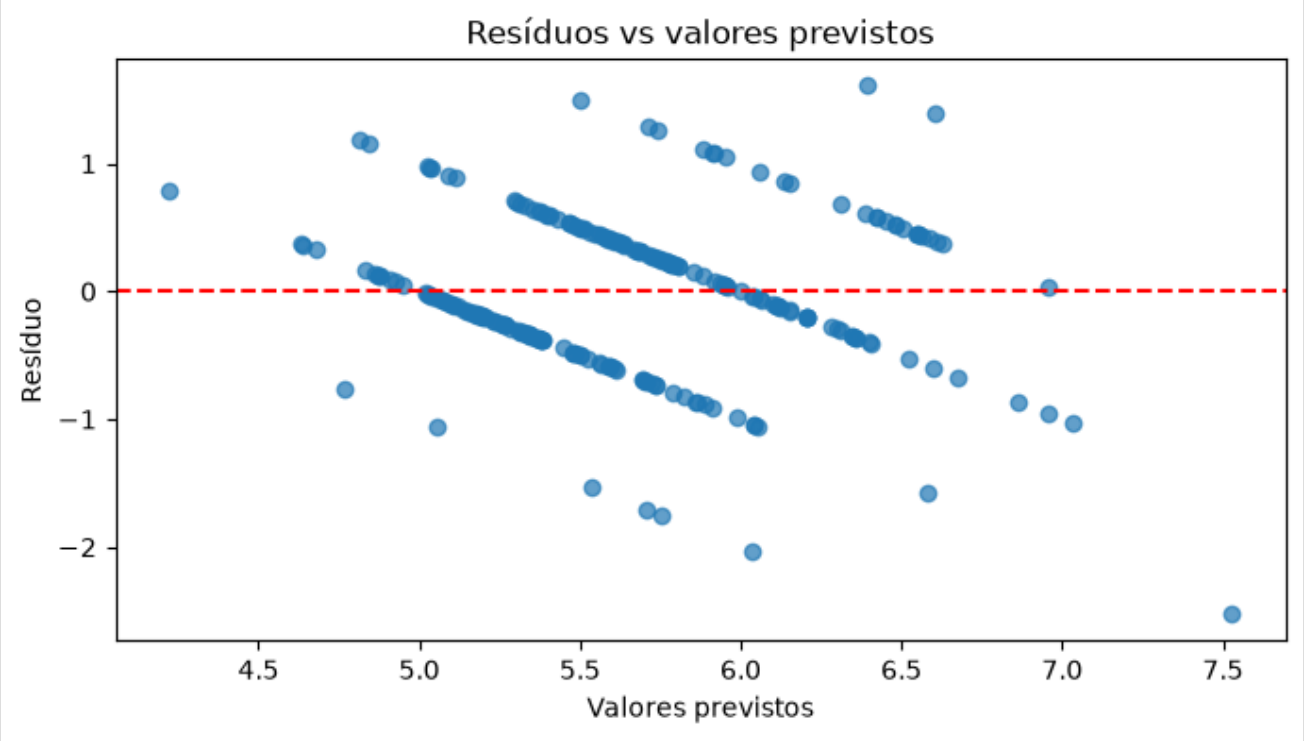
Modelagem, comparação e decisão final — Gráfico 8

Este gráfico reforça a conclusão analítica do notebook e sustenta a interpretação do modelo.



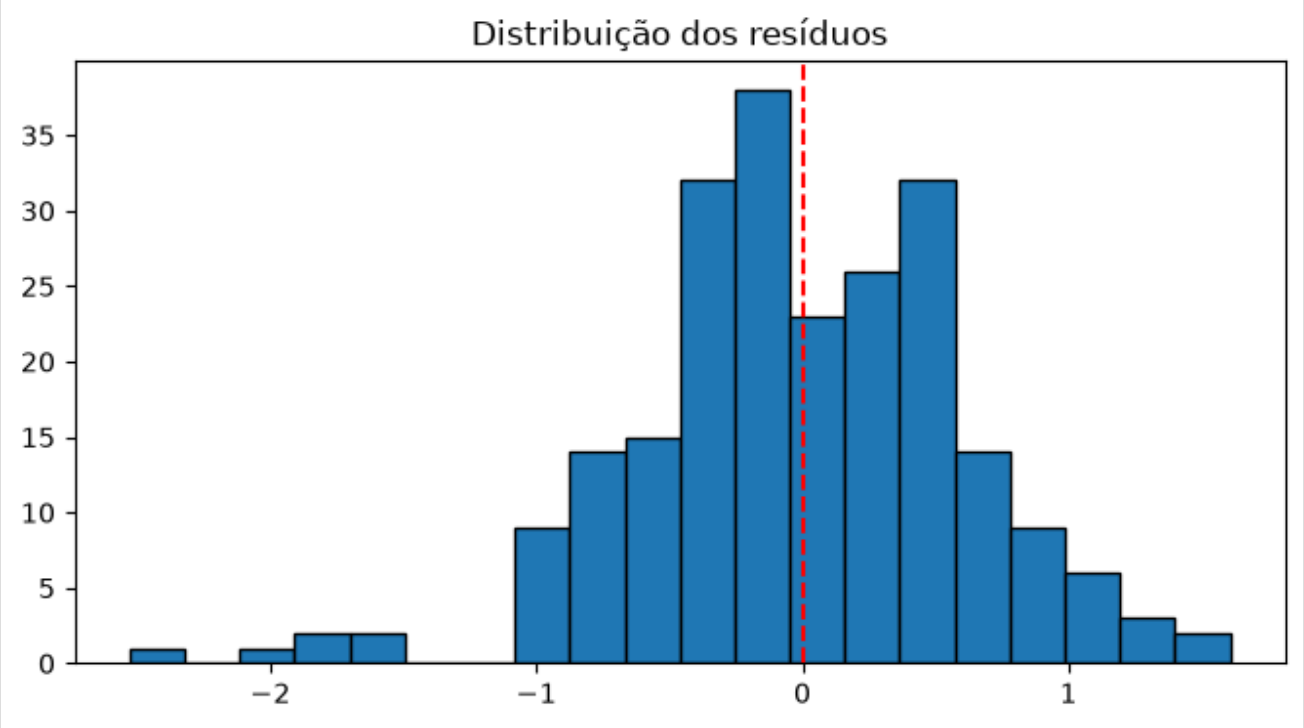
Regressão linear — Gráfico 1

A regressão linear não captura de forma suficiente a relação entre variáveis e a qualidade do vinho.



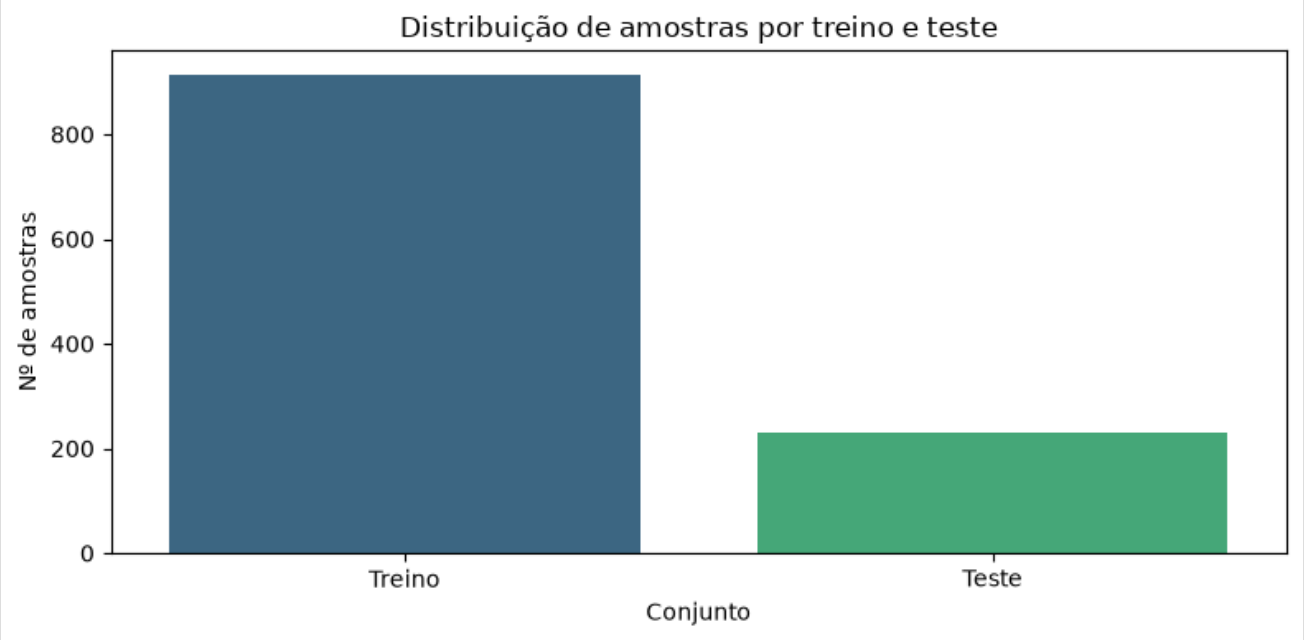
Regressão linear — Gráfico 2

Os resíduos sugerem que o padrão é mais complexo e exige modelos não lineares para uma melhor separação da classe alvo.



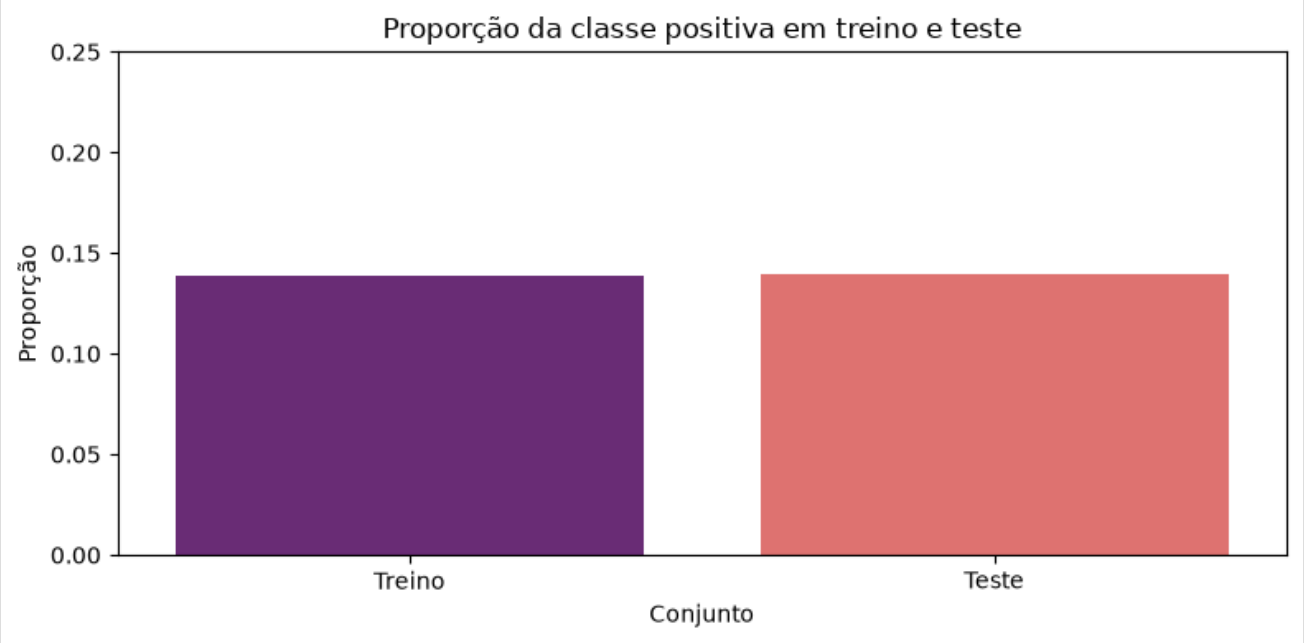
Regressão linear — Gráfico 3

Esse diagnóstico confirma que a regressão linear funciona como referência, mas não como solução principal do problema.



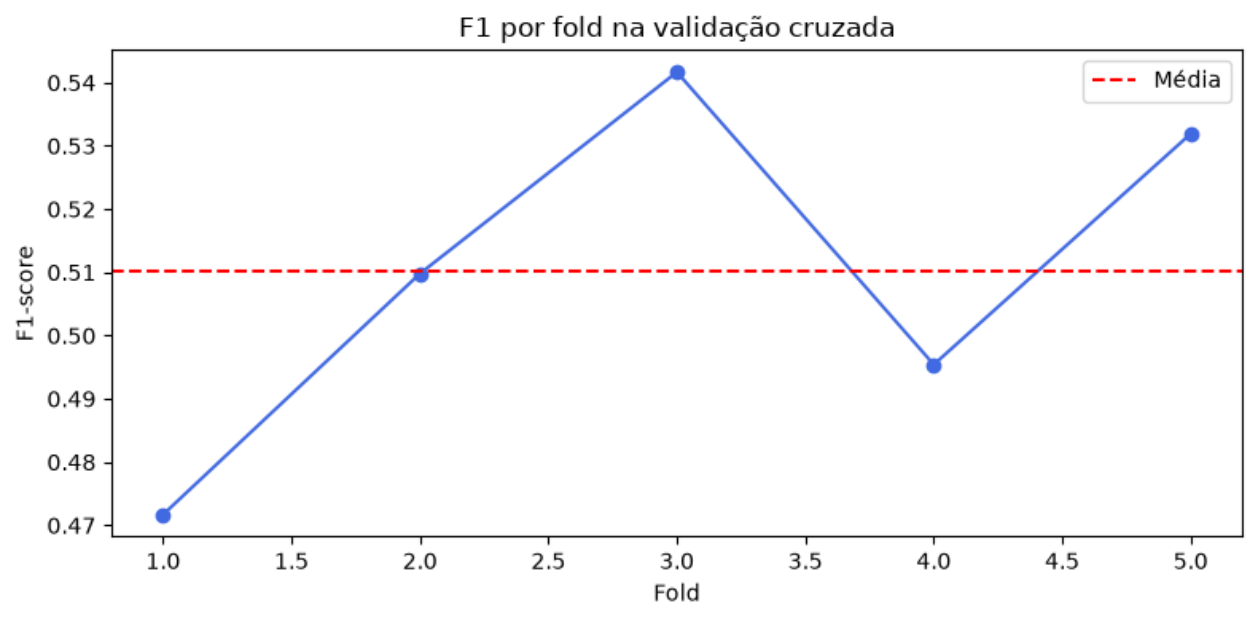
Train/Test Split — Gráfico 1

A separação entre treino e teste preserva a capacidade de generalização e evita decisões baseadas em overfitting.



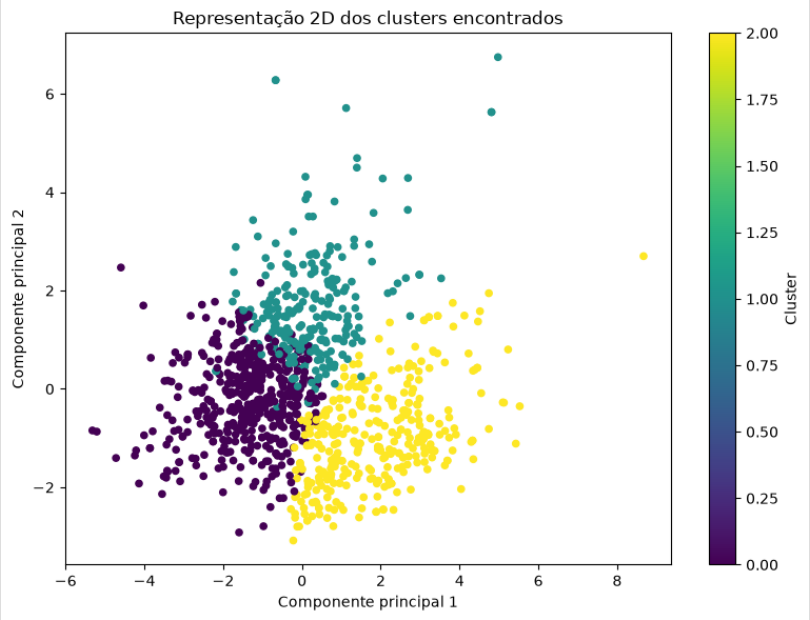
Train/Test Split — Gráfico 2

A comparação em dados não vistos é a base mais confiável para a recomendação final.



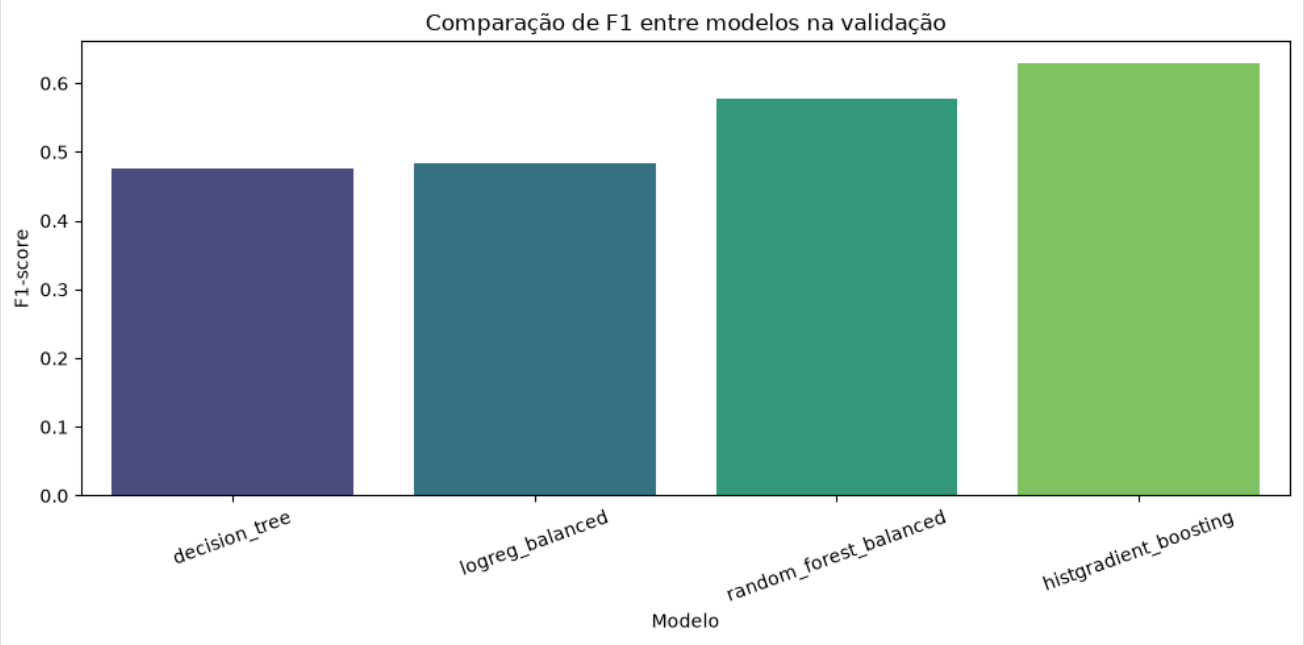
Validação cruzada — Gráfico 1

A validação cruzada mostra que o desempenho se mantém estável em diferentes subconjuntos do dado, reduzindo o impacto de uma divisão favorável.



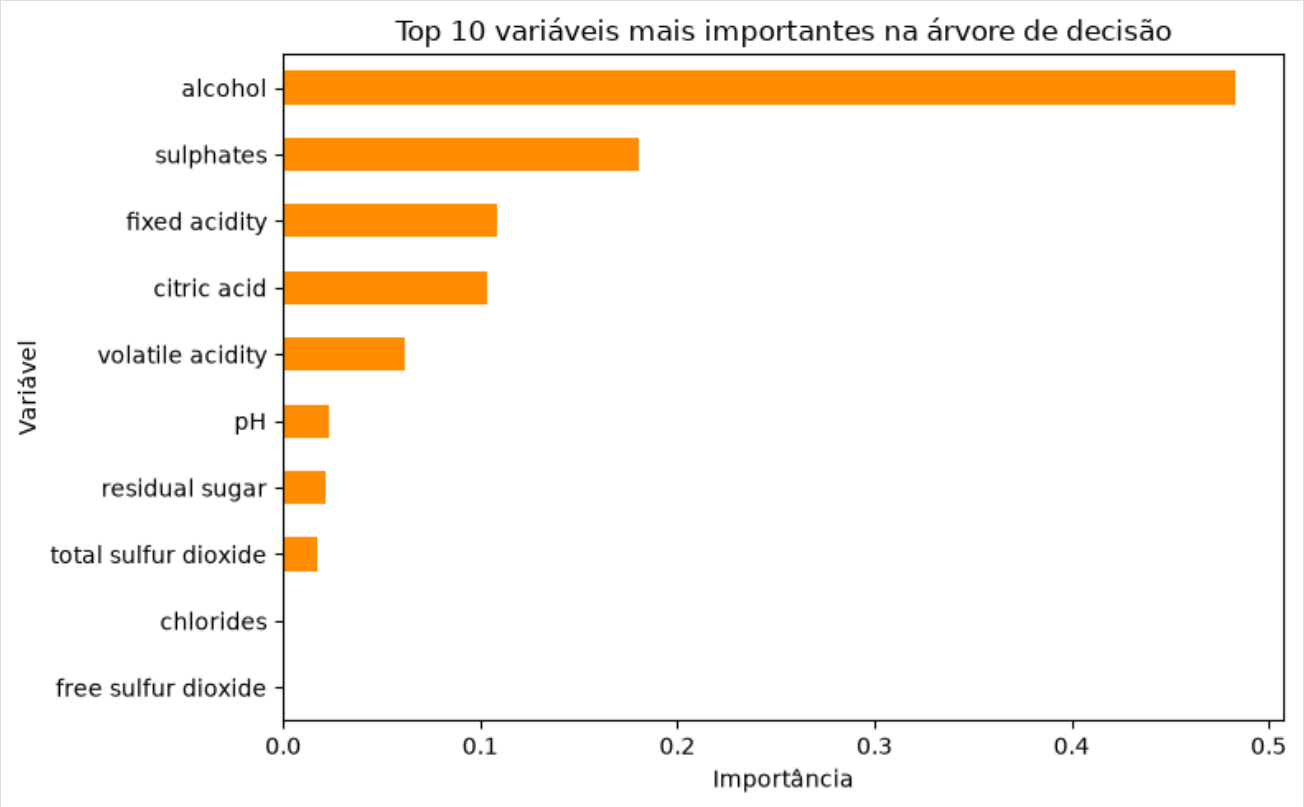
Clusterização — Gráfico 1

A clusterização não explica diretamente a classe alvo e, por isso, não substitui a modelagem supervisionada.



Árvore de decisão — Gráfico 1

A árvore aumenta a interpretabilidade do modelo e ajuda a explicar regras de decisão.



Árvore de decisão — Gráfico 2

Mesmo com boa explicabilidade, ela não supera a melhor performance global dos modelos de ensemble.

5. Resultados de validação

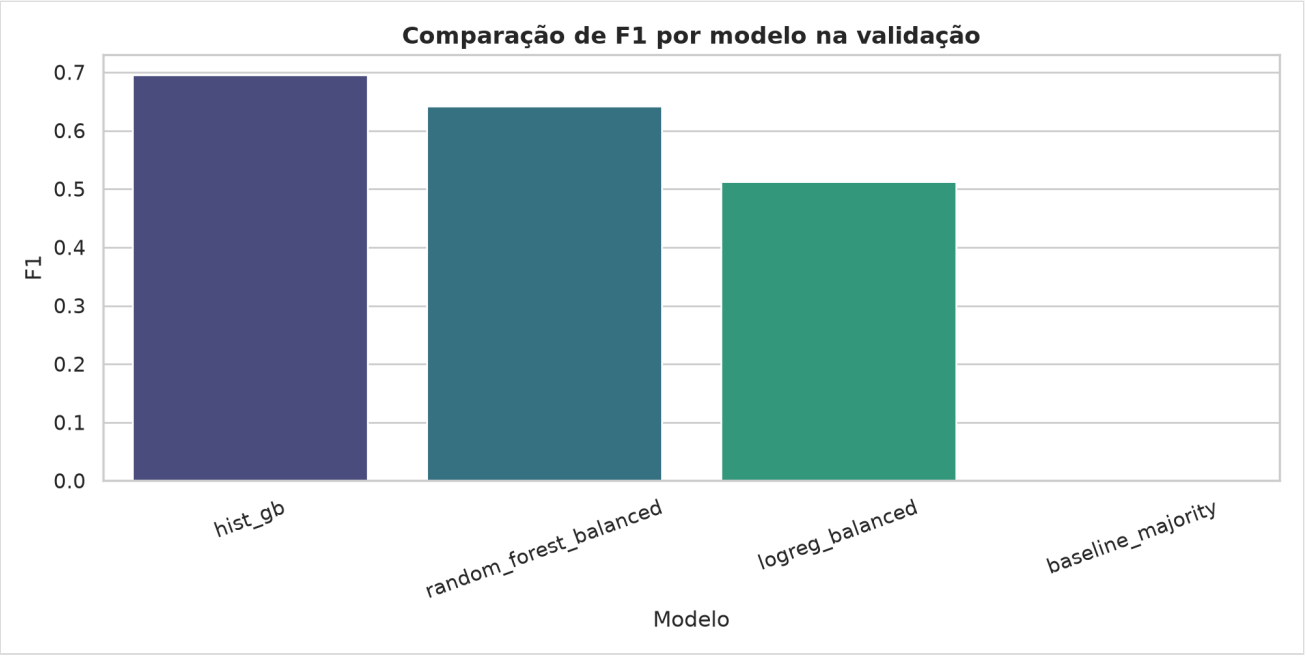


Figura 4 — Comparação de F1 por modelo na validação.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Logistic Regression (balanced)	0.8035	0.4058	0.8750	0.5545	0.8669	0.4762
Random Forest (balanced)	0.9039	0.6562	0.6562	0.6562	0.9408	0.7578
HistGradientBoosting	0.9170	0.7600	0.5938	0.6667	0.9261	0.6688

A performance de validação mostra que:

- o **HistGradientBoosting** apresentou o melhor F1 (0,6667) e precision (0,7600) na etapa de validação;
- o **Random Forest balanceado** ficou muito próximo, com F1 de 0,6563 e ROC-AUC de 0,9408;
- a **Logistic Regression** teve maior recall, mas pior equilíbrio geral e pior precision;
- o **baseline majoritário** não é competitivo e serve apenas como referência.

Ajuste de limiar

Após escolher o modelo baseline, foi feito ajuste de limiar usando apenas validação cruzada estratificada. O objetivo foi deixar claro o trade-off entre recall e precision da classe positiva.

Cenário	Limiar	F1	Recall	Precision
Baseline t=0.50	0.5000	0.6562	0.6541	0.6582
Melhor F1	0.4600	0.6647	0.7107	0.6243
Trade-off de recall	0.4200	0.6466	0.7421	0.5728

A recomendação operacional padrão é **limiar 0.46**, por melhor F1 médio na validação. Se a prioridade for aumentar sensibilidade da classe positiva, o cenário em **0.42** aumenta recall, com queda de precision.

Checagem final no teste reservado

A comparação final confirmou que, para o Random Forest, o limiar 0.46 melhorou F1 e recall em relação ao limiar 0.50, com pequena queda de acurácia.

Limiar	Acurácia	Precision	Recall	F1
t=0.50	0.8430	0.4286	0.3750	0.4000
t=0.46	0.8372	0.4167	0.4167	0.4167
t=0.42	0.8256	0.3846	0.4167	0.4000

6. Avaliação final no teste reservado

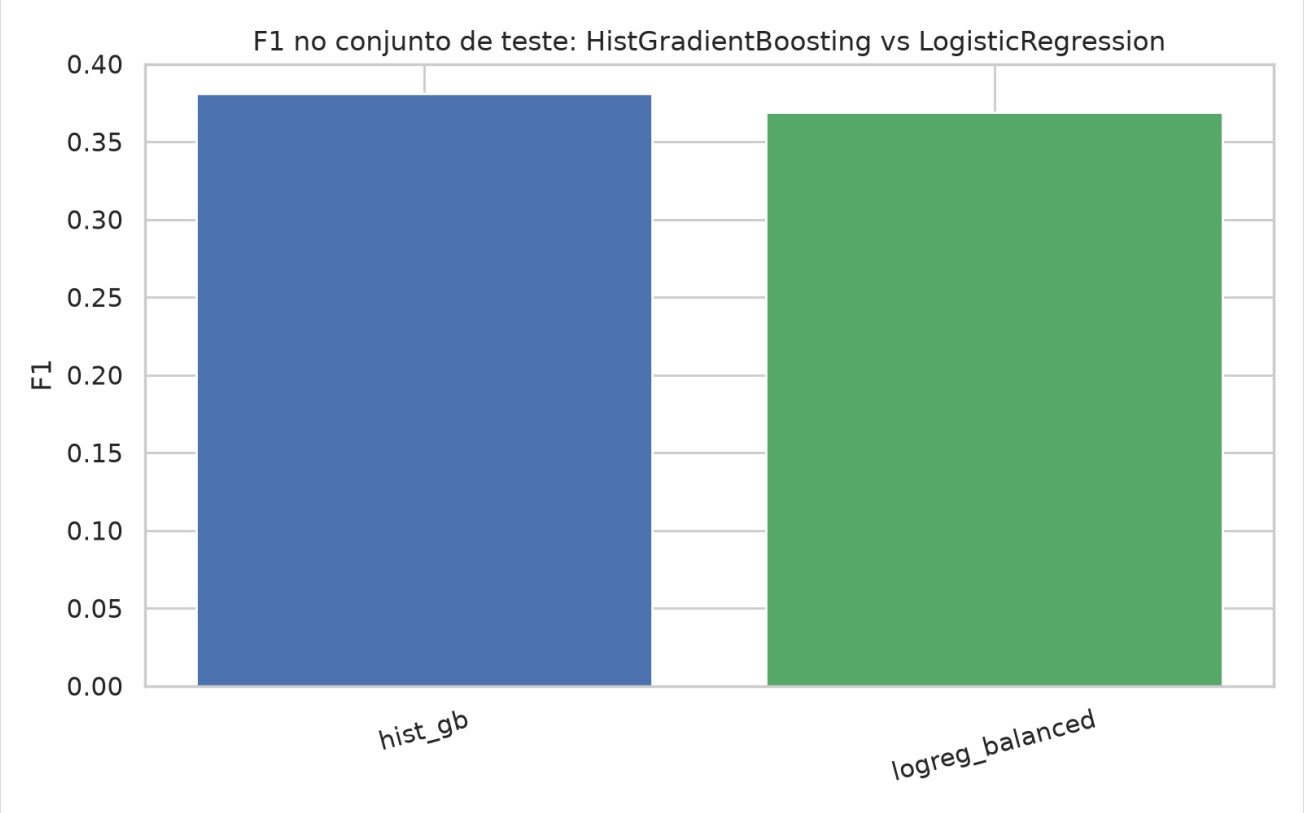


Figura 5 — Comparação final no conjunto de teste.

O conjunto de teste reservado foi a etapa decisiva. O Random Forest balanceado ficou como principal por manter melhor equilíbrio entre F1 e recall da classe positiva. O HistGradientBoosting manteve boa precision, mas com recall menor.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Random Forest (balanced)	0.8996	0.6364	0.6562	0.6462	0.8910	0.6719
HistGradientBoosting	0.9039	0.7273	0.5000	0.5926	0.8826	0.6678

Em termos práticos, o **Random Forest** teve melhor equilíbrio para este problema desbalanceado. O **HistGradientBoosting** segue como alternativa quando a prioridade for precision.

7. Conclusão final

A recomendação final do projeto é:

- **Random Forest balanced** como modelo principal;
- **limiar 0.46** como configuração padrão de classificação;
- **limiar 0.42** como alternativa quando a meta for maior recall;
- **HistGradientBoosting** como alternativa preferencial quando a organização prioriza precision;
- **regressão linear** e **clusterização** como diagnósticos e ferramentas complementares, mas não como solução principal;
- **árvore de decisão** como apoio interpretativo, não como substituta da melhor performance global.

Em síntese, a decisão foi guiada por evidência de validação e teste reservado. O projeto fecha com modelo definido e política de limiar clara para diferentes objetivos de negócio.

Relatório executado com base nos resultados finais do WineQT e nos notebooks gerados no projeto.