RELATÓRIO EXECUTIVO

DATA ANALYTICS — FIAP

WineQT — Classificação de qualidade de vinho

Julia Ayumi Suzuki
Larissa Nicoli Rodrigues
Matheus Silva de Jesus
Paulo Jean Alves da Silva

São Paulo — 2026

Sumário

Resumo executivo

Objetivos

Metodologia e evidência dos notebooks

Diagnóstico exploratório

Resultados de validação

Avaliação final no teste reservado

Conclusão final

1. Resumo executivo

Este projeto classificou vinhos em alta qualidade e baixa/média qualidade com base em variáveis físico-químicas. A regra usada foi **quality ≥ 7** para classe positiva e **quality < 7** para classe negativa. Como a classe positiva é minoritária, a decisão não foi baseada apenas em acurácia.

O modelo recomendado é o **Random Forest com balanceamento de classes**. Depois do ajuste de limiar, o melhor equilíbrio no teste reservado ficou em **threshold 0.46**, com ganho de F1 e recall da classe positiva em relação ao threshold padrão de 0.50. O critério técnico principal foi **F1, recall, precision, ROC-AUC e Average Precision**.

0.6647	0.4167	0.4167
F1 do Random Forest com limiar 0.46 (CV)	F1 do Random Forest com limiar 0.46 (teste)	Recall do Random Forest com limiar 0.46 (teste)

2. Objetivos

Objetivo geral

Construir e validar um modelo preditivo capaz de identificar vinhos de alta qualidade a partir de atributos físico-químicos, com rigor metodológico e métricas adequadas ao desbalanceamento de classes.

Objetivos específicos

- confirmar a definição da variável alvo binária;
- validar a separação entre treino, validação e teste sem leakage;
- comparar modelos com foco na classe minoritária;
- interpretar resultados dos notebooks de regressão, split, validação cruzada, clusterização e árvore de decisão;
- definir a recomendação final com base em evidência e não em suposição.

3. Metodologia e evidência dos notebooks

Objetivo da análise

A sequência analítica foi organizada para: validar a classe alvo, comparar modelos de forma justa e decidir com evidência de validação. Como o problema é desbalanceado, o foco foi a classe positiva.

Evidência dos notebooks

A análise exploratória mostrou que a classe de alta qualidade é minoritária (cerca de 13,9%). Por isso, F1, recall e ROC-AUC foram mais importantes do que acurácia isolada. A variável álcool mostrou diferença entre classes, e a correlação indicou que a qualidade depende da combinação de variáveis.

A etapa de outliers, com boxplots e critério de IQR, mostrou valores extremos em sulfur dioxide, chlorides e residual sugar. Esses pontos não foram removidos automaticamente no EDA para evitar perda de sinal da classe positiva.

Decisão metodológica

Os testes mostraram que regressão linear não era a melhor abordagem para este problema. A divisão estratificada e a validação cruzada deram estabilidade para a decisão. A árvore de decisão ajudou na explicabilidade, mas os ensembles tiveram melhor performance.

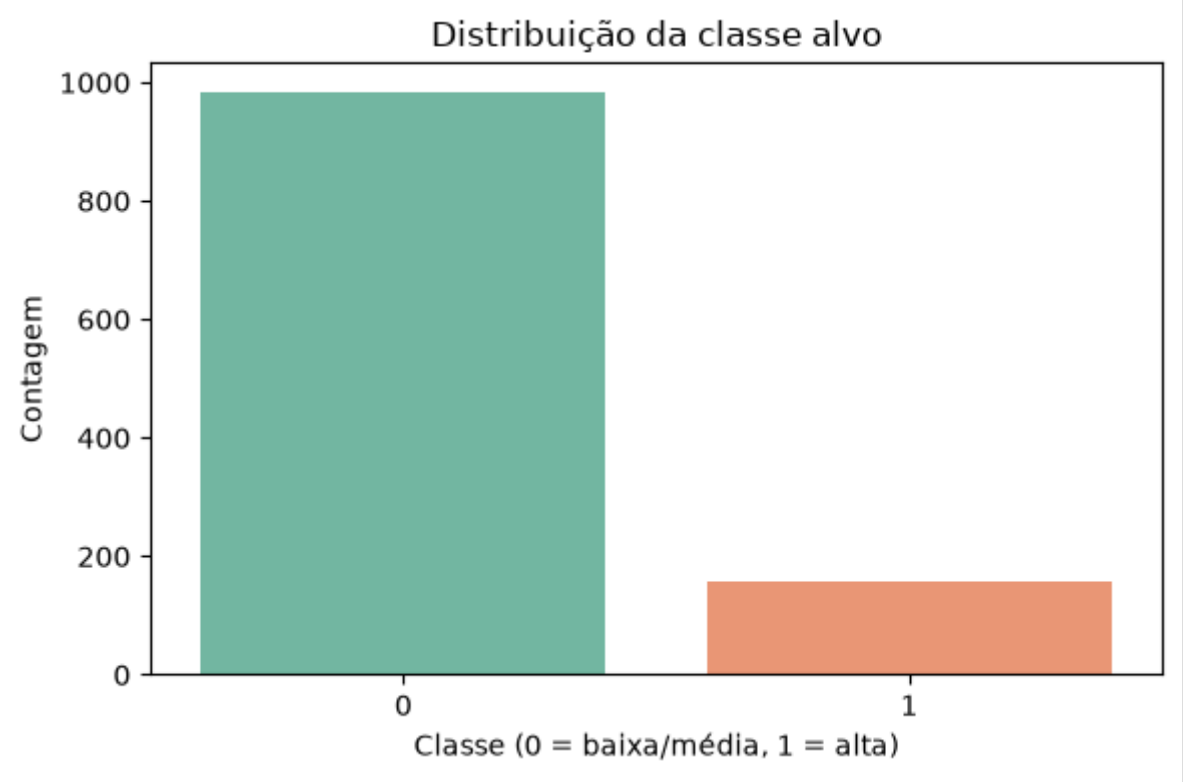
> A coluna **Id** foi excluída dos preditores, em conformidade com o enunciado, e o preprocessamento foi ajustado apenas sobre os dados de treino.

- **Regressão Linear**: não foi suficiente para explicar a qualidade de forma robusta; o padrão é mais complexo e exige modelos não lineares.
- **Train/Test Split**: preservou a proporção da classe alvo e reduziu o risco de vazamento entre etapas.
- **Validação Cruzada**: reforçou a estabilidade do desempenho e reduziu a chance de decisão baseada em uma divisão favorável.
- **Clusterização**: foi útil como diagnóstico, mas não como solução principal para a classificação alvo.
- **Árvore de decisão**: ajudou na interpretação das regras, mas não superou o melhor ensemble no teste final.

4. Diagnóstico exploratório

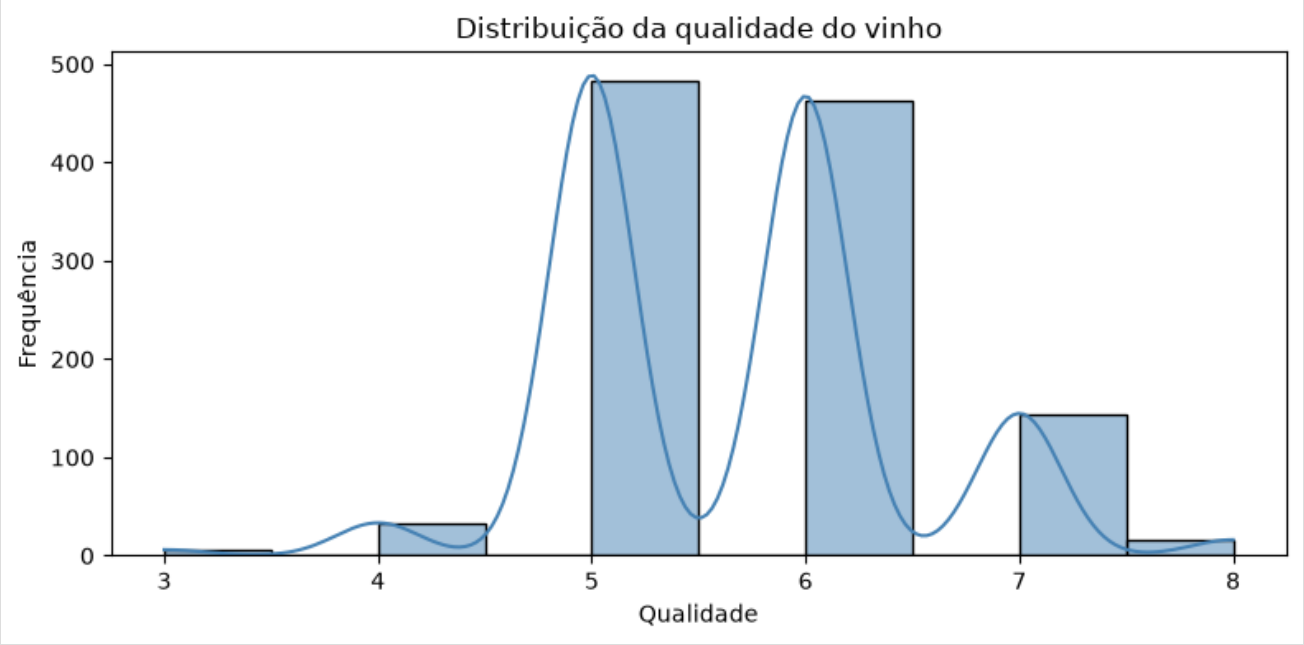
O conjunto de gráficos reforça que a decisão final foi tomada a partir de evidência analítica e não por hipótese. Abaixo, cada figura acompanha a interpretação direta do que foi observado e a relevância para a escolha do modelo.

Análise exploratória e entendimento do problema



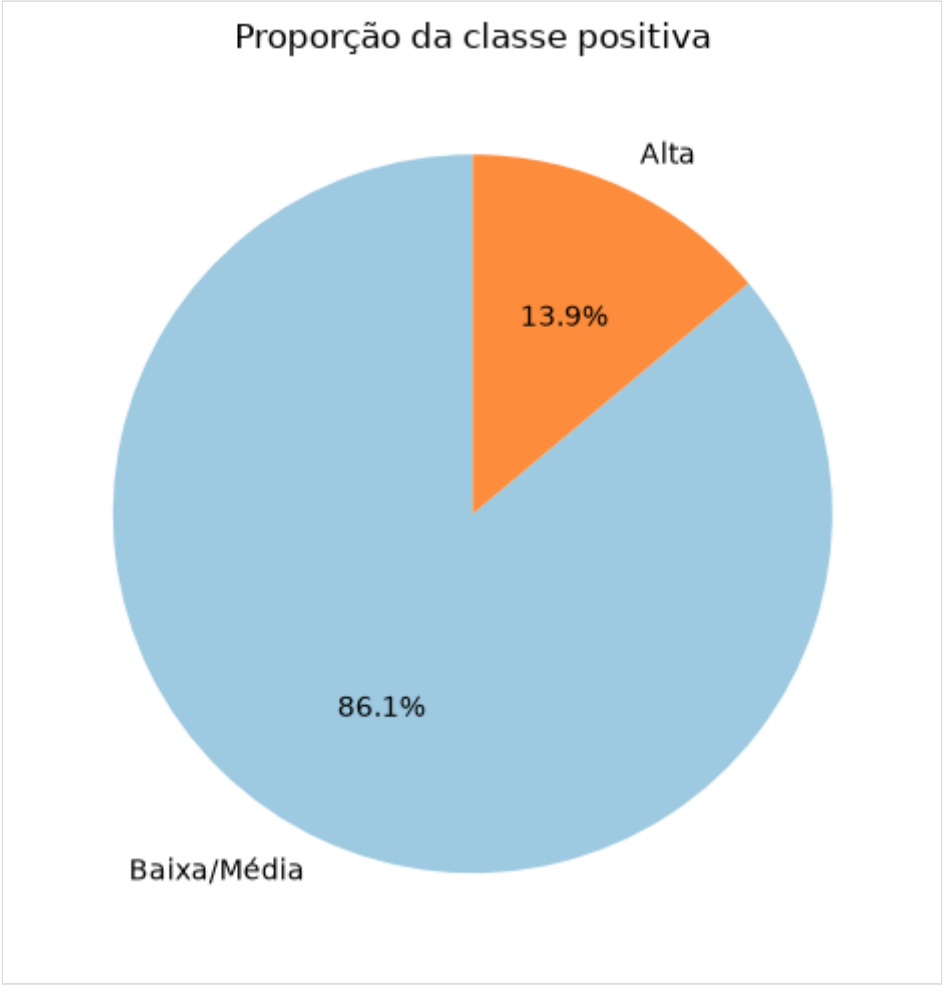
Análise exploratória e entendimento do problema — Gráfico 1

A distribuição da classe alvo mostra que a classe positiva é minoritária e exige avaliação por métricas orientadas à classe relevante.



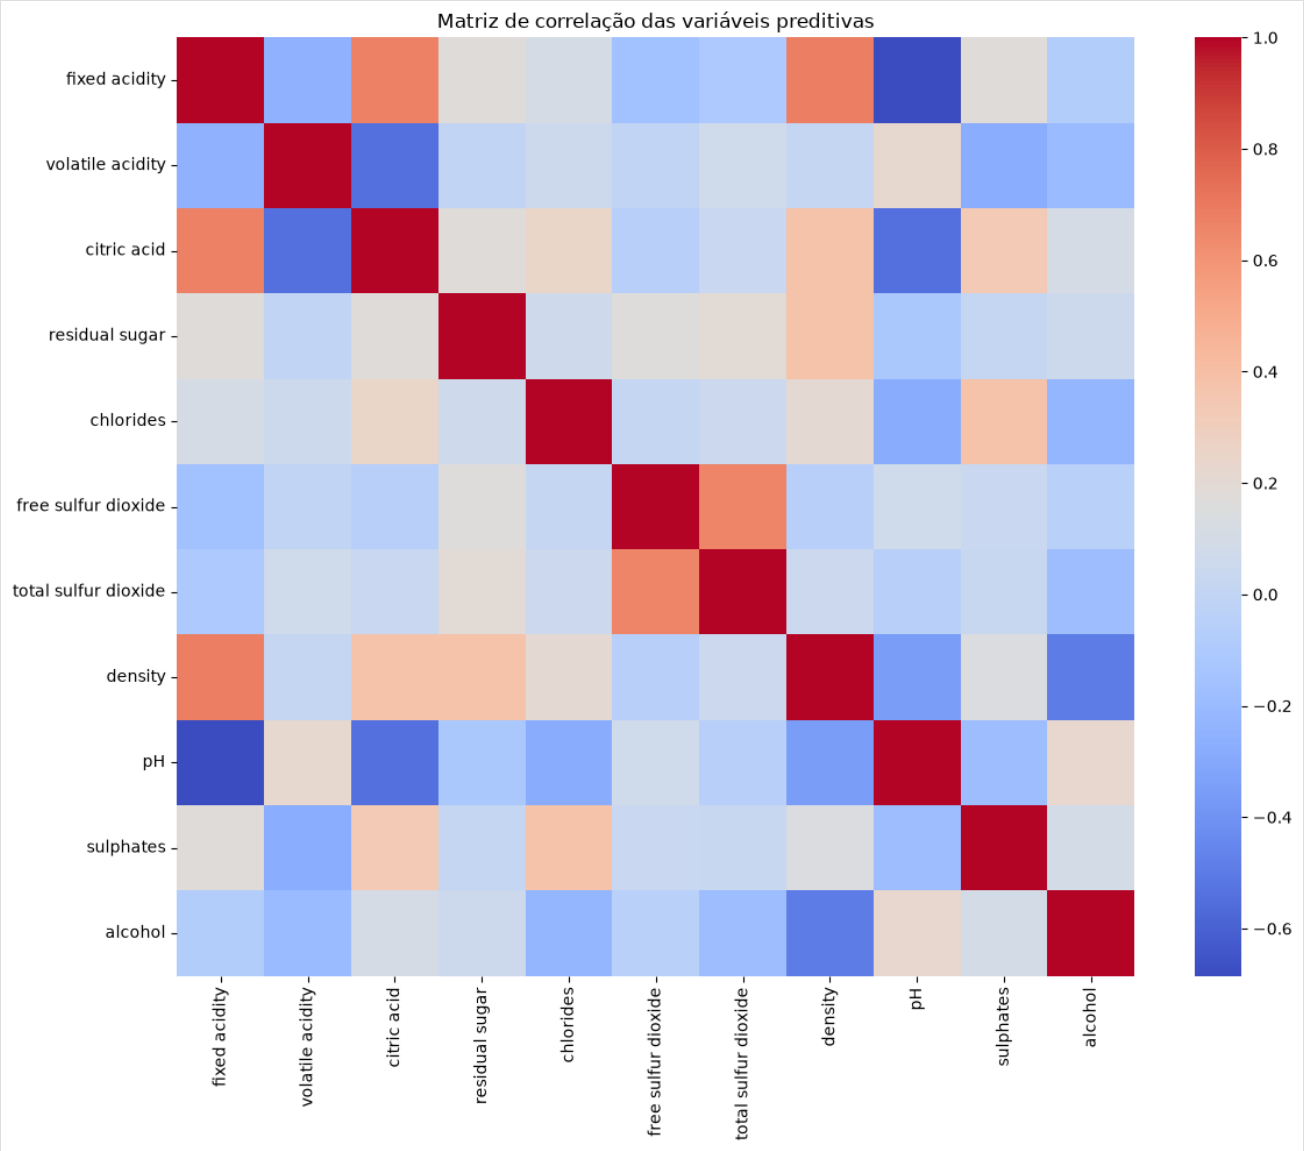
Análise exploratória e entendimento do problema — Gráfico 2

A correlação entre variáveis sugere que a qualidade depende de combinações de atributos, não de um único fator isolado.



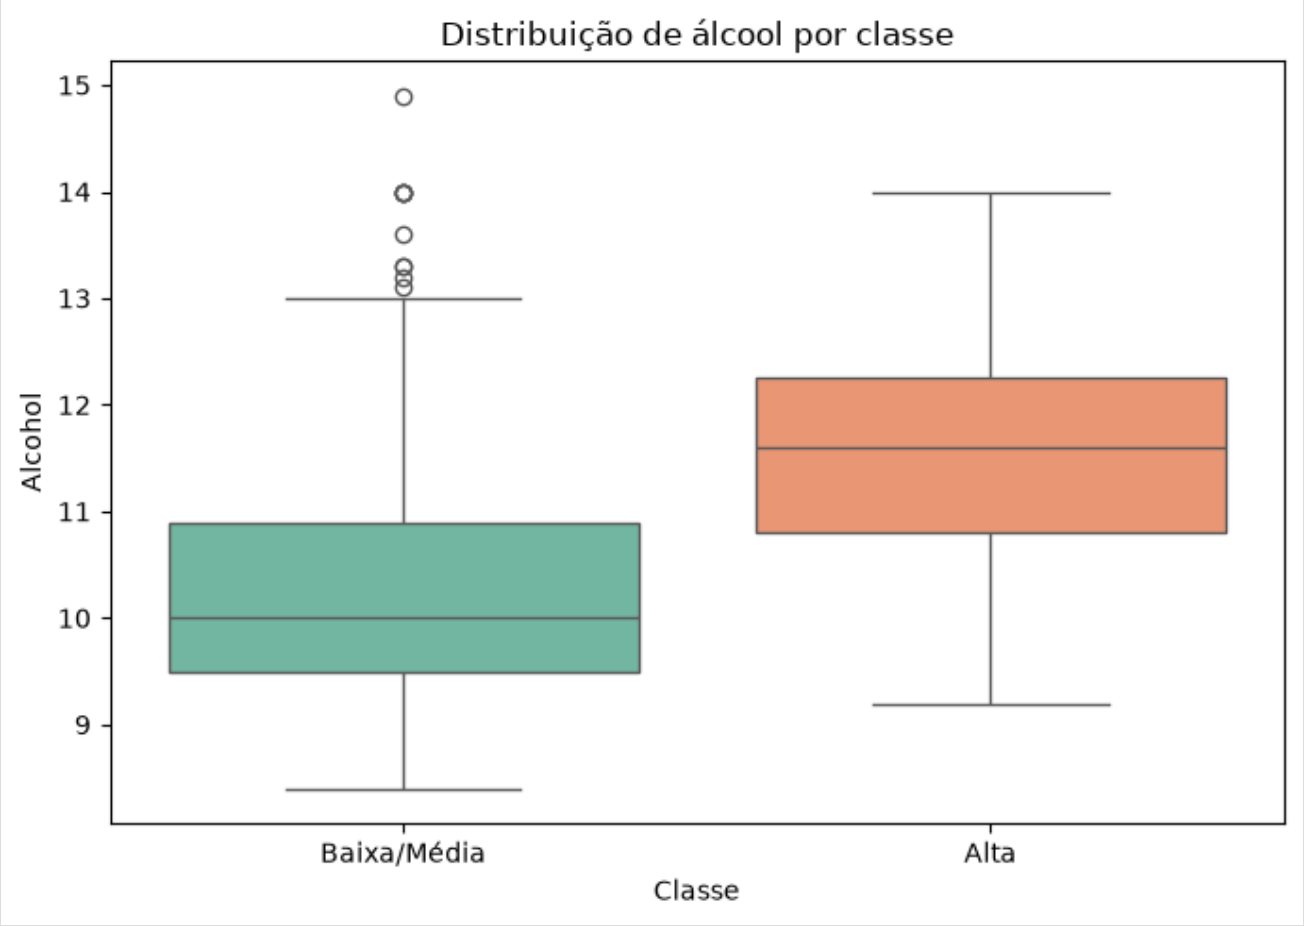
Análise exploratória e entendimento do problema — Gráfico 3

A separação do teor alcoólico por classe reforça o poder discriminativo da variável e a plausibilidade do problema de classificação.



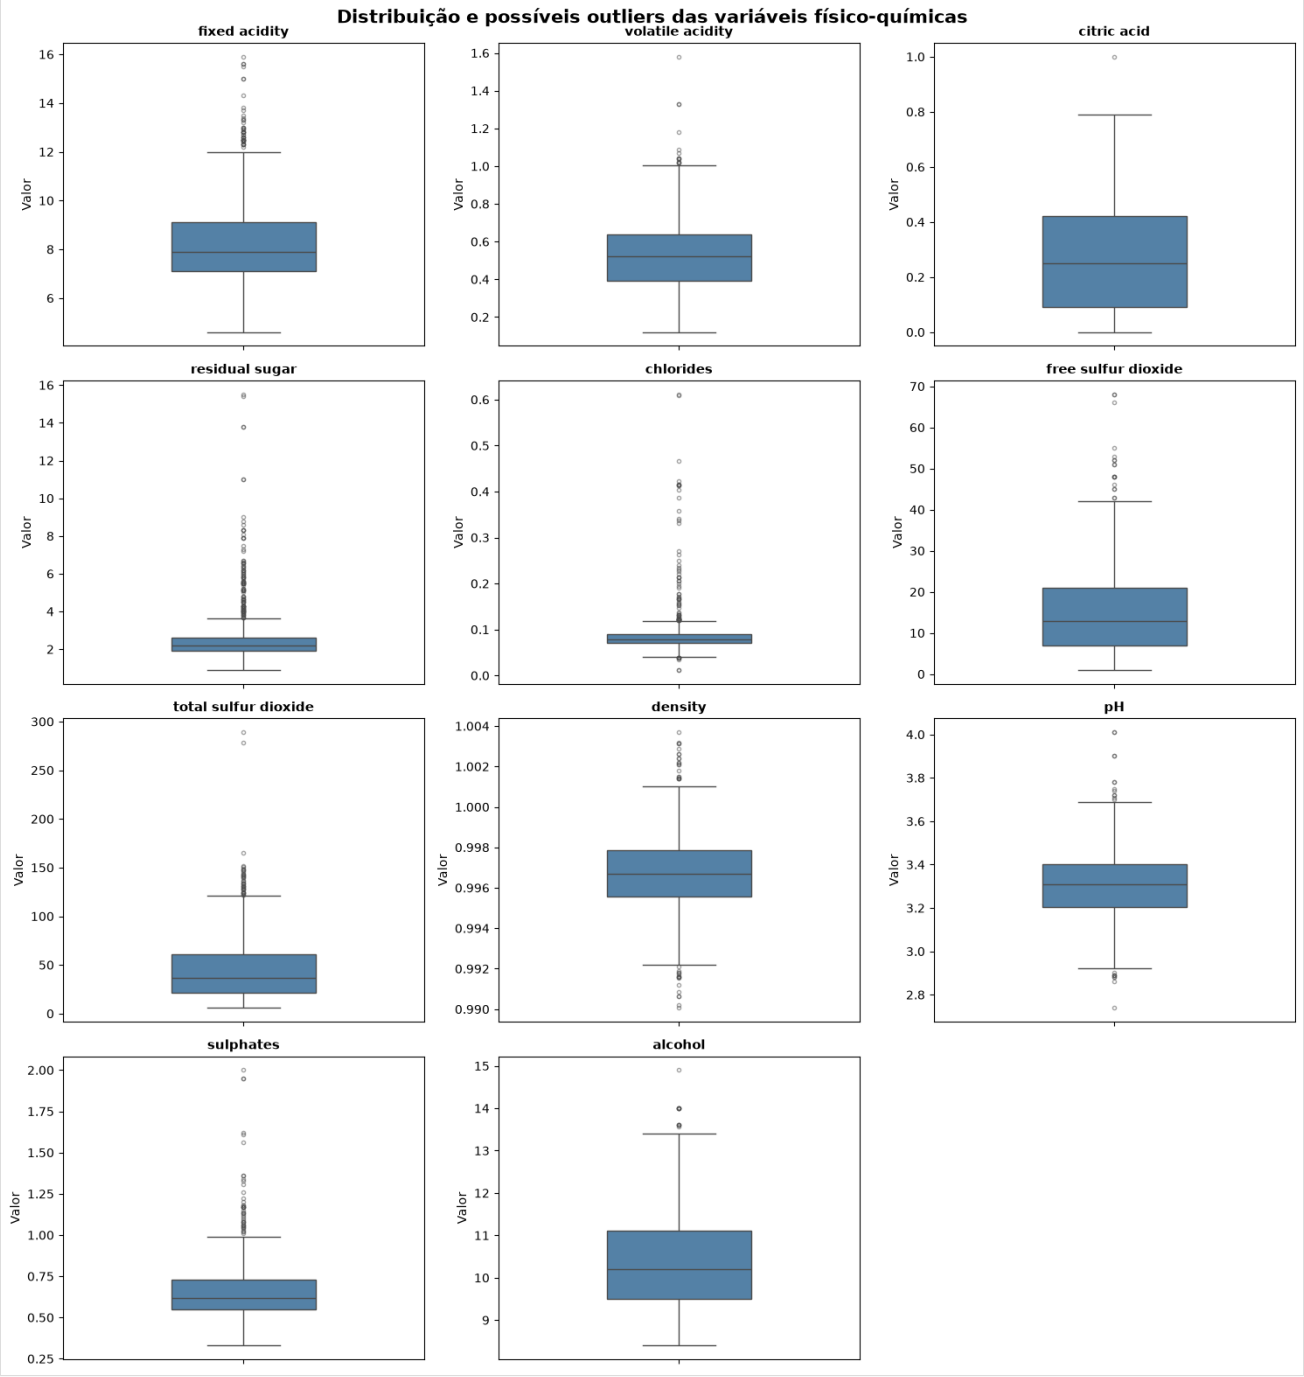
Análise exploratória e entendimento do problema — Gráfico 4

Os gráficos indicam sinais claros de diferença entre classes, mas também deixam evidente que o problema não é simples de uma variável isolada.



Análise exploratória e entendimento do problema — Gráfico 5

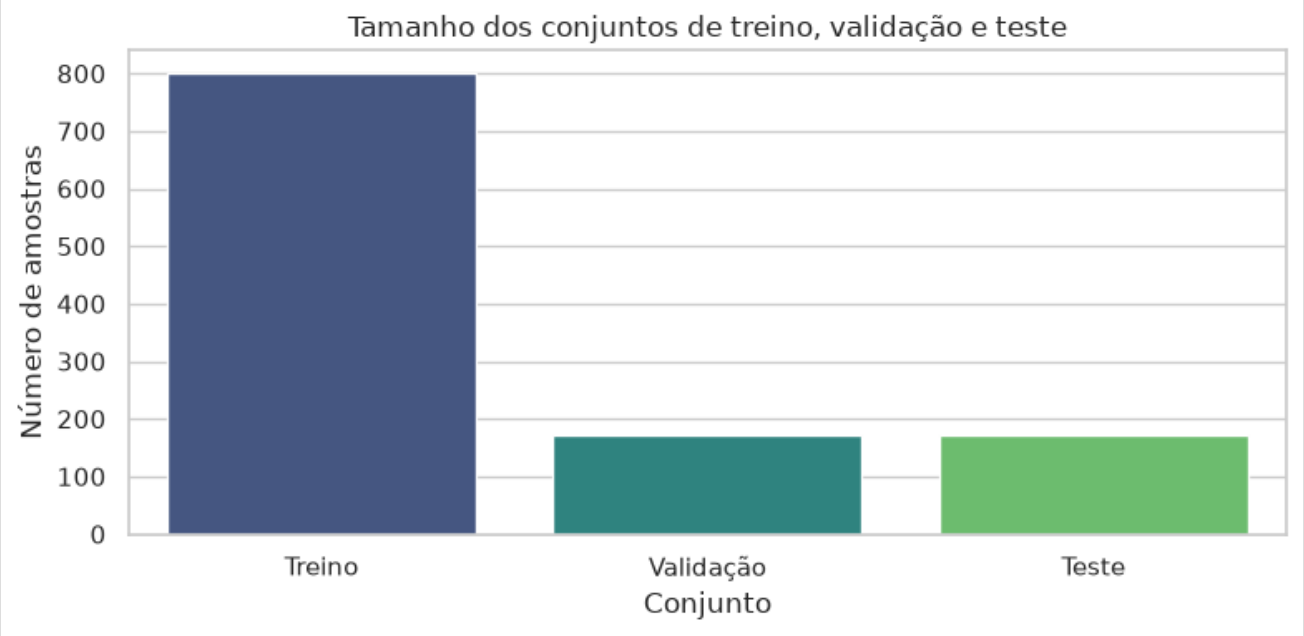
Esse diagnóstico sustentou a continuidade da modelagem com técnicas mais flexíveis do que a regressão linear simples.



Análise exploratória e entendimento do problema — Gráfico 6

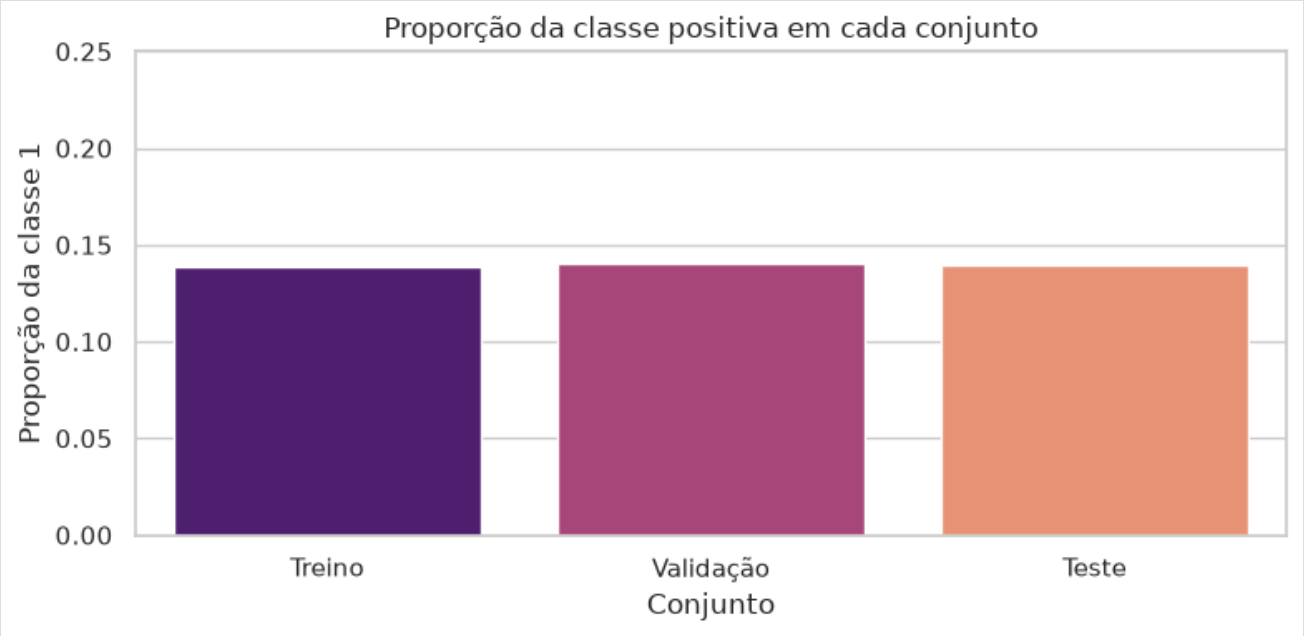
A avaliação de boxplots e da regra de IQR evidencia caudas e possíveis outliers em variáveis físico-químicas, reforçando a necessidade de modelos e transformações robustas.

Modelagem, comparação e decisão final



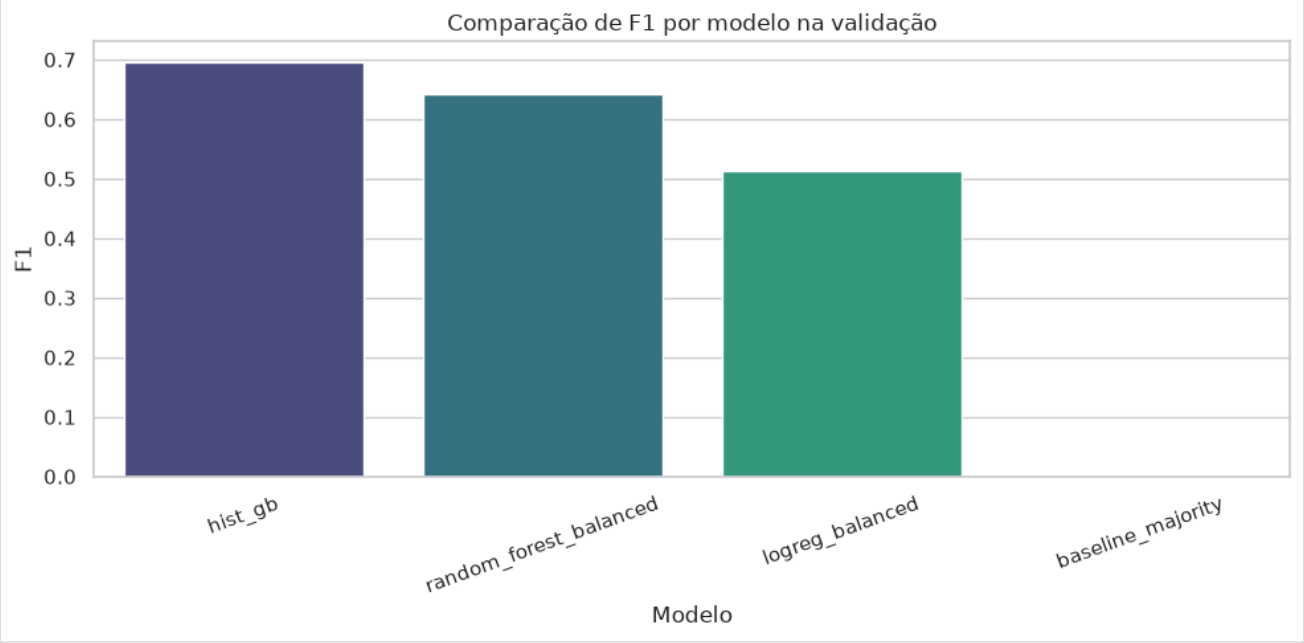
Modelagem, comparação e decisão final — Gráfico 1

A divisão estratificada entre treino e validação preserva a proporção da classe alvo e reduz risco de vazamento de informação.



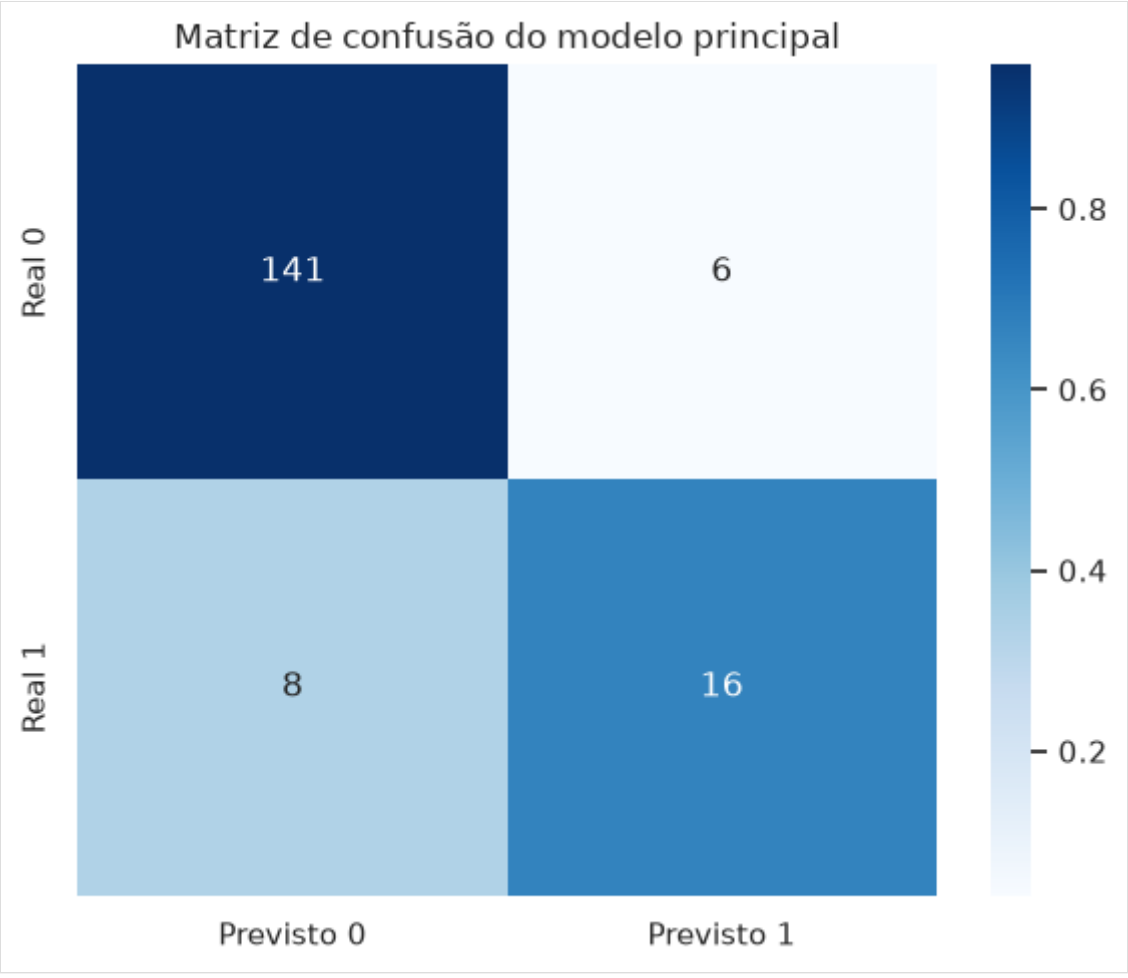
Modelagem, comparação e decisão final — Gráfico 2

A comparação entre modelos mostra que a acurácia isolada não é suficiente quando a classe positiva é minoritária.



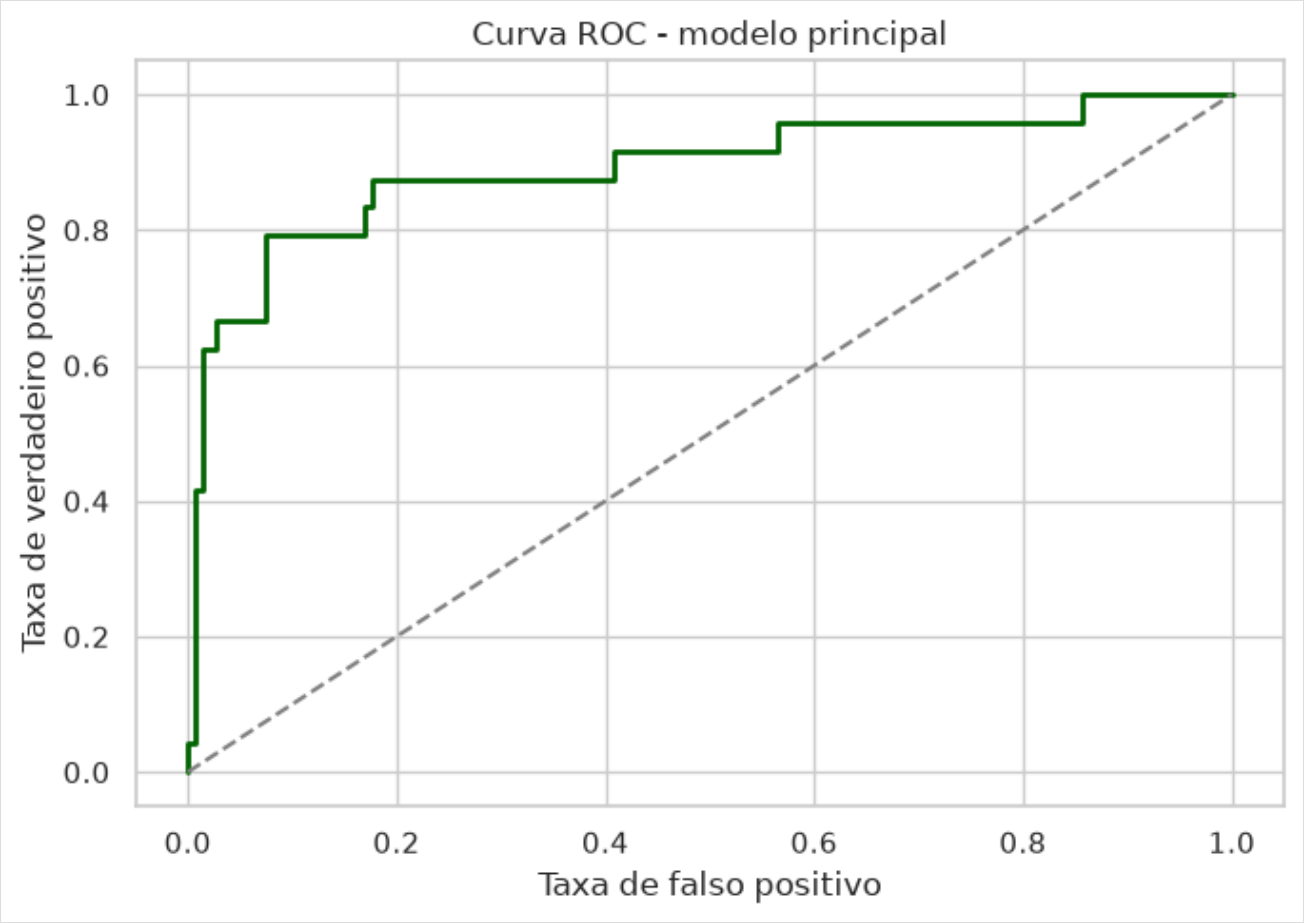
Modelagem, comparação e decisão final — Gráfico 3

O equilíbrio entre recall e precision é central para a decisão, especialmente na classe relevante do problema.



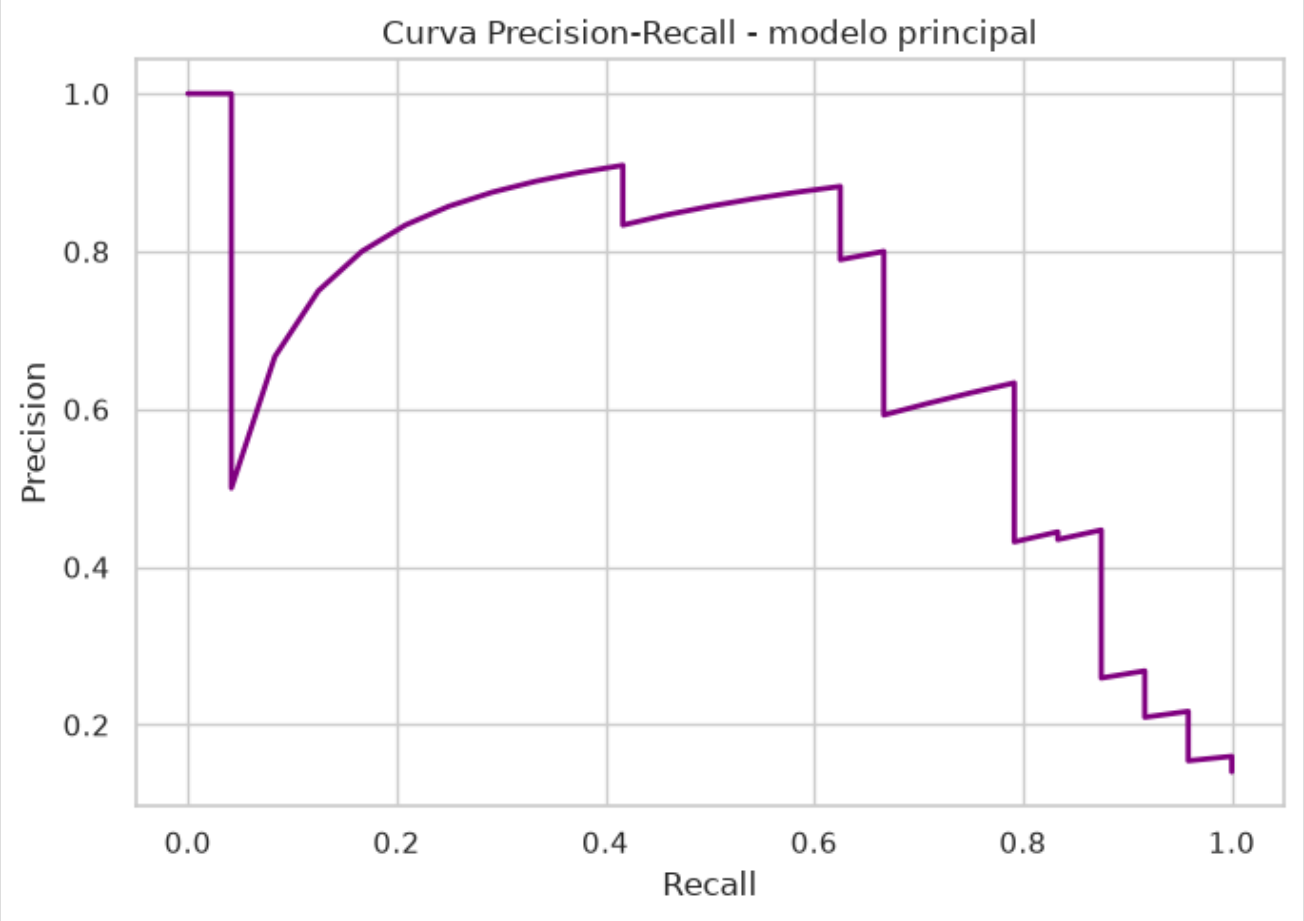
Modelagem, comparação e decisão final — Gráfico 4

A validação interna reforça que o desempenho deve ser medido em conjunto, e não por uma única métrica isolada.



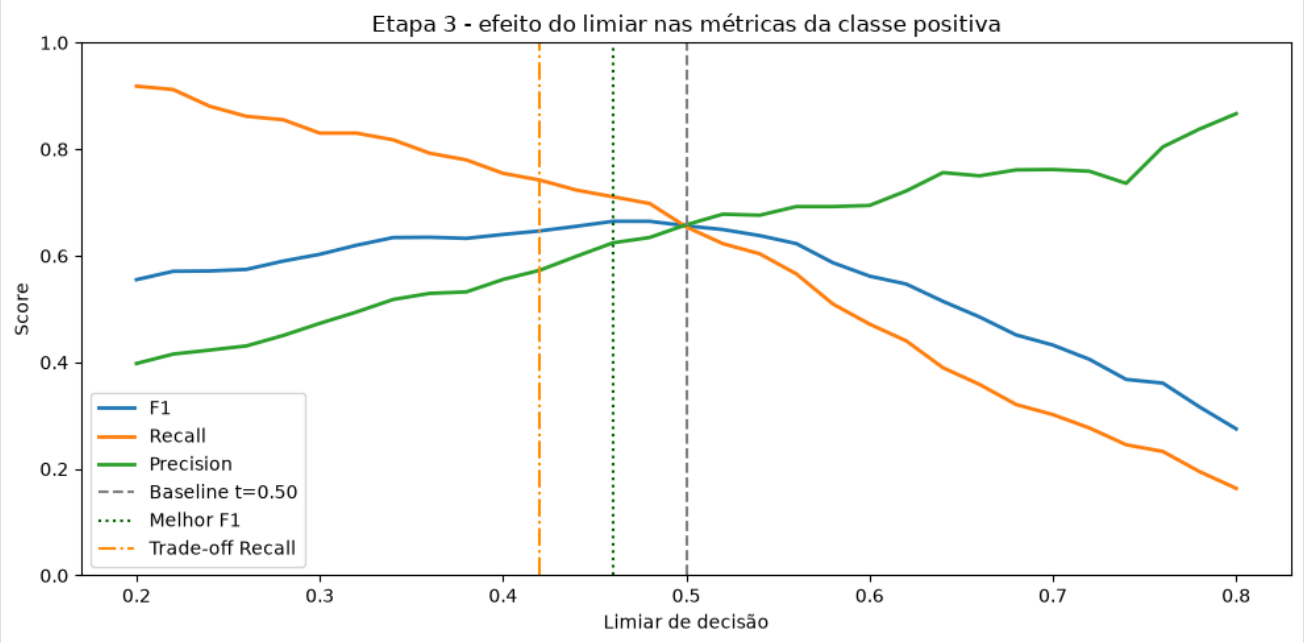
Modelagem, comparação e decisão final — Gráfico 5

Os resultados apontam que o Random Forest e o HistGradientBoosting são os modelos mais competitivos, com diferenças definidas pelo trade-off de negócio.



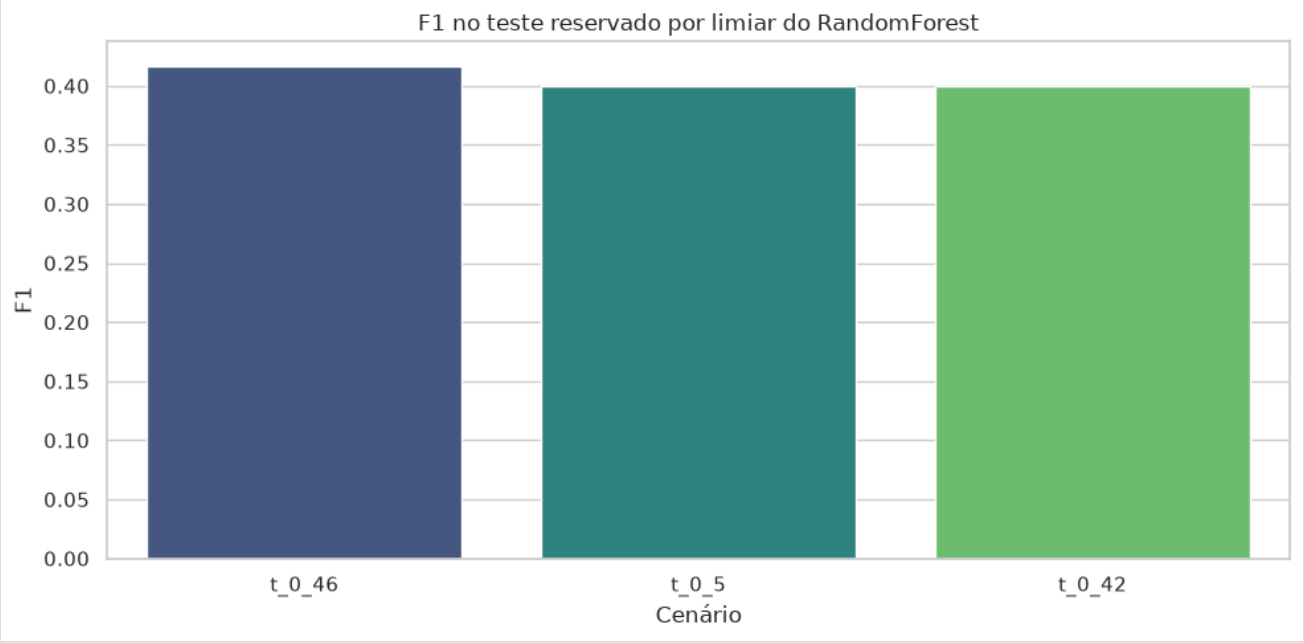
Modelagem, comparação e decisão final — Gráfico 6

A comparação final sustenta a decisão por equilíbrio geral e pela avaliação no conjunto de teste reservado.



Modelagem, comparação e decisão final — Gráfico 7

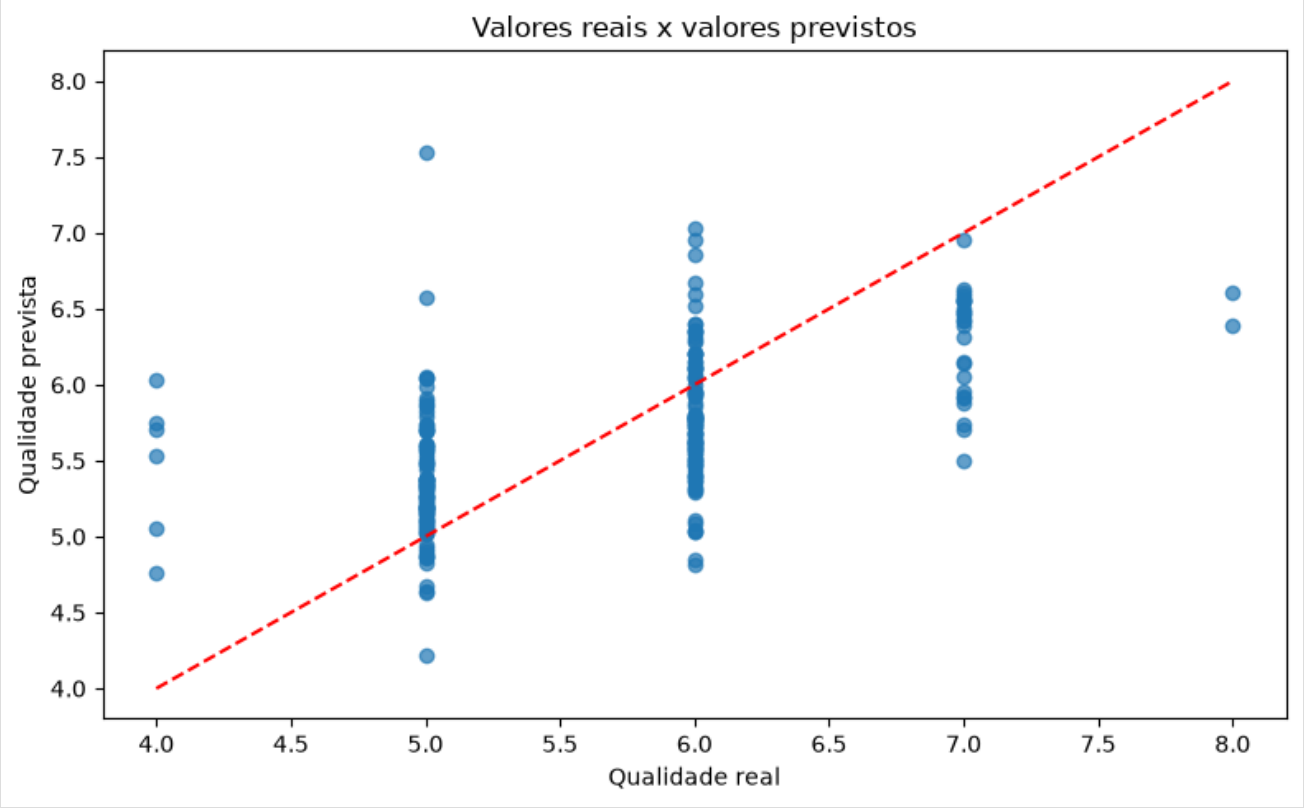
Este gráfico reforça a conclusão analítica do notebook e sustenta a interpretação do modelo.



Modelagem, comparação e decisão final — Gráfico 8

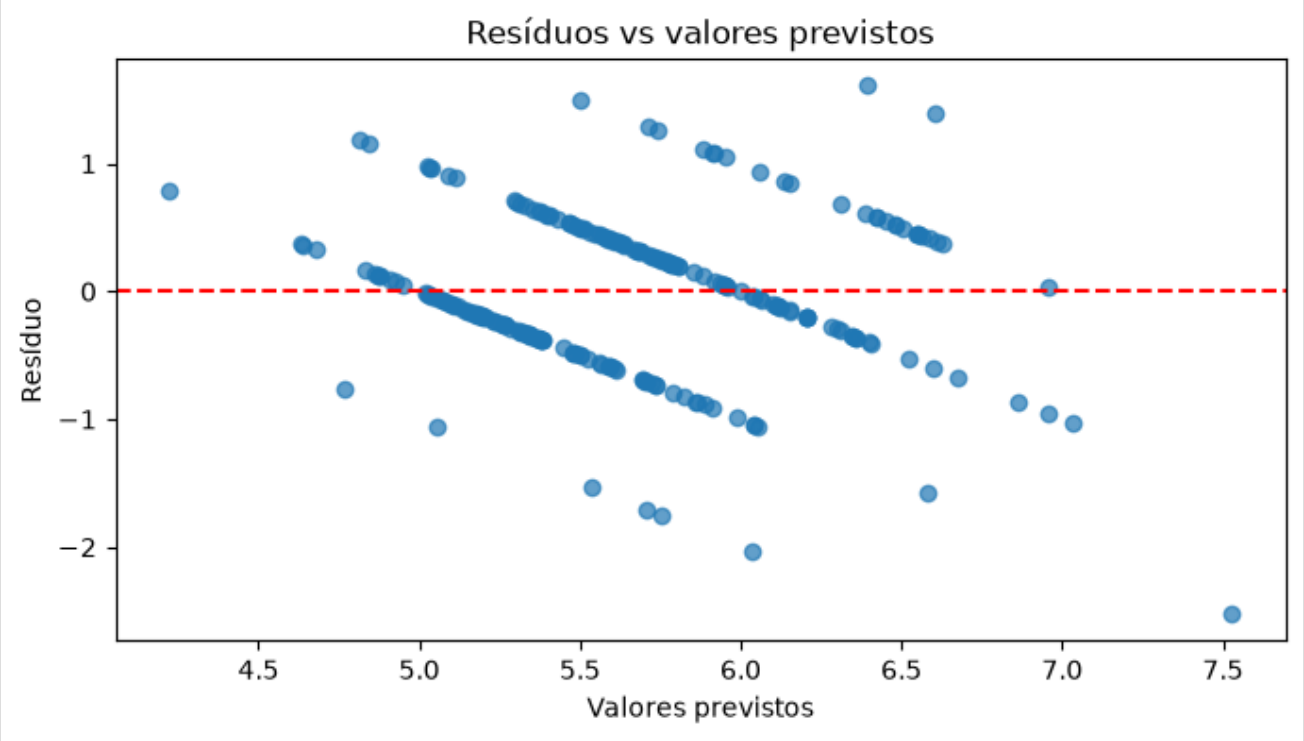
Este gráfico reforça a conclusão analítica do notebook e sustenta a interpretação do modelo.

Regressão Linear



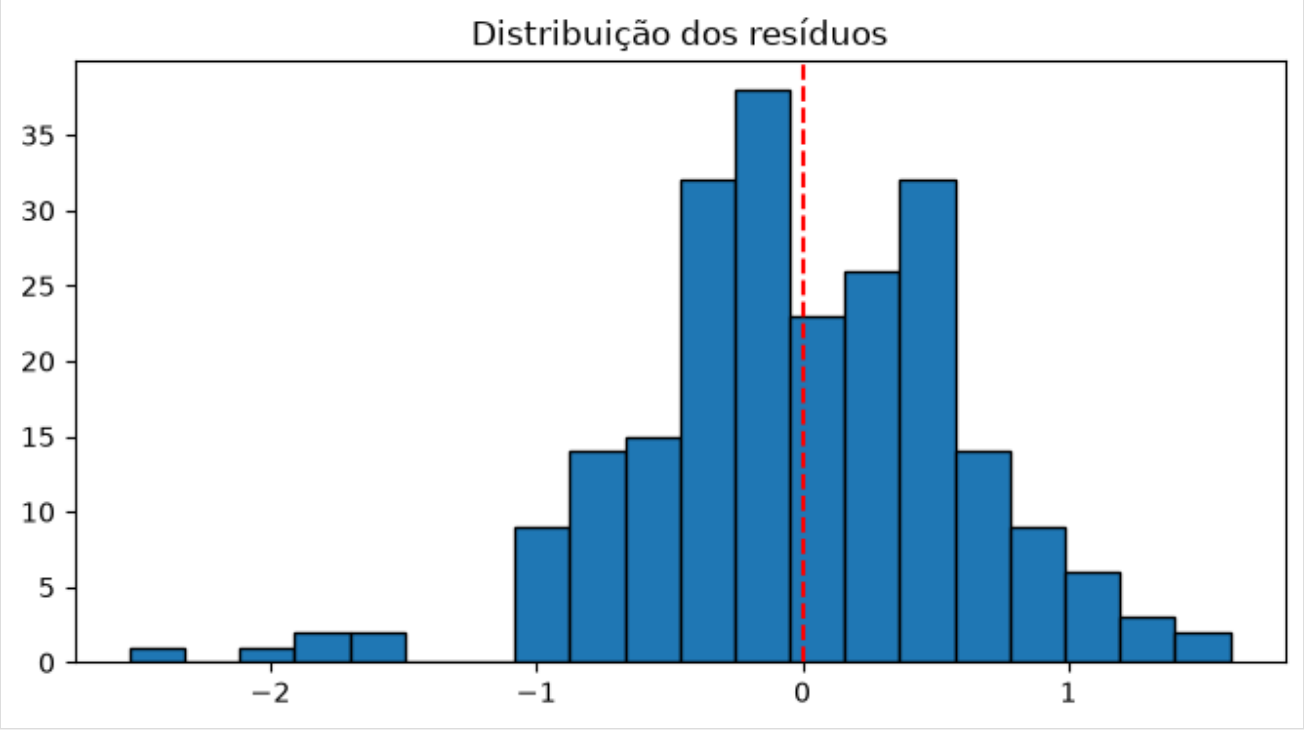
Regressão Linear — Gráfico 1

A regressão linear não captura de forma suficiente a relação entre variáveis e a qualidade do vinho.



Regressão Linear — Gráfico 2

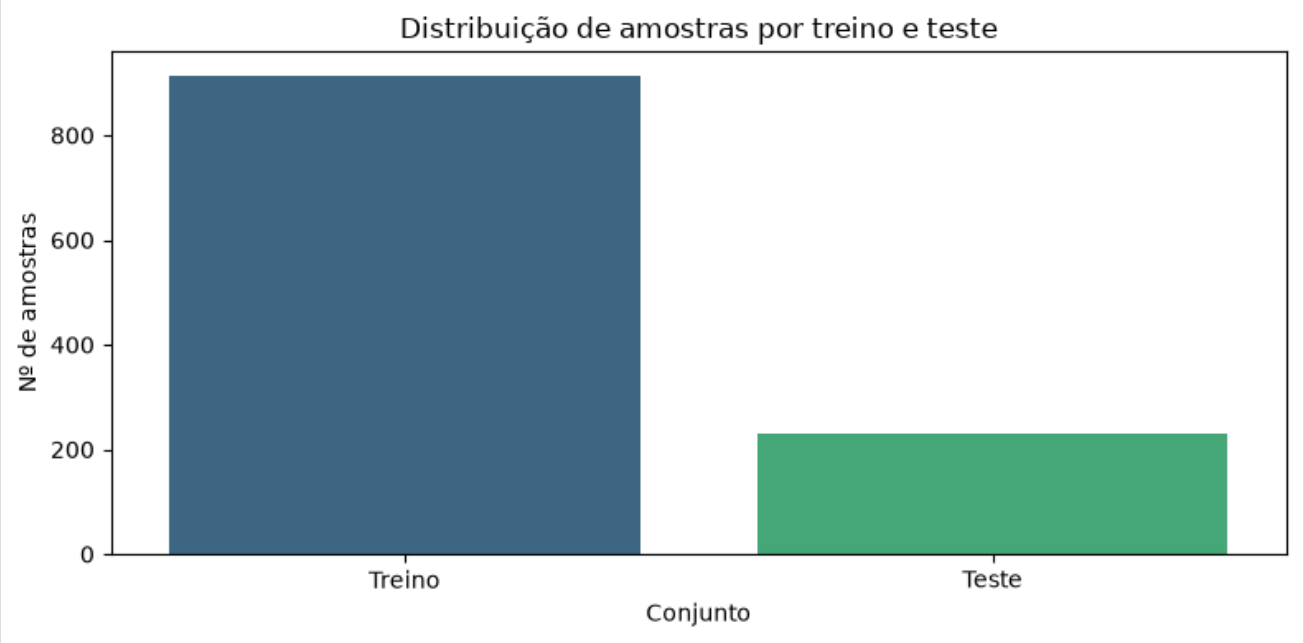
Os resíduos sugerem que o padrão é mais complexo e exige modelos não lineares para uma melhor separação da classe alvo.



Regressão Linear — Gráfico 3

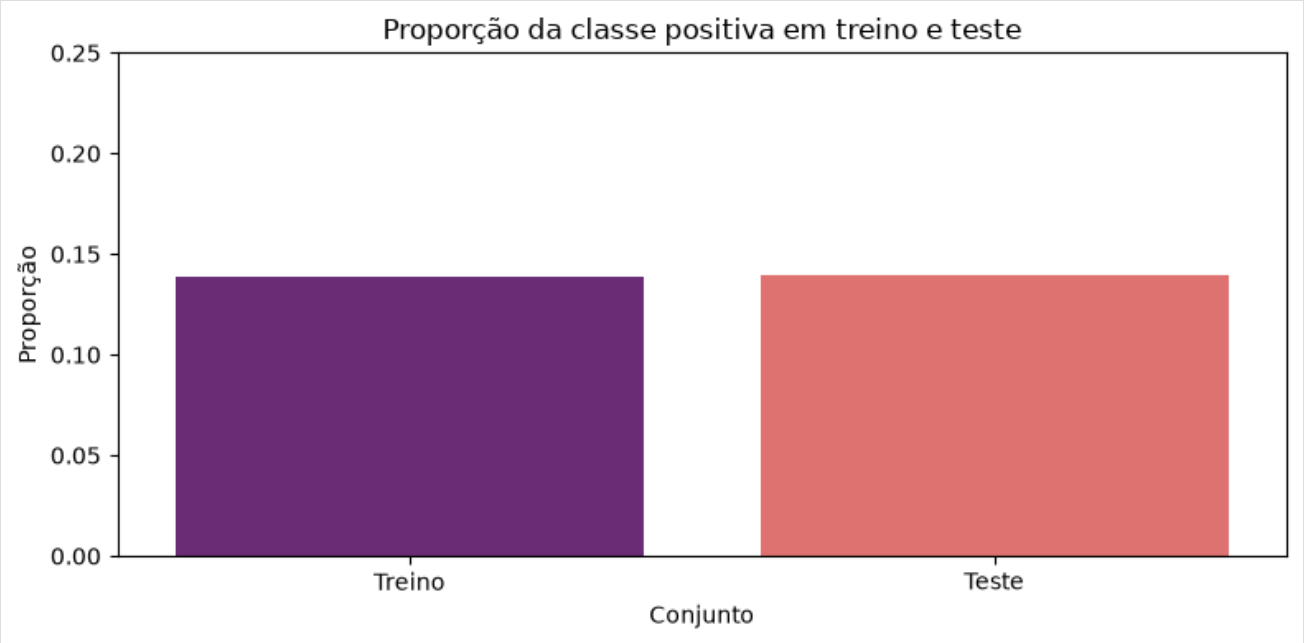
Esse diagnóstico confirma que a regressão linear funciona como referência, mas não como solução principal do problema.

Train/Test Split



Train/Test Split — Gráfico 1

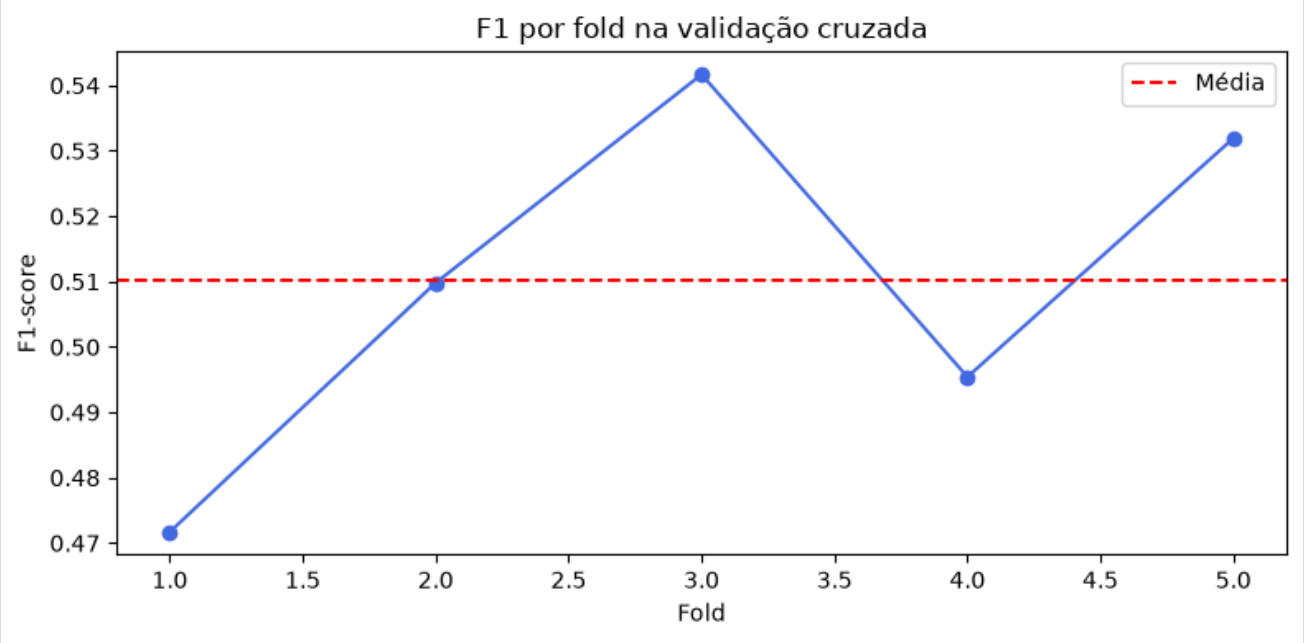
A separação entre treino e teste preserva a capacidade de generalização e evita decisões baseadas em overfitting.



Train/Test Split — Gráfico 2

A comparação em dados não vistos é a base mais confiável para a recomendação final.

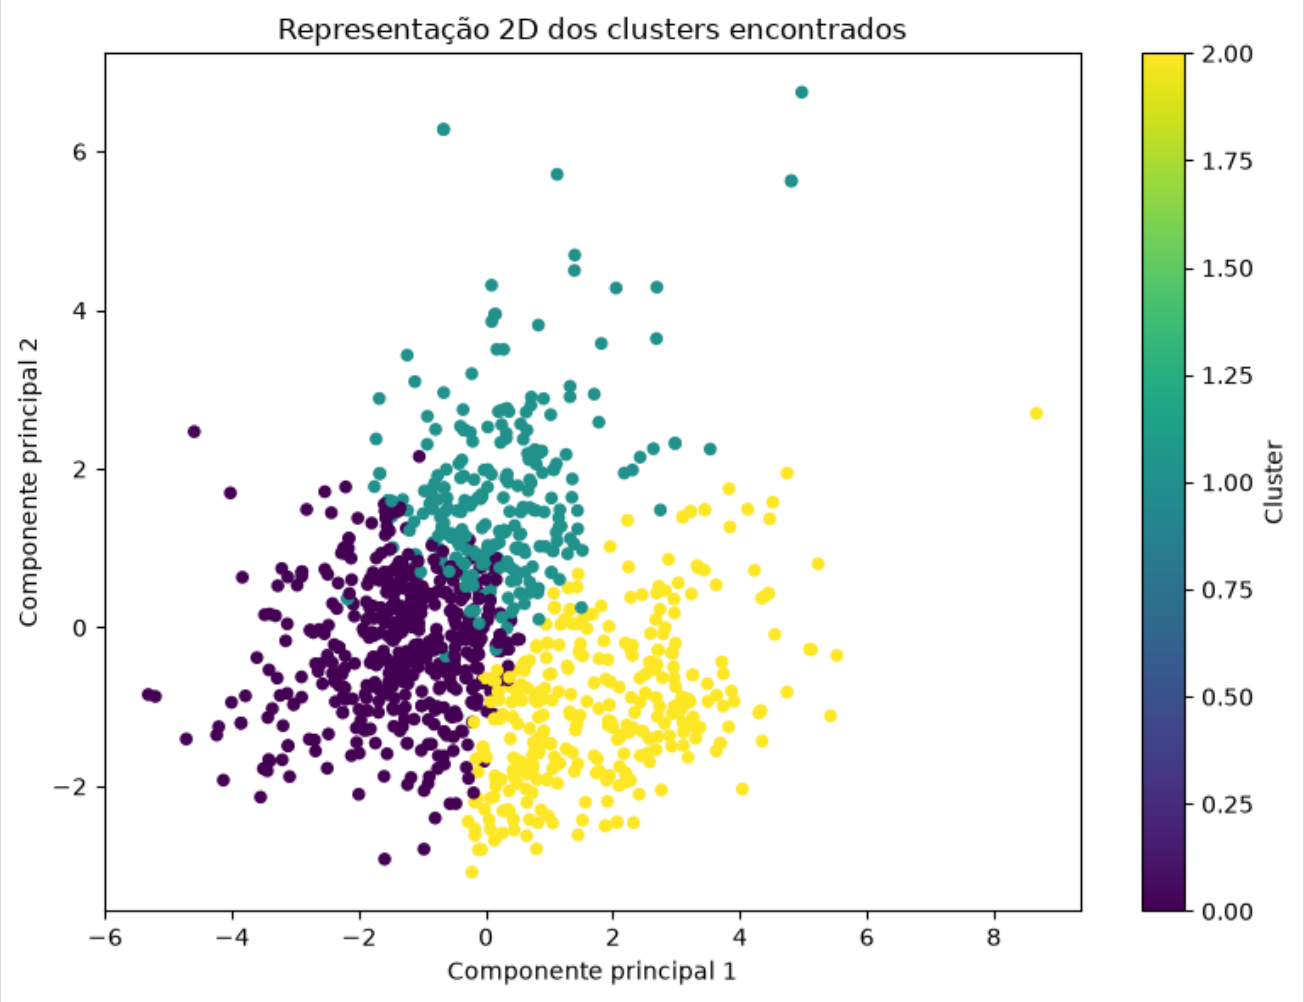
Validação Cruzada



Validação Cruzada — Gráfico 1

A validação cruzada mostra que o desempenho se mantém estável em diferentes subconjuntos do dado, reduzindo o impacto de uma divisão favorável.

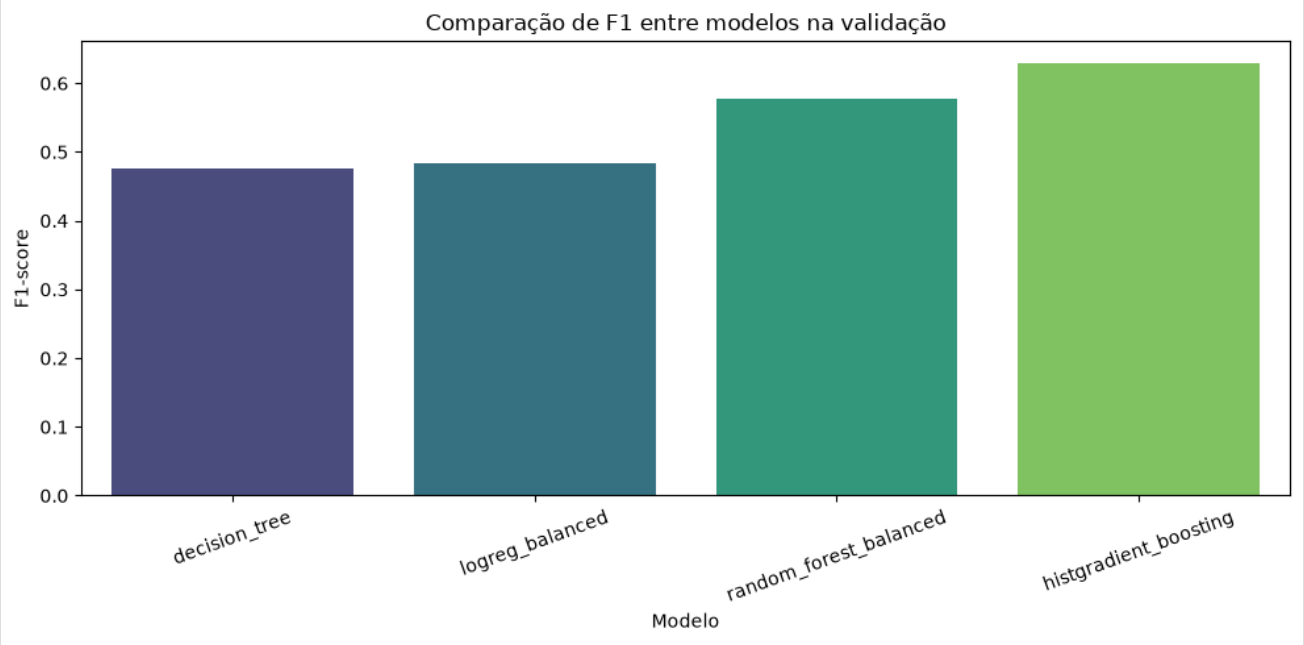
Clusterização



Clusterização — Gráfico 1

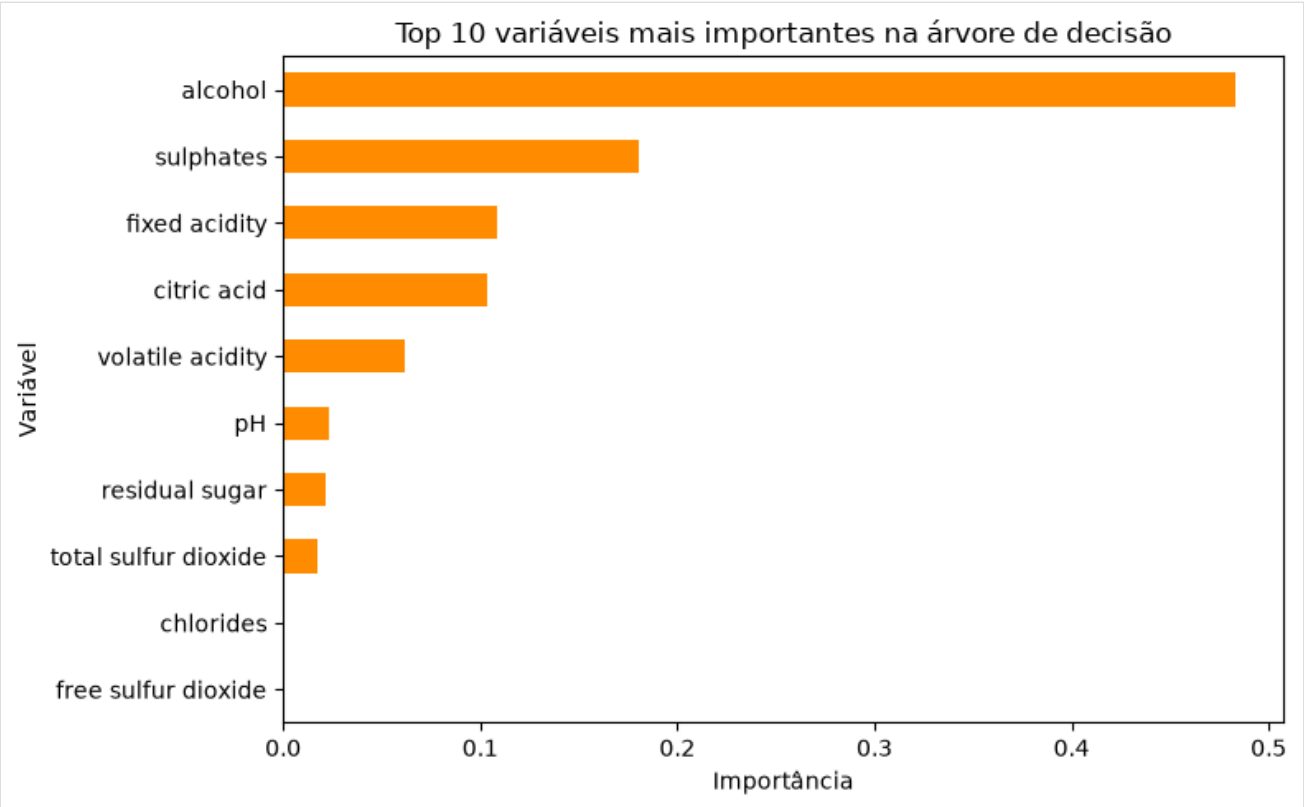
A clusterização não explica diretamente a classe alvo e, por isso, não substitui a modelagem supervisionada.

Árvore de decisão



Árvore de decisão — Gráfico 1

A árvore aumenta a interpretabilidade do modelo e ajuda a explicar regras de decisão.



Árvore de decisão — Gráfico 2

Mesmo com boa explicabilidade, ela não supera a melhor performance global dos modelos de ensemble.

5. Resultados de validação

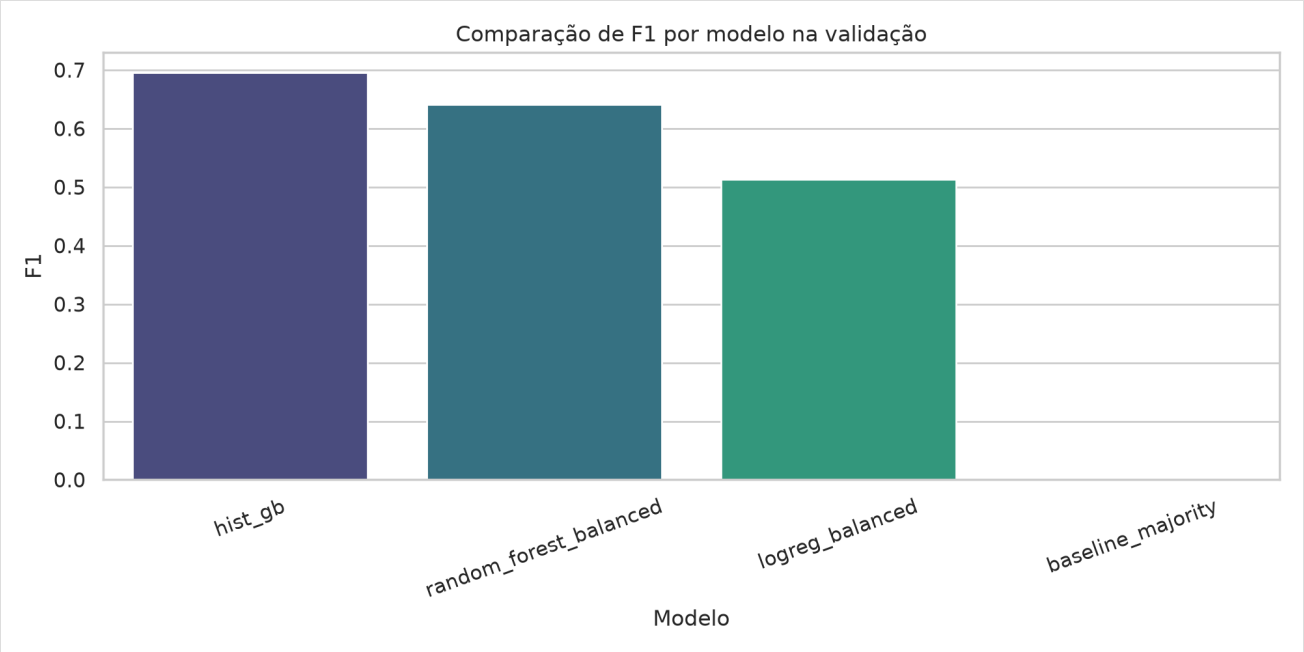


Figura 4 — Comparação de F1 por modelo na validação.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Logistic Regression (balanced)	0.8035	0.4058	0.8750	0.5545	0.8669	0.4762
Random Forest (balanced)	0.9039	0.6562	0.6562	0.6562	0.9408	0.7578
HistGradientBoosting	0.9170	0.7600	0.5938	0.6667	0.9261	0.6688

A performance de validação mostra que:

- o **HistGradientBoosting** apresentou o melhor F1 (0,6667) e precision (0,7600) na etapa de validação;
- o **Random Forest balanceado** ficou muito próximo, com F1 de 0,6563 e ROC-AUC de 0,9408;
- a **Logistic Regression** teve maior recall, mas pior equilíbrio geral e pior precision;
- o **baseline majoritário** não é competitivo e serve apenas como referência.

Ajuste de limiar (Etapa 3)

Após escolher o modelo baseline, foi feito ajuste de limiar usando apenas validação cruzada estratificada. O objetivo foi deixar claro o trade-off entre recall e precision da classe positiva.

Cenário	Limiar	F1	Recall	Precision
Baseline t=0.50	0.5000	0.6562	0.6541	0.6582

Cenário	Limiar	F1	Recall	Precision
Melhor F1	0.4600	0.6647	0.7107	0.6243
Trade-off de recall	0.4200	0.6466	0.7421	0.5728

A recomendação operacional padrão é **limiar 0.46**, por melhor F1 médio na validação. Se a prioridade for aumentar sensibilidade da classe positiva, o cenário em **0.42** aumenta recall, com queda de precision.

Checagem final no teste reservado

A comparação final confirmou que, para o Random Forest, o limiar 0.46 melhorou F1 e recall em relação ao limiar 0.50, com pequena queda de acurácia.

Limiar	Acurácia	Precision	Recall	F1
t=0.50	0.8430	0.4286	0.3750	0.4000
t=0.46	0.8372	0.4167	0.4167	0.4167
t=0.42	0.8256	0.3846	0.4167	0.4000

6. Avaliação final no teste reservado

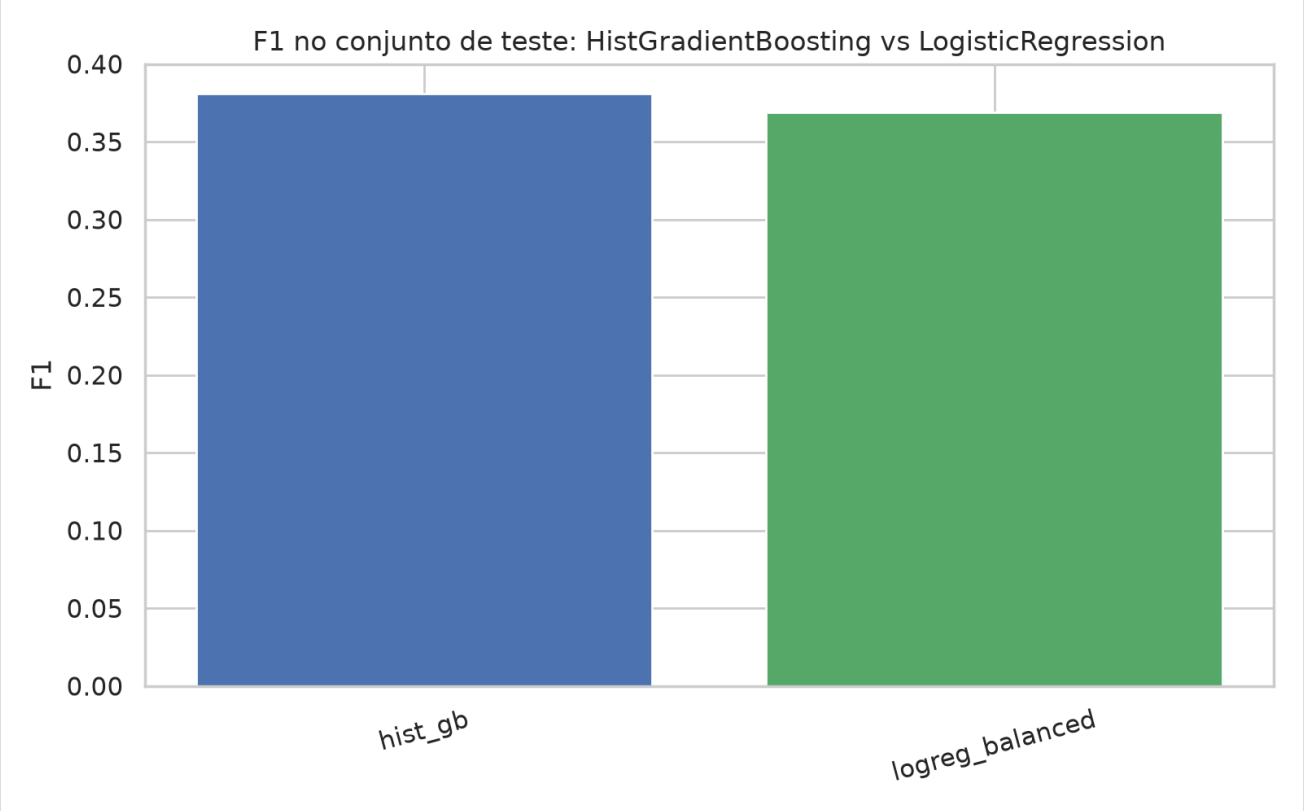


Figura 5 — Comparação final no conjunto de teste.

O conjunto de teste reservado foi a etapa decisiva. O Random Forest balanceado ficou como principal por manter melhor equilíbrio entre F1 e recall da classe positiva. O HistGradientBoosting manteve boa precision, mas com recall menor.

Modelo	Acurácia	Precision	Recall	F1	ROC-AUC	Average Precision
Baseline majoritário	0.8603	0.0000	0.0000	0.0000	0.5000	0.1397
Random Forest (balanced)	0.8996	0.6364	0.6562	0.6462	0.8910	0.6719
HistGradientBoosting	0.9039	0.7273	0.5000	0.5926	0.8826	0.6678

Em termos práticos, o **Random Forest** teve melhor equilíbrio para este problema desbalanceado. O **HistGradientBoosting** segue como alternativa quando a prioridade for precision.

7. Conclusão final

A recomendação final do projeto é:

- **Random Forest balanced** como modelo principal;
- **limiar 0.46** como configuração padrão de classificação;
- **limiar 0.42** como alternativa quando a meta for maior recall;
- **HistGradientBoosting** como alternativa preferencial quando a organização prioriza precision;
- **regressão linear** e **clusterização** como diagnósticos e ferramentas complementares, mas não como solução principal;
- **árvore de decisão** como apoio interpretativo, não como substituta da melhor performance global.

Em síntese, a decisão foi guiada por evidência de validação e teste reservado. O projeto fecha com modelo definido e política de limiar clara para diferentes objetivos de negócio.

Relatório executado com base nos resultados finais do WineQT e nos notebooks gerados no projeto.